

APPROCCI *IN SILICO*

per la progettazione di farmaci biotecnologici

— ratio in proteinis —

Manuale di lezione

Trascrizioni WhisperX corrette e organizzate accademicamente
delle dodici lezioni del prof. **Ivano Eberini**

con contributo del dott. Davide Bassani

Università degli Studi di Milano
Laurea Magistrale in Biotecnologie del Farmaco
Anno Accademico 2025–2026

Premessa

Notae editoriales

Questo manuale raccoglie e riorganizza in forma accademica le trascrizioni automatiche (WhisperX large-v3, con Demucs attivo) delle dodici lezioni del corso di *Approcci in silico per la progettazione di farmaci biotecnologici*, tenuto dal prof. Ivano Eberini presso il Laboratorio di Immunometabolismo del Dipartimento di Scienze Farmacologiche e Biomolecolari dell'Università degli Studi di Milano.

Le trascrizioni grezze prodotte dal sistema di speech-to-text contengono inevitabili errori di riconoscimento — soprattutto su terminologia tecnica, acronimi, nomi propri di amminoacidi, recettori, software e algoritmi. In questo manuale tali errori sono stati corretti ricostruendo la terminologia originaria a partire dal contesto biochimico e bioinformatico, dalla letteratura di riferimento e dalla pratica didattica del corso. Sono stati altresì rimossi gli inevitabili passaggi di servizio (chiamate di presenza, problemi tecnici, digressioni non pertinenti) preservando però le digressioni scientifiche e gli aneddoti didatticamente rilevanti, che costituiscono parte integrante dello stile espositivo del docente.

Il filo conduttore del corso è esplicitato fin dalla prima lezione: *l'omologia* tra proteine — non quantificabile direttamente, ma misurabile in modo surrogato attraverso identità e similarità di sequenza — è il fondamento su cui si costruisce ogni inferenza strutturale e funzionale *in silico*. Da qui muovono, in ordine logico più che strettamente cronologico: il problema degli allineamenti di sequenza, lo sviluppo delle matrici di sostituzione, la statistica degli allineamenti, *l'homology modeling*, la dinamica molecolare, i metodi *ab initio*, fino all'ottimizzazione razionale degli anticorpi monoclonali.

Convenzioni tipografiche

- I **termini tecnici** introdotti per la prima volta sono in grassetto.
- I *nomi di software, algoritmi e database* sono in corsivo, secondo la convenzione bioinformatica.
- I valori numerici di riferimento (cutoff energetici, soglie statistiche, percentuali di identità) sono riportati così come dati dal docente.
- Quando il prof. Eberini cita esplicitamente un punto come potenziale domanda d'esame, ciò è segnalato in nota e ripreso nella sezione finale.
- Le sezioni numerate seguono la sequenza delle lezioni; al loro interno il discorso del docente è strutturato in paragrafi tematici.

Nota — Il presente manuale non sostituisce la frequenza alle lezioni né lo studio del materiale ufficiale caricato dal docente su Microsoft Teams. Costituisce piuttosto uno strumento di studio integrativo, costruito a partire dalla viva voce del prof. Eberini e ordinato in modo da rendere agile la ripresa dei concetti in vista dell'esame.

Indice

Premessa — iii

Lezione 1 — Omologia, accuratezza, fondamenti della bioinformatica strutturale — 1

Lezione 2 — Dal punteggio binario alla statistica: introduzione agli allineamenti —

Lezione 3 — Allineamenti di sequenza, dot plot, matrici di sostituzione PAM —

Lezione 4 — Statistica degli allineamenti, profili, PSI-BLAST e modelli di Markov nascosti —

Lezione 5 — Caso di studio: β -lattoglobulina, transizione di Tanford, riconoscimento del ligando —

Lezione 6 — Homology modeling: β -lattoglobulina di bufalo e introduzione a GPR17 — —

Lezione 7 — Completamento del modeling di GPR17, validazione e identificazione del sito di legame
— —

Lezione 8 — Dinamica molecolare: teoria, campi di forza, ensemble termodinamici — —

Lezione 9 — Predizione di proprietà dalla struttura primaria, reti neurali, BLAST — —

Lezione 10 — Costruzione e validazione dei modelli, CASP, threading, modeling de novo/ab initio —
—

Lezione 11 — Pratica MOE: ottimizzazione dell'anticorpo CNT-O627 e Antibody Modeler — —

Lezione 12 — Dinamica molecolare delle glicoforme anticorpali e ruolo del dominio Fc — —

Glossario tecnico — —

Tabelle riassuntive — —

Domande d'esame possibili — —

Lezione 1

Omologia, accuratezza e fondamenti della bioinformatica strutturale

Marzo 2026 — Prima lezione introduttiva

1.1 Il concetto cardine: l'omologia

Il corso si apre con la definizione del concetto attorno al quale ruoterà l'intera trattazione della bioinformatica strutturale: l'**omologia**. Due proteine (o due geni) si dicono omologhe quando condividono un **antenato comune**, vale a dire quando derivano filogeneticamente da un gene o da una proteina ancestrale comune.

Dogma biofisico fondamentale. Proteine omologhe condividono **struttura, funzione e architettura**. È questo principio che giustifica l'utilità operativa del concetto di omologia: se la mia proteina di interesse è omologa ad una proteina già caratterizzata, posso inferire per essa struttura, funzione ed architettura senza doverle determinare ex novo.

Un esempio pratico: in laboratorio si è isolata una proteina ignota e se ne conosce soltanto la **struttura primaria** (il termine corretto per la sequenza amminoacidica; il vocabolo *sequenza* in senso stretto è riservato agli acidi nucleici). Se in un database trovo proteine omologhe alla mia, ben caratterizzate strutturalmente e funzionalmente, posso attribuire alla mia molecola, in via inferenziale, la stessa struttura tridimensionale, la stessa architettura di folding e — verosimilmente — una funzione simile.

1.1.1 L'omologia non è quantitativa

Un punto su cui il prof. Eberini insiste con particolare fermezza: **l'omologia non è quantitativa, è qualitativa**. Due proteine sono omologhe oppure non lo sono. Non esiste un *40% di omologia*: tale formulazione, che pure si incontra anche in letteratura, è **concettualmente scorretta**.

«Quando trovate scritto anche nei paper scientifici un'omologia del 40%, state leggendo qualcosa di sbagliato. È un po' come la gravidanza: non si può essere un po' incinta. O si è incinta, o non si è incinta. Stessa cosa per l'omologia.»

Si possono al limite distinguere casi di **distant homology** (omologia distante) — concetto probabilistico, non quantitativo — quando l'evidenza statistica di parentela filogenetica è debole.

1.1.2 Identità e similarità: indicatori surrogati

Poiché l'omologia non è misurabile direttamente, in pratica si ricorre a due indicatori surrogati che invece sono pienamente quantitativi: l'**identità di sequenza** e la **similarità di sequenza**. Si possono affermare quantità: 40% di identità, 60% di similarità.

Identità di sequenza. Percentuale di posizioni in cui, in un allineamento, le due sequenze presentano lo stesso amminoacido.

Similarità di sequenza. Percentuale di posizioni in cui le due sequenze presentano amminoacidi con caratteristiche chimico-fisiche analoghe (sostituzioni conservative), pesata secondo una matrice di sostituzione.

Identità e similarità ci forniscono la **probabilità** che due proteine siano omologhe. Misuriamo questi parametri non perché ci interessino in sé, ma perché sono ciò che possiamo realmente misurare; l'obiettivo ultimo resta l'inferenza dell'omologia e quindi dell'identità di struttura, funzione e architettura.

1.2 Sottoclassificazioni dell'omologia

1.2.1 Ortologia

Due proteine si dicono **ortologhe** quando rappresentano la stessa proteina (con la medesima funzione) in **specie diverse**. Esempio paradigmatico: l'albumina umana, l'albumina bovina e l'albumina della trota sono ortologhe in quanto derivano da un'albumina ancestrale comune e mantengono la stessa funzione fisiologica.

Si tratta dunque di una relazione **verticale** nell'albero filogenetico, lungo le linee di speciazione.

1.2.2 Paralogia

Due proteine si dicono **paraloghe** quando, all'interno della **stessa specie**, derivano da un evento di duplicazione genica e si sono successivamente specializzate per svolgere funzioni parzialmente diverse — spesso non funzioni completamente differenti, ma **specializzazioni** diverse di una funzione affine.

Esempio: **LCAT** (*Lecithin–Cholesterol Acyltransferase*) esterifica il colesterolo nel plasma; **ACAT** (*Acyl-CoA:Cholesterol Acyltransferase*) esterifica il colesterolo all'interno delle cellule. Entrambe sono presenti nell'uomo, derivano da un antenato comune ed esterificano il colesterolo, ma in compartimenti diversi: sono paraloghe.

1.2.3 Xenologia

La **xenologia** si riferisce a sequenze altamente conservate fra specie filogeneticamente molto distanti, conservazione che non è spiegabile attraverso il normale processo evolutivo. La spiegazione più frequente è il **trasferimento genico orizzontale** mediato da virus, capaci di veicolare materiale genetico fra specie diverse.

Nota — Nel contesto di questo corso ci concentreremo sull'ortologia e sulla paralogia. La xenologia, sebbene fenomenologicamente affascinante, è raramente rilevante per gli scopi di drug design e di antibody engineering qui trattati.

1.3 Accuratezza dei metodi: un concetto cruciale

Il secondo grande principio metodologico del corso riguarda l'**accuratezza**. Un errore frequente da parte degli studenti consiste nel ragionare in modo lineare: «se devo risolvere un problema, scelgo il metodo più accurato disponibile». Questo ragionamento è sbagliato.

«Tutte le volte che noi vedremo dei metodi, io insisterò sull'accuratezza di questi metodi. Perché? Perché non sempre per rispondere a una domanda biologica avrete bisogno del livello di accuratezza più alto. Ma avrete bisogno del livello di accuratezza più alto per rispondere alla vostra specifica domanda.»

1.3.1 L'esempio della diagnostica COVID

Il prof. Eberini propone un esempio illuminante. Si chieda: qual è il metodo più tecnologicamente avanzato per la diagnostica del COVID-19? La risposta corretta è la **RT-PCR** (la diagnostica molecolare). Eppure, nella pratica quotidiana, il **test antigenico** rapido — metodologicamente molto più semplice — si è rivelato la scelta migliore per la diagnostica di massa, per diverse ragioni:

- **Accessibilità**: eseguibile a casa, senza personale specializzato.
- **Costo**: significativamente inferiore.
- **Rapidità**: risultato in pochi minuti.

• **Specificità in fase post-guarigione:** la PCR continuava a risultare positiva per 30, 40, 50 giorni dopo la guarigione clinica, rilevando frammenti residui di acidi nucleici legati al particolato delle cavità nasali. L'antigenico, riconoscendo l'antigene proteico intatto, evita questo bias diagnostico.

Morale: **il metodo migliore è quello con il livello di accuratezza adeguato alla domanda, compatibile con i tempi e con le risorse disponibili.** Non necessariamente quello più tecnologicamente avanzato.

1.3.2 L'esempio del virtual screening farmacologico

Si supponga di dover identificare, in una libreria di un milione e mezzo di molecole, quelle attive su un determinato bersaglio farmacologico. L'energia che andiamo a misurare per quantificare l'interazione proteina–ligando è l'**energia libera di legame** (*binding free energy*), ΔG° , . . .

Relazione tra energia libera di legame e costante di dissociazione. A temperatura costante: $\Delta G^\circ_{\text{bind}} = -RT \ln K_a = RT \ln K_d$. Quindi dalla variazione di energia libera di legame si calcola direttamente la costante di dissociazione K_d , che rappresenta l'inverso dell'affinità.

Per uno screening di 1,5 milioni di molecole è impensabile calcolare ΔG° accuratissimi (per esempio con metodi di *free energy perturbation*): il calcolo non finirebbe in tempi umani. In questa fase ci si accontenta di metodi **approssimati** — le cosiddette **scoring functions empiriche** — con un'accuratezza dell'ordine di **un ordine di grandezza** in energia libera di legame. È sufficiente, perché:

K_d	Significato farmacologico	Strategia
nanomolare	Legame molto buono — <i>hit</i> potenziale	Si conserva
micromolare	Legame debole — possibile <i>lead</i>	Si ottimizza
millimolare	Non lega significativamente	Si scarta

Fra nanomolare e micromolare ci sono tre ordini di grandezza (1000×); fra nanomolare e millimolare un milione di volte. Un errore di un ordine di grandezza in queste fasi è perfettamente accettabile: l'obiettivo è scartare il 99,9% delle molecole inattive, non quantificare con precisione l'affinità di ciascuna.

1.3.3 Quando invece serve accuratezza assoluta

Lo scenario cambia radicalmente quando si lavora su una **serie congenere** di molecole — per esempio i diversi -prazoli inibitori della pompa protonica (omeprazolo, pantoprazolo, lansoprazolo, esomeprazolo, rabeprazolo): in questo caso le molecole sono molto simili fra loro e lo scopo è discriminare fini differenze di affinità. Qui servono **metodi accurati** di calcolo dell'energia libera; ma ne abbiamo 10 molecole, non 1,5 milioni, e quindi il tempo di calcolo è gestibile.

Principio generale. Scegliere sempre la tecnica e la metodologia con il livello di accuratezza **adeguato** per rispondere alla propria domanda biologica in tempi e modi compatibili con la propria sopravvivenza professionale. **Non esiste un protocollo universale:** la scelta del metodo è responsabilità del ricercatore.

1.4 Una potenzialità della bioinformatica: studiare l'inaccessibile

La bioinformatica strutturale permette di eseguire **esperimenti che non sono fisicamente realizzabili in laboratorio**. Il prof. Eberini introduce qui un caso concreto, anticipato come esempio e che sarà poi ripreso nella Lezione 5: lo studio della **transizione di Tanford** nella β -lattoglobulina bovina.

1.4.1 La transizione di Tanford

Negli anni Sessanta del Novecento, Charles Tanford osservò che la β -lattoglobulina bovina cambia struttura tridimensionale in funzione del pH della soluzione. Lavorando con curve di titolazione degli amminoacidi titolabili (i carichi: acido aspartico, acido glutamico per gli acidi; arginina, lisina, istidina per i basici), Tanford individuò un **amminoacido acido con pKa anomala di circa 7,3**.

Per un acido aspartico o glutamico ci si aspetta una pKa nell'intervallo 3–4 (manualistico) o leggermente più alto in alcuni contesti strutturali. Una pKa di 7,3 per un residuo acido è notevolmente anomala. Si incomincia a sospettare che proprio questo amminoacido sia il **motore molecolare** della transizione conformazionale pH-dipendente.

1.4.2 L'esperimento impossibile in vetro

Il problema sperimentale: per dimostrare che un singolo amminoacido è responsabile del cambiamento conformazionale, dovremmo poter modificare **localmente** il pH intorno a quell'unico residuo, lasciando inalterato il pH del resto della soluzione. In laboratorio è impossibile: qualunque modifica di pH si ripercuote sull'intera soluzione, alterando lo stato di protonazione di tutti i residui titolabili.

Al computer, invece, si può fare. Si prende la struttura della proteina cristallizzata a pH acido (per esempio 6,2), si identifica l'acido glutamico sospetto, si **strappa il protone** di quel singolo residuo (simulando l'effetto di un pH locale più alto) e si lancia una simulazione di dinamica molecolare per osservare il comportamento della proteina.

Il risultato del lavoro pubblicato dal gruppo (2004): la proteina parte con il **loop EF** (così denominato perché connette i foglietti β E ed F) chiuso sopra il sito di legame; dopo la deprotonazione locale, il loop si apre completamente. È la dimostrazione causale che quella deprotonazione è il motore della transizione conformazionale.

Nota — Questo caso di studio sarà ripreso in dettaglio nella Lezione 5, dove vedremo come ottenere risultati analoghi con metodi più approssimati ma molto più rapidi.

1.5 Responsabilità e libertà metodologica

Un punto programmatico del corso: **non vengono forniti protocolli**. Lo studente — futuro biotecnologo, ricercatore, dipendente di industria farmaceutica — avrà piena libertà di scegliere gli strumenti e i metodi, ma avrà parimenti piena responsabilità delle conseguenze di tali scelte.

1.5.1 Un caso di modello imperfetto: LCAT

Il prof. Eberini illustra con un caso reale tratto dalla propria attività di ricerca. Anni fa il suo gruppo lavorava su LCAT, allora poco caratterizzata strutturalmente: si conosceva la **topologia** (numerosi foglietti β centrali, paralleli ed antiparalleli, circondati da quattro α -eliche, con una triade catalitica Ser-His-Asp), ma non esisteva un modello tridimensionale di qualità.

Il problema scientifico: si voleva identificare inibitori del sito attivo dell'enzima. Senza una buona struttura, il **virtual screening** sarebbe stato improponibile. La scelta fatta dal gruppo: costruire comunque il **miglior modello possibile**, dichiarandone esplicitamente i limiti, e usarlo per lo screening, ben sapendo che — per la bassa identità di sequenza con i template disponibili (meno del 20%) — il modello aveva criticità importanti.

Il risultato sperimentale: le molecole identificate dal virtual screening vennero acquistate e testate in laboratorio su LCAT umana, e **risultarono effettivamente in grado di inibire l'attività enzimatica**. Conclusione: per quanto imperfetto il modello, la posizione del sito attivo non era così distante dalla realtà da inficiare il drug discovery.

Lezione metodologica. Un modello imperfetto può essere comunque utile, purché:

- (i) le sue limitazioni siano **esplicitamente dichiarate**;
- (ii) l'obiettivo sia coerente con il livello di accuratezza disponibile;
- (iii) la validazione sperimentale sia integrata nel processo decisionale.

Quel che non si deve fare è presentare un modello con identità di sequenza al template del 20% come «modello accuratissimo»: questo sarebbe una scorrettezza intellettuale.

1.6 Architettura, struttura e folding: distinzioni terminologiche

Architettura. Il **modo di folding** di una proteina, considerato a livello di famiglia o di superfamiglia. Per esempio: «foglio β classico, con foglietti β paralleli ed antiparalleli al centro circondati da quattro α -eliche» è un'architettura, condivisa da lipasi, proteasi e da molte altre proteine. Un'architettura definisce il **tipo di organizzazione spaziale**, non la posizione esatta dei singoli atomi.

Struttura. La **posizione precisa, nello spazio tridimensionale, di ognuno degli atomi** che compongono una specifica proteina. È quindi qualcosa di più particolare dell'architettura.

Più alta è l'identità di sequenza fra due proteine omologhe, più simili saranno non solo la loro architettura ma anche la loro struttura dettagliata. Tuttavia, per omologie meno strette, possiamo aspettarci comunque la conservazione dell'architettura — il modo di folding generale — anche quando la struttura fine differisce.

1.7 Le sequenze come linguaggio: preludio agli allineamenti

L'ultima parte della prima lezione introduce concettualmente il problema degli allineamenti. Confrontare sequenze biologiche è **operativamente analogo** a confrontare parole di un linguaggio. I nucleotidi sono quattro lettere (A, C, G, T — la U dell'RNA non compare nei database, che archiviano il cDNA); gli amminoacidi naturali sono venti. L'alfabeto italiano ha 21 lettere; quello inglese 26. I numeri sono comparabili.

Le tecniche di allineamento di sequenze biologiche, anzi, condividono le basi matematiche con tecniche sviluppate per scopi affatto diversi: la **crittoanalisi militare** dei codici cifrati (svilupata durante le guerre mondiali, da cui deriverà la **programmazione dinamica**) e l'**analisi linguistica** comparata (che studia come una stessa parola evolva fra lingue diverse e come misurarne la distanza).

1.7.1 Il primo esempio didattico: i due nomi

Il prof. Eberini propone come primo esempio non due sequenze proteiche ma due forme del nome di **Dorothy Crowfoot Hodgkin**, premio Nobel per la chimica 1964 (per la determinazione strutturale ai raggi X di biomolecole, fra cui la vitamina B₁₂): la forma con due cognomi (*Dorothy Crowfoot Hodgkin*) e quella con un solo cognome (*Dorothy Hodgkin*). Le due «sequenze» di lettere sono di lunghezza diversa, ma sono evidentemente correlate: condividono Dorothy all'inizio ed Hodgkin alla fine, con un inserto (*Crowfoot*) presente solo nella prima.

Il problema dell'allineamento si pone esattamente in questi termini: esistono diversi allineamenti possibili, e dobbiamo scegliere il migliore. Per scegliere, occorrerà un **sistema di punteggio**.

1.7.2 Il problema dei gap (indel)

Quando in un allineamento compare un trattino — indicato come **gap** o **indel** — significa che in una posizione una sequenza non ha alcuna lettera corrispondente. La parola *indel* è la contrazione di **insertion** / **deletion**: filogeneticamente non sappiamo se sia stata un'inserzione in una sequenza o una delezione nell'altra, perché non sappiamo quale delle due sia evolutivamente più antica. Operativamente, ci basta sapere che *quella posizione differisce*, e la chiamiamo indel.

Esistono in linea di principio molti allineamenti ammissibili. Per esempio, date le sequenze nucleotidiche GCTGAACG e CTATAAC, possiamo proporre vari allineamenti che inseriscono gap in posizioni diverse. Senza un sistema di punteggio, tutti sono ammissibili e nessuno è il «giusto». Per scegliere serve sviluppare metodi quantitativi: la matrice **dot plot**, le matrici di sostituzione (PAM e BLOSUM), gli algoritmi di programmazione dinamica.

Nota — Questi metodi saranno trattati nelle Lezioni 2 e 3. L'idea cardine è che il sistema di punteggio non sempre risolve completamente l'ambiguità — alle volte rimangono N allineamenti con identico punteggio massimale, e basta una piccola modifica al sistema di punteggio per cambiare quale sia il migliore — ma ci permette comunque di scartare allineamenti palesemente sbagliati e di trovare un allineamento ragionevole. Per allineamenti facili (alta identità di sequenza) il problema è risolvibile univocamente; per allineamenti difficili, mai con certezza assoluta.

Lezione 2

Dal punteggio binario alla statistica: introduzione operativa agli allineamenti

Marzo 2026 — Seconda lezione

2.1 Nota editoriale sulla Lezione 2

La trascrizione della seconda lezione presenta una larga sovrapposizione concettuale con la prima: il prof. Eberini riprende i temi dell'omologia, dell'accuratezza, dell'identità e similarità di sequenza, anche per venire incontro a studenti che non avevano partecipato alla prima lezione. Per evitare ridondanze, in questo manuale i contenuti già esposti nella Lezione 1 non vengono ripetuti; ci concentriamo sui temi **nuovi o approfonditi** rispetto alla lezione introduttiva.

2.2 Approfondimento sulla transizione di Tanford

La seconda lezione approfondisce alcuni dettagli quantitativi sulla transizione di Tanford anticipata nella Lezione 1.

Il caso documentato in letteratura: la β -lattoglobulina bovina, in ambiente **acido** ($\text{pH} \approx 6,2$), presenta una conformazione con il loop EF chiuso sul sito di legame, mentre in ambiente **basico** ($\text{pH} \approx 8,2$) presenta lo stesso loop aperto. Il loop EF è chiamato così perché connette i foglietti β **E** ed **F** nella struttura ad ipocalina della proteina.

Tanford, dalla curva di titolazione, identificò una pK_a anomala di circa 7,3 (rispetto ai valori manualistici di 3,5–4,5 per aspartato e glutamato): l'amminoacido così caratterizzato è il candidato come **motore** della transizione conformazionale.

Negli anni del lavoro pubblicato dal gruppo Eberini (2004), il calcolo del pK_a locale richiedeva metodi di elettrostatica computazionale molto onerosi (basati su risolutori dell'equazione di Poisson–Boltzmann). Oggi metodi semplificati ed empirici come **PropKa** (si pronuncia *prop-ka*) consentono di stimare la pK_a di tutti i residui titolabili in pochi secondi con un'equazione lineare. La Lezione 5 mostrerà la procedura nel dettaglio.

2.3 Il problema dell'allineamento: formalizzazione

Definito il quadro concettuale, la seconda lezione formalizza i passi che vedremo nelle lezioni successive.

2.3.1 Schema generale del processo

Il flusso logico-operativo della bioinformatica strutturale che il prof. Eberini esporrà nei dettagli nelle prossime lezioni può essere riassunto in:

Passo	Operazione	Strumento tipico
1	Acquisizione della struttura primaria (query)	UniProt, sequenziamento
2	Ricerca di proteine omologhe note	BLAST, PSI-BLAST, HMM
3	Selezione del template omologo di struttura nota	PDB + valutazione manuale
4	Allineamento globale esatto query–template	Programmazione dinamica + matrice di sostituzione

Passo	Operazione	Strumento tipico
5	Costruzione del modello tridimensionale	Homology modeling (MOE, Modeller, SwissModel)
6	Validazione e selezione del miglior modello	Energia di solvatazione, Ramachandran plot, RMSD
7	Studio funzionale del modello	Docking, MD, mutagenesi in silico

2.3.2 Anticipazione del problema del punteggio

Il sistema di punteggio più rudimentale è quello **binario**: 1 se le due lettere coincidono (*match*), 0 se differiscono (*mismatch*). Questo è il sistema utilizzato nella matrice **dot plot**, che vedremo in dettaglio nella Lezione 3.

Le limitazioni del punteggio binario sono evidenti: dal punto di vista biochimico, sostituire un acido aspartico con un acido glutamico (due residui acidi con catene laterali corte, comportamento chimico-fisico analogo) **non è equivalente** a sostituire un acido aspartico con un triptofano (un'enorme catena laterale aromatica idrofobica). Il punteggio binario assegna 0 ad entrambi i casi, trattandoli equivalentemente — e questo è scorretto.

Si pone dunque il problema di sviluppare **matrici di sostituzione** che attribuiscono a ogni coppia di amminoacidi un punteggio differenziato, tenendo conto della frequenza con cui quella sostituzione è osservata in natura nelle proteine omologhe allineate. È questo il lavoro fondativo di Margaret Dayhoff e delle matrici PAM, che saranno trattate nella Lezione 3.

2.4 Sintesi dei tre punti chiave

Il prof. Eberini conclude la seconda lezione enumerando esplicitamente tre punti che lo studente deve ricordare e portare all'esame:

Punto	Concetto
1.	Il core dell'interesse è l' omologia . Non venire all'esame dicendo di essere interessati a similarità ed identità in sé: ci interessano in quanto indicatori surrogati dell'omologia, che a sua volta ci interessa perché proteine omologhe condividono struttura, funzione e architettura.
2.	Accuratezza adeguata al problema, non massima per principio. La tecnica più costosa, più nuova o tecnologicamente avanzata non è necessariamente la più adatta alla domanda scientifica concreta.
3.	Responsabilità : non esistono protocolli universali in bioinformatica strutturale. Lo studente sarà libero di scegliere metodi e strumenti, ma sarà altresì responsabile delle conseguenze delle proprie scelte e dovrà saperle giustificare davanti ad un revisore.

Nota — Tutti e tre i punti sono potenziali domande d'esame e sono ripresi nella sezione finale del manuale.

Lezione 3

Allineamenti di sequenza, dot plot, matrici di sostituzione PAM

Marzo 2026 — Terza lezione (in due parti: 3.1 e 3.2)

3.1 Perché si fanno gli allineamenti di sequenza

Abbiamo già stabilito che gli allineamenti servono primariamente a valutare l'**omologia**. Tuttavia, questa non è l'unica ragione. Gli allineamenti, fatti correttamente, sono utili a:

- **Misurare la similarità di sequenza** (e quindi identità) come indicatori surrogati di omologia.
- **Determinare la corrispondenza fra i residui** delle diverse sequenze: in un buon allineamento, gli amminoacidi corrispondenti (omologhi) di tutte le proteine sono incolonnati correttamente.
- **Identificare pattern conservati**: amminoacidi che si conservano in tutta una famiglia di proteine sono presumibilmente critici per la struttura o la funzione, e nell'evoluzione non hanno potuto cambiare.
- **Riconoscere firme di famiglia** (*signature, fingerprint*): alcune famiglie proteiche possiedono pattern caratteristici di pochi amminoacidi conservati che fungono da etichetta molecolare identificativa.
- **Costruire la filogenesi molecolare**: studiare come le sequenze siano cambiate nel tempo evolutivo per ricostruire alberi di speciazione (interesse principalmente biologico, accessorio nel presente corso).

3.1.1 Allineamenti a coppie e allineamenti multipli

Si distinguono:

Allineamento a coppie (*pairwise alignment*). Allineamento di due sole sequenze. Esistono per esso strategie matematiche ottimali — la **programmazione dinamica** (Needleman–Wunsch per allineamento globale; Smith–Waterman per allineamento locale) — che trovano la soluzione di punteggio massimo senza provare tutti gli allineamenti possibili.

Allineamento multiplo (*multiple sequence alignment, MSA*). Allineamento di tre o più sequenze. Algoritmicamente più complesso, richiede strategie progressive (Clustal, MUSCLE, T-Coffee) o iterative. L'output è una matrice di amminoacidi in cui le righe sono le sequenze e le colonne le posizioni allineate.

In linea generale, più sequenze sono allineate insieme, più robusto diventa l'allineamento per le sezioni conservate (perché evidenze evolutive coincidenti si rafforzano a vicenda) e più ricca diventa l'inferenza di proprietà biologiche.

3.2 La matrice dot plot

Il primo metodo di confronto sequenza–sequenza è la **matrice dot plot**, un metodo grafico assolutamente elementare ma sorprendentemente informativo.

3.2.1 Costruzione della dot plot

Si scrivono le due sequenze da confrontare lungo i due assi di una matrice (l'una in orizzontale, l'altra in verticale). Per ogni cella (i, j) della matrice si applica un **punteggio binario**: se l'amminoacido i della prima sequenza coincide con l'amminoacido j della seconda (*match*), si segna un punto nero (o si scrive la lettera); altrimenti si lascia bianco. Tradizionalmente la matrice si sviluppa dall'angolo in alto a sinistra all'angolo in basso a destra.

Il caso didattico proposto dal prof. Eberini è il confronto fra *Dorothy Hodgkin* e *Dorothy Crowfoot Hodgkin*.

3.2.2 Cosa rivela una dot plot

Una matrice dot plot rivela quattro tipi di informazioni:

Pattern grafico	Significato biologico
Diagonale principale (alto-sinistra → basso-destra)	Regioni in cui le due sequenze sono allineate residuo-a-residuo. È il segnale forte di identità di sequenza.
Spostamenti orizzontali/verticali della diagonale principale	Indel: presenza di inserzioni/delezioni; uno spostamento in orizzontale di N posizioni indica un gap di N residui in una sequenza rispetto all'altra.
Diagonali secondarie parallele alla principale	Sequenze ripetute (<i>short repeat sequences</i>) all'interno delle proteine. Per esempio: nel confronto della parola <i>abracadabracadabra</i> con se stessa compaiono diagonali parallele dovute alla ripetizione interna di <i>abra</i> e <i>abracadabra</i> .
Diagonali secondarie perpendicolari alla principale	Sequenze palindrome. Biologicamente rilevanti: ad esempio i siti di legame dei fattori di trascrizione al DNA sono spesso palindromi, e gli enzimi di restrizione (es. <i>EcoRI</i>) tagliano in corrispondenza di sequenze palindrome.

*Nota — Una causa di confusione frequente: la diagonale secondaria perpendicolare si presenta come una singola linea, non come una stella o un asterisco. Risposte come «vedo una stella» o «vedo un asterisco» quando si confronta una sequenza palindroma con se stessa sono sbagliate: si vedono **due diagonali** incrociate, una principale ed una secondaria perpendicolare.*

3.2.3 Il rumore di fondo e la finestra flottante

Una matrice dot plot mostra sempre un certo numero di celle nere **non significative**, dovute al fatto che il numero di lettere dell'alfabeto è finito: occasionalmente due lettere identiche compaiono in posizioni non correlate. Questo è il **rumore di fondo**. Con un alfabeto di 20 amminoacidi il problema è gestibile; con i quattro nucleotidi A, C, G, T diventa molto serio, perché statisticamente in ogni cella la probabilità di un *match* casuale è del 25%.

Finestra flottante (*floating window*). Strategia di filtraggio per ridurre il rumore di fondo. Aniché valutare ogni cella singolarmente, si considera un intorno di N celle attorno alla diagonale e si dichiara *match* solo se almeno K dei residui contigui nell'intorno coincidono. Tipicamente N è dispari (es. 3, 5, 7); il parametro K si chiama **ktup** (o *cutoff*) e fissa la soglia di tolleranza.

Esempio: con finestra di 3 e ktup di 2, una cella (i, j) è dichiarata *match* se, nei tre residui (i-1, j-1), (i, j), (i+1, j+1), almeno 2 coincidono. Aumentando la dimensione della finestra si riduce il rumore di fondo, ma **si rischia di perdere informazione**: la diagonale principale può apparire più frammentata. Bisogna trovare il giusto bilanciamento. Per il confronto di geni (alfabeto di 4 lettere) si usano finestre tipicamente di 15.

3.2.4 Ricostruzione dell'allineamento dalla dot plot

Una volta costruita la dot plot, per scrivere l'allineamento corrispondente **non** si percorre la diagonale dall'alto in basso (come la si è sviluppata), ma **al contrario, dal basso in alto**, ricostruendo a ritroso il percorso che ha generato il punteggio totale più elevato. Questo procedimento si chiama **traceback**.

La ragione tecnica è che, quando si lavora con matrici di punteggio non-binarie (ossia matrici di sostituzione vere come PAM o BLOSUM), ogni cella accumula il punteggio massimo ottenibile fino a quel punto. Il traceback dal valore più alto (in basso a destra) procede risalendo le celle con i punteggi crescenti, ricostruendo l'allineamento ottimale.

Nota — Lo sviluppo manuale di una matrice di allineamento con programmazione dinamica è materia di un corso di bioinformatica algoritmica e non viene trattato in dettaglio in questo corso. Quel che lo studente deve aver chiaro è il principio: il traceback ricostruisce a ritroso il percorso di massimo punteggio.

3.3 Distanze fra stringhe: Hamming e Levenshtein

Concettualmente correlata agli allineamenti, ma diversa, è la misura delle **distanze** fra stringhe, che quantifica quanto due sequenze siano dissimili. Le due distanze più usate sono:

Distanza	Ambito operativo	Definizione
Hamming	Stringhe di uguale lunghezza	Numero di posizioni in cui le due stringhe differiscono. Es. distanza Hamming fra AGTC e CGAC = 2.
Levenshtein (edit distance)	Stringhe di lunghezza qualunque	Numero minimo di operazioni di editing (inserzione, delezione, sostituzione di un carattere) necessarie per trasformare una stringa nell'altra.

Nota — È un errore frequente confondere ambito operativo e definizione. La distanza di Hamming è definita come «numero di posizioni differenti» e si applica solo a stringhe di uguale lunghezza; la distanza di Levenshtein è definita come «numero minimo di edit» e si applica anche a stringhe di lunghezza diversa. Confonderle è una tipica caduta da evitare all'esame.

3.4 Punteggi di allineamento: dai nucleotidi agli amminoacidi

Il sistema di punteggio binario è troppo grezzo. Per i nucleotidi esiste una considerazione biochimica che permette di sviluppare un sistema un poco più ricco: la distinzione fra **transizione** e **transversione**.

3.4.1 Transizione e transversione

Transizione. Sostituzione di una purina con un'altra purina ($A \leftrightarrow G$) o di una pirimidina con un'altra pirimidina ($C \leftrightarrow T$).

Transversione. Sostituzione di una purina con una pirimidina o viceversa ($A \leftrightarrow C$, $A \leftrightarrow T$, $G \leftrightarrow C$, $G \leftrightarrow T$).

Biologicamente, le transversioni sono **meno favorite** rispetto alle transizioni. La ragione strutturale è che il DNA ha legami a idrogeno complementari ottimali tra purina e pirimidina; sostituire una purina con una pirimidina (o viceversa) altera la geometria dell'appaiamento e dei legami a idrogeno con la base complementare, destabilizzando il duplex.

Un sistema di punteggio sensato per i nucleotidi può quindi essere il seguente (un esempio):

Evento	Punteggio
Conservazione (es. $A \rightarrow A$, $T \rightarrow T$)	+20

Evento	Punteggio
Transizione ($A \leftrightarrow G$, $C \leftrightarrow T$)	+10
Transversione ($A \leftrightarrow C$, $A \leftrightarrow T$, $G \leftrightarrow C$, $G \leftrightarrow T$)	+5

Questo sistema, costruito su basi biochimiche, è qualitativamente ragionevole. Per gli **amminoacidi**, dove le possibilità sono $20 \times 20 = 400$ combinazioni di coppia, occorre un approccio diverso: le **matrici di sostituzione**.

3.5 Le matrici di sostituzione PAM

Lo sviluppo storico delle matrici di sostituzione per amminoacidi si deve a **Margaret Dayhoff**, considerata la madre della bioinformatica, nel 1978. Le matrici da lei sviluppate si chiamano **PAM** — acronimo di *Percent Accepted Mutation*.

3.5.1 L'approccio osservazionale di Dayhoff

La logica di Dayhoff è la seguente: gli amminoacidi che cambiano più frequentemente in proteine omologhe sono evidentemente quelli **tolerati** dall'evoluzione, dunque accettati senza conseguenze letali per la proteina. Le mutazioni tollerate sono quelle **conservative**, ossia che conservano struttura, architettura e funzione della proteina.

Operativamente: Dayhoff prese un numero modesto di famiglie di proteine omologhe ad altissima identità di sequenza (perché negli anni Settanta non c'erano database sufficientemente ricchi né algoritmi di allineamento robusti per proteine molto divergenti), le allineò manualmente e per ogni coppia di amminoacidi (i, j) contò la frequenza con cui i diventava j (e viceversa) nelle posizioni allineate.

Da questi conteggi costruì la **matrice PAM1**: 1 sta per **1% di mutazione accettata**, ossia 99 amminoacidi su 100 sono uguali, 1 su 100 è cambiato. La PAM1 è dunque la matrice di base, costruita per **osservazione diretta**.

3.5.2 Le altre matrici PAM

Per stimare la frequenza delle sostituzioni a tempi evolutivi più lunghi — per proteine più divergenti — Dayhoff **non** osservò proteine più diverse (che non erano in quantità sufficiente né allineabili in modo affidabile), ma procedette **matematicamente**: moltiplicò la matrice PAM1 per se stessa più volte, ottenendo PAM30, PAM80, PAM110, PAM200, PAM250 (il numero indica il tempo evolutivo, ossia il numero di mutazioni accettate ogni 100 residui).

Il numero della matrice **non corrisponde linearmente** alla percentuale di residui diversi: la curva è non-lineare. PAM30 corrisponde a circa il 75% di identità, PAM80 al 50%, PAM250 al 23%. Tale non-linearità è la conseguenza delle approssimazioni introdotte nella PAM1, propagate dalla moltiplicazione matriciale.

3.5.3 Le quattro approssimazioni di Dayhoff

Le matrici PAM (ad eccezione della PAM1, ottenuta osservazionalmente) **contengono errori**, conseguenze delle approssimazioni necessariamente fatte da Dayhoff. È fondamentale conoscerle, poiché — sottolinea il prof. Eberini — sono **tipica domanda d'esame**.

#	Approssimazione	Conseguenza
1	Probabilità ($i \rightarrow j$) = Probabilità ($j \rightarrow i$)	Non si conosce la direzione evolutiva: si assume simmetria. In natura non è vero (es. $P(\text{Met} \rightarrow \text{Cys}) \neq P(\text{Cys} \rightarrow \text{Met})$).

#	Approssimazione	Conseguenza
2	Non si considerano le retromutazioni ($i \rightarrow j \rightarrow i$)	Si sottostima il numero di mutazioni accettate; si sovrastima la conservazione delle posizioni invariate.
3	Processo Markoviano : lo stato all'istante t dipende solo dallo stato $t-1$, non da tutta la storia evolutiva	Non si tiene conto della successione storica dei cambiamenti in una posizione.
4	Probabilità di mutazione uguale in ogni posizione della proteina	Falso: una mutazione nel sito attivo è molto meno tollerata che una mutazione in superficie su un loop. Il fattore di tolleranza posizionale viene trascurato.

Nota — Domanda tipica d'esame: «Mi parli delle matrici di sostituzione, mi dica quali sono le approssimazioni che ha fatto Dayhoff e quale ne è l'impatto sull'uso di queste matrici.»

3.5.4 Eredità e successori di PAM

Le matrici PAM sono ancora oggi presenti nei sistemi di allineamento, ma non sono più le più usate. Le matrici successive — in particolare le **BLOSUM** di Henikoff & Henikoff (1992) — sono **tutte osservazionali**: ogni matrice della famiglia BLOSUM (BLOSUM45, BLOSUM62, BLOSUM80...) è costruita allineando proteine con identità di sequenza al di sopra di una certa soglia (es. BLOSUM62 = proteine con identità $\geq 62\%$) e contando direttamente le sostituzioni osservate.

Le BLOSUM mitigano sostanzialmente le approssimazioni di Dayhoff perché ogni matrice è costruita per il suo proprio range evolutivo, senza estrapolazione matematica. **BLOSUM62** è la matrice standard utilizzata da BLAST e dai principali algoritmi di allineamento.

Sintesi storica. Margaret Dayhoff (1978) — pioniera, matrici PAM, basate sulla PAM1 osservazionale ed estrapolate matematicamente.
 Henikoff & Henikoff (1992) — matrici BLOSUM, tutte osservazionali, ciascuna costruita per uno specifico range di identità. BLOSUM62 è lo standard de facto.

Lezione 4

Statistica degli allineamenti, profili, PSI-BLAST e modelli di Markov nascosti

Marzo 2026 — Quarta lezione

4.1 Statistica degli allineamenti: dal punteggio alla probabilità

La sequenza logica del corso prosegue: a noi interessa l'omologia, che misuriamo surrogata-mente con identità e similarità tramite allineamenti. L'allineamento ci fornisce un **punteggio**, ma il punteggio in sé non ci dice se la nostra coppia di proteine sia filogeneticamente correlata. Per affermarlo serve un'**inferenza statistica**.

4.1.1 La distribuzione di Gumbel

Se si calcolano i punteggi di tutti gli allineamenti locali fra una proteina di interesse (*query*) e tutte le proteine di un grande database, la distribuzione dei punteggi non è gaussiana ma **asimmetrica**, con una lunga coda verso destra (cioè verso punteggi alti). Tale distribuzione è la **distribuzione di Gumbel** (o distribuzione dei valori estremi).

La forma della distribuzione dipende da due fattori:

- la **matrice di sostituzione** utilizzata (BLOSUM62, BLOSUM80, PAM, etc.);
- la **composizione amminoacidica** del database utilizzato.

Conseguenza pratica: il **punteggio assoluto** di un allineamento **non è direttamente confrontabile** fra allineamenti fatti con matrici o database diversi. Per fare confronti significativi occorre **normalizzare** il punteggio.

4.1.2 Lo Z-score

Z-score. $z = (S - \mu) / \sigma$, dove S è il punteggio di allineamento, μ è la media e σ è la deviazione standard della distribuzione di Gumbel su un database di sequenze random o non correlate.

Lo Z-score esprime quanto il nostro punteggio sia distante dalla media della distribuzione, in unità di deviazione standard. Essendo indipendente dalla forma della distribuzione, consente di confrontare allineamenti ottenuti con matrici e database diversi.

Soglia operativa: si considera significativo un allineamento con **Z-score** ≥ 5 (5 deviazioni standard sopra la media). Sotto questa soglia l'allineamento è statisticamente compatibile con il rumore di fondo.

4.1.3 Il P-value e l'E-value

L'inferenza statistica formale degli allineamenti procede attraverso un **test d'ipotesi nulla**:

Ipotesi nulla H_0 . L'allineamento osservato è un'estrazione casuale dalla distribuzione di Gumbel del database — cioè non c'è omologia reale, il punteggio è dovuto al caso.

Si calcola la probabilità di osservare per caso un punteggio uguale o superiore a quello osservato (area sotto la coda destra della distribuzione di Gumbel oltre il valore S):

P-value. $P(X \geq S | H_0)$ = probabilità di ottenere casualmente un allineamento con punteggio uguale o migliore di quello osservato. Più P è piccolo, più l'allineamento è statisticamente significativo.

Tuttavia il P-value **dipende dalla dimensione del database**: in un database grande è più probabile, per caso, trovare allineamenti ad alto punteggio. Si introduce quindi l'E-value:

E-value. $E = P \times D$, dove D è la dimensione (numero di sequenze) del database. Rappresenta il numero **atteso** di allineamenti casuali con punteggio uguale o superiore al nostro. Più E è piccolo, più l'allineamento è significativo.

4.1.4 Interpretazione operativa dei valori

Il prof. Eberini fornisce una tabella di interpretazione che lo studente deve avere ben chiara:

Range P-value	Interpretazione biologica
$P \leq 10^{-100}$	Sequenze pressoché identiche (stessa proteina o stessa proteina con polimorfismi minimi).
$10^{-100} < P \leq 10^{-50}$	Sequenze con variazioni molto piccole (alleli, SNP, varianti minori).
$10^{-50} < P \leq 10^{-10}$	Proteine certamente omologhe con altissima probabilità.
$10^{-5} < P \leq 10^{-1}$	Distant homologs : omologia esistente ma lontana filogeneticamente; gli allineamenti saranno difficili.
$P > 0,1$	Significatività insufficiente: omologia non supportata statisticamente.

Soglia operativa per E-value: $E \leq 0,02$ indica buona probabilità di omologia; $0,02 < E \leq 1$ zona ambigua; $E > 1$ verosimilmente non omologhi.

Nota — Una domanda tipica d'esame: «Se il cutoff di E per affermare omologia è 0,02, e nel mio database trovo un allineamento con $E = 0,02$, quante proteine in quel database posso aspettarmi che diano per caso un allineamento di punteggio uguale o migliore?» Risposta: meno di una (perché $E < 1$). Domanda di completamento: «di quante volte deve crescere il database perché me ne aspetti almeno una?» Risposta: 50 volte (perché $50 \times 0,02 = 1$).

4.2 Identità di sequenza e tipologie di inferenza strutturale

L'identità di sequenza fra proteine fornisce una guida operativa per valutare quali inferenze strutturali siano lecite:

Identità	Inferenza lecita
> 45%	Architettura, struttura specifica e funzione molto probabilmente conservate.
25–45%	Architettura conservata (stesso modo di folding); struttura specifica e funzione non sicure.
12–25%	Twilight zone (zona crepuscolare): non si distingue con certezza fra omologia distante e similarità casuale.
< 12%	Midnight zone : similarità per caso più probabile dell'omologia.

4.2.1 Perché la twilight zone esiste

Se si prendono due proteine completamente non correlate dal database e le si confronta, si trova quasi sempre **almeno il 20% di identità di sequenza per puro caso**: cioè circa 2 amminoacidi identici ogni 10. Questo è dovuto al fatto che gli amminoacidi naturali sono solo 20, quindi la probabilità di match casuale per posizione è del 5%, ma considerando tutti gli allineamenti possibili e le sostituzioni conservative, ci si attesta intorno al 20%.

Conseguenza: **sotto il 20% di identità non si può distinguere** con sicurezza se i match osservati siano dovuti a una lontana relazione filogenetica o a coincidenza statistica. È in questa zona che lavorare diventa critico: occorre supportare le evidenze di similarità con altri dati (struttura secondaria, predizioni indipendenti, dati sperimentali, cisteine conservate, motivi).

4.3 Allineamenti multipli e logo di sequenza

Il manuale di Arthur Lesk — testo di riferimento per il corso — sottolinea che un biologo molecolare trae da un allineamento multiplo ricchezza di informazioni molto superiore a quella di un allineamento a coppie.

4.3.1 L'esempio delle tioredossine

Il caso didattico è il seguente: il manuale propone un allineamento multiplo di **16 tioredossine** da diverse specie. La tioredossina è una proteina ubiquitaria coinvolta nelle reazioni di ossidoriduzione dei ponti disolfuro, con un ventaglio amplissimo di attività biologiche (proliferazione cellulare, coagulazione, germinazione dei semi vegetali, regolazione dell'insulina, regolazione enzimatica).

Supponiamo di conoscere sperimentalmente la struttura secondaria di una sola tioredossina dell'allineamento (per esempio quella di *Escherichia coli*) — sappiamo quali residui formano α -elica, quali foglietto β , quali sono in random coil. **Possiamo trasferire** queste informazioni di struttura secondaria a tutti gli altri membri della famiglia allineati: dove un residuo è in α -elica nella tioredossina di *E. coli*, ci aspettiamo α -elica anche nei residui omologhi delle altre 15 proteine.

Questa è una forma potente di **predizione per omologia**: con un solo esperimento strutturale, attraverso il MSA, caratterizziamo un'intera famiglia.

4.3.2 Pattern conservati e firme di famiglia

Esaminando il MSA delle tioredossine si individuano singoli amminoacidi **completamente conservati** in tutte le 16 sequenze: per esempio una D, una F, una A in posizioni specifiche. Sono presumibilmente **residui critici** per la funzione. Inoltre si individua un blocco conservato — **W-C-G-P-C-K-R** — che è la **firma (signature) della famiglia delle tioredossine**: tutte le tioredossine note hanno questo motivo.

Logo di sequenza (sequence logo). Rappresentazione grafica di un MSA in cui, per ogni posizione, si elencano gli amminoacidi presenti, con altezza della lettera proporzionale alla frequenza. Una posizione conservata appare come una grande lettera singola; una posizione variabile come una pila bassa di lettere multiple.

Nota — Implicazione pratica: se in laboratorio si sequenzia una nuova proteina e si trova al suo interno il motivo W-C-G-P-C-K-R, si può concludere con altissima probabilità che si tratta di una tioredossina, e da lì importare per omologia funzione, architettura e struttura secondaria.

4.3.3 Pattern di idrofobicità e struttura secondaria

Un'inferenza meno sicura ma utile: dall'**analisi del pattern di idrofobicità** lungo la sequenza si può tentare di prevedere la struttura secondaria:

- **Foglietto β** : pattern alternato di amminoacidi idrofobici con **spaziatura di 2** (idrofobico ogni 2 residui). I residui idrofobici si trovano da uno stesso lato del foglietto.
- **α -elica**: pattern alternato di amminoacidi idrofobici con **spaziatura di 4** (idrofobico ogni 3-4 residui, perché l'elica fa un giro completo ogni 3,6 residui).

Nota — La distanza giusta nasce dalla geometria: nel foglietto β i legami a idrogeno fra catene adiacenti coinvolgono gli amminoacidi i e $i+2$; nell' α -elica i legami a idrogeno intracatena collegano i e $i+4$.

4.4 Metodi ad alta sensibilità per la ricerca di omologhi distanti

Quando BLAST non trova alcuna proteina omologa al di sopra della soglia di significatività, si possono usare metodi più sensibili. I tre più rilevanti sono:

Metodo	Caratteristica essenziale
Profili da allineamenti multipli	Anziché allineare una singola sequenza al database, si usa come query un profilo derivato da un MSA. In ogni posizione del profilo si conosce la frequenza dei 20 amminoacidi: l'allineamento ne tiene conto.
PSI-BLAST (<i>Position-Specific Iterative BLAST</i>)	Versione iterativa di BLAST. Si lancia BLAST con la query, si raccolgono gli allineamenti con $E \leq 0,05$, si allineano fra loro generando un profilo; il profilo è la nuova query per il ciclo successivo. Si itera finché non si trovano nuovi allineamenti significativi.
Modelli di Markov nascosti (HMM, <i>Hidden Markov Models</i>)	Strutture computazionali statistico-probabilistiche che imparano il pattern caratteristico di una famiglia di proteine e poi possono valutare la probabilità che una nuova sequenza appartenga a quella famiglia.

Compromesso: aumentando la sensibilità si recuperano omologhi distanti, ma essi avranno bassa identità di sequenza con la query, rendendo difficili gli allineamenti successivi e i modelli costruiti su tali allineamenti.

4.5 Modelli di Markov nascosti (HMM)

Modello di Markov nascosto. Struttura computazionale basata su probabilità e statistica (non su intelligenza artificiale). Capace di analizzare sequenze di segnali, riconoscerne pattern sottili e ripetibili, impararli e ripeterli.

Un HMM applicato alle proteine impara l'**essenza** di una famiglia (l'*albuminità*, le *tiredossinità*... il prof. Eberini usa il neologismo provocatorio): impara il pattern profondo che caratterizza tutte le proteine di quella famiglia e poi può:

- (i) **generare** nuove sequenze che condividono quel pattern (funzione generativa, poco usata in pratica);
- (ii) **calcolare la probabilità** che una nuova sequenza data appartenga a quella famiglia (funzione classificativa, principale uso bioinformatico);
- (iii) **generare allineamenti accurati** della nuova sequenza con la famiglia.

4.5.1 Architettura di un HMM proteico

Un HMM per famiglie proteiche è composto da due strati (*layers*):

Strato nascosto (*hidden layer*). Sequenza di stati interni — START, MATCH (M), INSERT (I), DELETE (D), END — collegati da frecce con probabilità di transizione fra 0 e 1. Le catene di Markov sono **senza memoria**: la probabilità di essere in uno stato dipende solo dallo stato precedente, non da tutto il percorso.

Strato di emissione (*emission layer*, simbolico). Per ogni stato MATCH, una tabella con la **probabilità di emissione** di ciascuno dei 20 amminoacidi naturali in quella posizione. Per gli stati INSERT/DELETE si emette un gap.

Quando si percorre l'HMM da START a END, ogni stato MATCH genera un amminoacido secondo la propria tabella di emissione; gli stati INSERT/DELETE inseriscono gap. Il prodotto delle probabilità lungo il percorso fornisce la **verosimiglianza** della sequenza generata.

4.5.2 Esempio: HMM delle albumine

Supponiamo di aver addestrato (*training*) un HMM su tutte le albumine note. L'HMM ha imparato che il primo amminoacido di una pre-albumina eucariotica (con peptide segnale) è quasi sempre la **metionina**: dunque la sua tabella di emissione per il primo match avrà $M \approx 99\%$, e gli altri 19 amminoacidi a probabilità trascurabile.

*Nota — Attenzione: nell'albumina **matura**, dopo il taglio del peptide segnale durante la secrezione, il primo amminoacido **non** è più metionina. Bisogna sapere se si sta lavorando con la pre-pro forma o con la forma matura.*

4.5.3 I due problemi che un HMM risolve

Un HMM addestrato risolve due problemi statistici fondamentali:

Problema	Algoritmo risolutore	Output
Scoring problem: la mia nuova sequenza appartiene alla famiglia?	Algoritmo di Viterbi	Probabilità che il modello generi la sequenza.
Alignment problem: qual è l'allineamento ottimale della mia sequenza con la famiglia?	Algoritmo forward-backward	Il percorso più probabile da START a END, che identifica match, insert e delete posizione per posizione.
(Non trattato in dettaglio) Training problem: addestrare l'HMM su una famiglia	Baum-Welch (EM)	Tabelle di probabilità ottimizzate.

*Nota — Distinzione cruciale: il modello di Markov nascosto, in bioinformatica, **non confronta proteine**. Esso impara un pattern e produce valutazioni probabilistiche su sequenze nuove. Dire «un HMM confronta proteine» è un errore concettuale.*

4.6 Esempio didattico: HMM infinito a due stati

Un esempio molto semplice per fissare l'idea di transizione fra stati. Sia dato un modello con due soli stati (s_1, s_2), senza START né END (modello infinito):

- **Stato 1:** probabilità di rimanere in $s_1 = 99\%$; di passare a $s_2 = 1\%$. Emette nucleotidi con probabilità A = 40%, T = 40%, C = 10%, G = 10%.
- **Stato 2:** probabilità di rimanere in $s_2 = 90\%$; di tornare a $s_1 = 10\%$. Emette nucleotidi con probabilità G = 50%, C = 40%, A = 5%, T = 5%.

Il modello è **sbilanciato** verso s_1 : il rapporto fra le frequenze di visita degli stati è 10:1 ($1/0,1 = 10$). Cioè si visita s_1 dieci volte più spesso di s_2 . Le sequenze generate saranno prevalentemente ricche di A e T (stato 1), con brevi incursioni in regioni ricche di G e C (stato 2).

*Nota — Questo schema astratto è esattamente la logica con cui si individuano le **isole CpG** nei genomi: la matrice di transizione fra nucleotidi cambia all'interno delle isole CpG rispetto al resto del genoma, e un HMM è capace di riconoscerle automaticamente.*

4.7 Anteprima: dalla teoria alla pratica

La quarta lezione conclude la prima parte teorica del corso. Dalla lezione successiva si entra nella **pratica operativa**:

- Lezione 5: caso di studio sulla β -lattoglobulina bovina.

- Lezione 6–7: homology modeling di una proteina semplice (β -lattoglobulina di bufalo) e di una proteina complessa (GPR17, recettore di membrana a sette eliche).
- Lezione 8: teoria della dinamica molecolare (presentata dal dott. Davide Bassani, collaboratore del gruppo Eberini).
- Lezioni 9–10: teoria sistematica del modeling, validazione, metodi *ab initio* e *de novo*.
- Lezione 11: ottimizzazione razionale di un anticorpo monoclonale anti-IL-13 (caso CNT-O627), con l'Antibody Modeler di MOE.

Lezione 5

Caso di studio: β -lattoglobulina bovina, transizione di Tanford, riconoscimento del ligando

Marzo 2026 — Quinta lezione — Prima sessione pratica

5.1 Introduzione: la pratica come specchio della teoria

La Lezione 5 inaugura le sessioni pratiche del corso. Il prof. Eberini annuncia un cambio di registro: anziché esporre teoria pura, presenterà *workshow* — non veri *workshop*, perché gli studenti non hanno accesso individuale al software professionale (**MOE**, *Molecular Operating Environment*, della Chemical Computing Group), del quale verranno mostrate le funzionalità dal banco del docente.

Vi mostro come possiamo usare la biochimica computazionale e la bioinformatica per ottenere informazioni su proteine: comportamento strutturale, capacità di legare ligandi naturali, farmaci, agonisti, antagonisti, inibitori, substrati; e anche per studiare meccanismi molecolari di riconoscimento.

Nota — Per chi voglia replicare le procedure a costo zero, il prof. Eberini indica di poter ottenere risultati analoghi con software open source (VMD, PyMOL, ChimeraX, GROMACS per la dinamica, AutoDock per il docking, Modeller per l'homology modeling, SwissModel via web), accettando una maggiore necessità di lavoro di scripting e di gestione manuale dei dati.

5.2 Anteprima: il caso clinico dell'anticorpo anti-IL-13

Il prof. Eberini accenna brevemente, come anticipazione delle ultime lezioni, ad un caso reale sviluppato in collaborazione con Merck: un anticorpo monoclonale anti-IL-13 che **precipitava in vivo per aggregazione** alla dose terapeutica richiesta. L'ottimizzazione razionale ha agito su due fronti simultanei: (i) migliorare l'affinità per l'antigene mutando amminoacidi nelle regioni ipervariabili (CDR), e (ii) rompere una **patch idrofobica** superficiale responsabile dell'aggregazione sostituendo un amminoacido idrofobico con uno non idrofobico. L'effetto combinato: maggiore affinità → minore dose efficace → minore concentrazione → minore aggregazione. Il caso sarà ripreso in dettaglio nella Lezione 11.

5.3 Considerazioni storiche sul drug design razionale

Il prof. Eberini contestualizza: lo sviluppo dei farmaci antiretrovirali anti-HIV, negli anni Novanta, ha segnato il passaggio da una farmacologia **serendipitosa** — basata sull'osservazione casuale e sullo screening fenotipico di estratti naturali — a una farmacologia **razionale**, basata sulla conoscenza della struttura del bersaglio e sulla progettazione computazionale di molecole complementari.

Aneddoto storico raccontato: le rifamicine (rifampicina, rifaximina) furono scoperte a Milano da Piero Sensi negli anni Cinquanta. Sensi raccontava di aver isolato, durante una vacanza in Sardegna, batteri dalla sabbia degli scogli — batteri che producevano metaboliti secondari attivi contro la crescita batterica. Da quei ceppi si ottenne la rifamicina SV, capostipite di una famiglia che ancor oggi include il farmaco di prima linea per la tubercolosi (rifampicina) e un antibiotico non assorbibile per le infezioni intestinali (rifaximina). Il nome *rifa* deriverebbe dal titolo di un film francese di quegli anni, *Rififi*, allora di moda.

5.4 Il caso di studio: β -lattoglobulina bovina

La proteina scelta come modello didattico è la β -lattoglobulina bovina, per due ragioni operative:

- (1) Il prof. Eberini la conosce intimamente: vi ha lavorato per anni ed è in grado di muoversi rapidamente fra atomi e residui senza perdere tempo a cercare informazioni.
- (2) Essa è straordinariamente ben caratterizzata: è la più rappresentativa della famiglia delle **lipocaline** e della superfamiglia delle **calicine**; è altamente disponibile (principale proteina del siero del latte bovino, da cui si purifica facilmente); è stabile, cristallizza bene, è facile da studiare con tecniche strutturali ed è legante di numerosi ligandi diversi.

Nota — Nota biologica: la β -lattoglobulina è presente in alta concentrazione nel latte di praticamente tutti i mammiferi, eccetto l'uomo. Il latte materno umano non ne contiene. Questo è uno dei motivi per cui essa rappresenta un antigene rilevante nelle allergie al latte vaccino.

5.5 La transizione di Tanford: lo studio in silico

Il primo obiettivo didattico è dimostrare, con strumenti computazionali, il meccanismo molecolare della transizione conformazionale pH-dipendente già introdotta nelle Lezioni 1 e 2.

5.5.1 Acquisizione delle strutture sperimentali

Si interroga il **Protein Data Bank** (PDB) per ottenere strutture cristallografiche della β -lattoglobulina bovina cristallizzata a pH diversi. Si trovano:

- Una struttura a **pH 6,2** (acido) — il loop EF è **chiuso** sul sito di legame.
- Una struttura a **pH 8,2** (basico) — il loop EF è **aperto**.

Le strutture, scaricate, vengono caricate nel software e sovrapposte. Poiché si tratta della **stessa proteina** (stessa struttura primaria), la sovrapposizione strutturale è banale: si esegue residuo-per-residuo senza necessità di allineamento di sequenza preliminare.

5.5.2 Acque di cristallizzazione

Le strutture cristallografiche contengono molecole d'acqua **incidentali**: molecole intrappolate durante la formazione del cristallo, prive in molti casi di significato strutturale o catalitico. Vengono rimosse di routine, salvo che non si sospetti un ruolo funzionale per acque specifiche (acque catalitiche, acque strutturali).

5.5.3 Identificazione del loop EF

Sovrapposte le due strutture e variando il colore (per esempio rosso per la forma acida, blu per la basica), si vede chiaramente una sola differenza significativa: nel **loop EF**, che connette i foglietti β E ed F. In ambiente acido il loop chiude l'accesso al sito di legame; in ambiente basico è aperto.

Significato fisiologico. Nello stomaco (ambiente acido) la β -lattoglobulina è chiusa, **stabile alla proteolisi** e non viene digerita. Nell'intestino (ambiente basico) si apre, viene digerita e libera un peptide che ha attività biologica significativa: blocca l'assorbimento del colesterolo a livello intestinale.

5.5.4 Preparazione della struttura per il calcolo

Le strutture cristallografiche presentano due problemi sistematici che devono essere risolti prima di poter calcolare proprietà energetiche:

Problema	Origine	Soluzione
Mancanza degli idrogeni	La cristallografia ai raggi X rileva la densità elettronica degli atomi pesanti; gli H non hanno elettroni sufficienti per essere visibili e non vengono inseriti nei file PDB.	Aggiunta automatica degli idrogeni in base alla chimica.
Atomi mancanti	Regioni della proteina ad alta temperatura/fluttuazione (<i>B-factor</i> elevato) producono densità elettronica diffusa: il cristallografo non assegna atomi pesanti.	Ricostruzione algoritmica delle catene laterali o degli interi residui mancanti.
Cariche non assegnate	Lo stato di protonazione di Asp, Glu, Lys, Arg, His dipende dal pH dell'esperimento.	Protonazione a pH specifico (<i>Protonate 3D</i> in MOE).

Nota — Cruciale: protonare a pH 7,4 una struttura cristallizzata a pH 6,2 è un errore. La protonazione deve essere fatta al pH sperimentale, specificandolo nel software.

5.5.5 Modelli di solvatazione

La proteina nel cristallo è in stato solido; in soluzione è evidentemente immersa in acqua. Il calcolo deve tenerne conto. Esistono diversi **modelli di solvatazione**:

Modello	Cosa simula	Costo
Costante dielettrica	Solo la schermatura elettrostatica dell'acqua ($\epsilon_{\text{acqua}} \approx 80$ contro $\epsilon_{\text{vuoto}} = 1$). Le interazioni elettrostatiche sono ridotte di 80 volte. Solvatazione implicita più grezza.	Bassissimo
Reaction field	Usa le acque cristallografiche dove ci sono, e altrove simula la costante dielettrica.	Basso
Generalized Born (GB)	Solvatazione implicita completa: simula sia l'effetto dielettrico sia l'energia di solvatazione superficiale.	Medio
Solvente esplicito	Si circonda la proteina con molecole d'acqua reali (modello TIP3P, SPC/E, etc.) in una <i>box</i> periodica.	Alto

Limite dei modelli impliciti. Tendono a **sovrastimare** l'energia di solvatazione. Durante l'ottimizzazione strutturale, l'eccessiva energia di solvatazione favorisce l'esposizione degli amminoacidi idrofili in superficie a discapito dell'ottimizzazione geometrica interna, potendo introdurre piccole distorsioni strutturali artificiali.

5.6 Calcolo delle pKa con PropKa

Per individuare l'amminoacido con pKa anomala responsabile della transizione, si calcolano le pKa di **tutti** i residui titolabili della struttura (Asp, Glu, Lys, Arg, His). Nel lavoro pubblicato nel 2004, il prof. Eberini e collaboratori dovettero usare un metodo di elettrostatica numerica molto costoso e poterono permettersi solo il calcolo per E89 (l'amminoacido che già sospettavano).

Oggi **PropKa** (Olsson et al.) permette di calcolare le pKa di tutti i residui titolabili in tempi praticamente istantanei mediante un'equazione empirica e lineare. Eseguito il calcolo:

Residuo	pKa calcolata (forma acida, pH 6,2)	Note
Asp 11	3,67	Valore normale
Asp 28	2,58	Valore normale (leggermente basso)

Residuo	pKa calcolata (forma acida, pH 6,2)	Note
Asp 85	≈ 4 (normale)	Sul loop EF — escluso
Glu 89	7,2	Anomalo. Sul loop EF. L'amminoacido cercato.

Il valore di 7,2 calcolato è **in eccellente accordo** con il valore sperimentale storico di Tanford (≈ 7,3); l'errore è di 0,1 unità di pH, trascurabile.

5.6.1 Coerenza dello stato di protonazione con il pH

Un passaggio metodologico delicato: a pH 6,2 (sperimentale), il Glu 89 con pKa 7,2 è a un'unità di pH al di sotto della sua pKa. Conseguenza dalla legge di Henderson–Hasselbalch:

Henderson–Hasselbalch e rapporto delle forme. $\text{pH} = \text{pKa} + \log([A^-]/[HA])$. Se $\text{pH} - \text{pKa} = -1$, allora $[A^-]/[HA] = 10^{-1} = 0,1$. Vale a dire: la forma **protonata** (neutra, COOH) è 10 volte più abbondante della forma deprotonata (anione, COO⁻).

Pertanto Glu 89 a pH 6,2 deve essere protonato come COOH neutro, non come COO⁻. La protonazione standard applicata di default è scorretta e va corretta manualmente per quel singolo residuo.

5.6.2 Spiegazione molecolare della pKa anomala

Perché Glu 89 ha pKa 7,2 anziché 4,5? Andando a guardare la struttura in dettaglio: Glu 89 è collocato all'**interno del sito di legame**, in una cavità prevalentemente idrofobica, non esposto al solvente (*buried*). Inoltre, durante la simulazione di dinamica molecolare, l'idrogeno del gruppo COOH di Glu 89 forma un **legame a idrogeno stabile** con l'ossigeno del backbone della Serina 116.

Questo legame a idrogeno blocca strutturalmente il protone, impedendone la dissociazione: la pKa locale risulta drammaticamente innalzata. La cavità idrofobica circostante stabilizza ulteriormente la forma neutra (protonata) rispetto alla forma anionica, che sarebbe destabilizzata in un microambiente apolare.

5.6.3 Verifica con la struttura a pH basico

Ripetendo la stessa procedura sulla struttura cristallizzata a pH 8,2, preparata correttamente per pH 7,4, si ottiene per Glu 89 una pKa di 4,5: **perfettamente normale** per un acido carbossilico esposto al solvente. Perché? In questa conformazione il loop EF è aperto, Glu 89 è rivolto verso l'esterno, esposto all'acqua, e non può formare il legame a idrogeno con Ser 116. Il protone è quindi libero di dissociare normalmente.

Conclusione del caso di studio. La transizione di Tanford è guidata da un singolo residuo, **Glu 89**, la cui pKa è dipendente dalla conformazione: anomala (≈ 7,2) nella forma chiusa, normale (≈ 4,5) nella forma aperta. In ambiente acido (stomaco) la forma chiusa è stabile e protegge la proteina dalla proteolisi; in ambiente basico (intestino) la forma aperta è accessibile alla degradazione enzimatica.

5.7 Riconoscimento molecolare: il legame dell'acido palmitico

Seconda parte della Lezione 5: si studia il meccanismo con cui la β-lattoglobulina lega il suo ligando naturale, l'**acido palmitico**.

5.7.1 La struttura del complesso

Si scarica dal PDB la struttura della β-lattoglobulina co-cristallizzata con acido palmitico nel sito di legame. La struttura — opportunamente preparata (aggiunta idrogeni, protonazione, rilassamento in acqua implicita) — mostra:

- Una **cavità interna prevalentemente idrofobica**, perfetta per accomodare la lunga catena alifatica dell'acido palmitico.
- Sulla bocca della cavità, due lisine cariche positivamente (**Lys 60** e **Lys 69**) che formano **ponti salini** con la testa carbossilica COO^- dell'acido palmitico, orientandolo verso l'interno con la testa rivolta verso l'esterno.
- Un acido glutamico (carico negativo) sopra le lisine, che le mantiene nella posizione corretta tramite un'interazione elettrostatica.

Sandwich di cariche. All'imboccatura del sito di legame si forma un sandwich di interazioni elettrostatiche: $- (\text{Glu}) \leftrightarrow + (\text{Lys}) \leftrightarrow - (\text{COO}^- \text{ del palmitato})$. Il riconoscimento all'interno della cavità è invece **idrofobico-aspecifico**: qualunque catena alifatica della dimensione opportuna vi si accomoda.

5.7.2 Calcolo dell'energia libera di legame

Mediante una **scoring function empirica**, MOE calcola $\Delta G_{\text{bind}}^{\circ} \approx -8,2 \text{ kcal/mol}$ per il complesso β -lattoglobulina-palmitato. Convertendo a temperatura costante tramite $K_d = e^{\Delta G^{\circ}/RT}$, si ottiene un'affinità nel range **submicromolare-micromolare**.

5.8 Mutagenesi in silico: il ruolo di Lys 60 e Lys 69

Per dimostrare che le due lisine sono determinanti per il riconoscimento, si esegue una **mutagenesi in silico**. Il prof. Eberini sottolinea un principio metodologico generale prima di procedere.

5.8.1 Alanine scan e doppia attenzione metodologica

Alanine scan. Tecnica di mutagenesi sistematica in cui ogni amminoacido di interesse viene sostituito con un'alanina, eliminandone così la catena laterale (l'alanina ha come catena laterale un solo CH_3). Permette di quantificare il contributo individuale di ciascun residuo all'attività o all'interazione.

Errore metodologico tipico: mutare un residuo in alanina nel laboratorio wet, osservare perdita di affinità, e concludere immediatamente che quel residuo era critico per il legame. Si trascura una possibilità alternativa: la mutazione potrebbe aver destabilizzato il folding, impedendo alla proteina di assumere la corretta struttura tridimensionale. In quel caso la proteina non lega non perché manca l'interazione specifica, ma perché non è propriamente folded.

Doppia validazione. Quando si fa una mutagenesi, occorre **sempre** verificare in parallelo: (i) la variazione di stabilità ($\Delta G_{\text{fold}}^{\circ}$); (ii) la variazione di affinità ($\Delta G_{\text{bind}}^{\circ}$). Se $\Delta \Delta G_{\text{fold}}^{\circ} > 3-4 \text{ kcal/mol}$, il mutante è probabilmente destabilizzato e l'effetto sull'affinità è confuso da quello sulla stabilità.

5.8.2 Strategia di forza bruta vs eleganza

Al computer si può **esplorare tutto lo spazio delle mutazioni**: il prof. Eberini chiama questa strategia **forza bruta**. Provare tutti i 19 amminoacidi su Lys 60 e tutti i 19 su Lys 69 più la doppia mutazione 19×19 produce $19 + 19 + 19 \times 19 = 19 + 19 + 361 = \text{circa } 400$ mutanti. Il software MOE consente di lanciare il calcolo per tutti in modalità automatica via *side-chain limit* = 2.

Dal punto di vista dell'eleganza concettuale è pessima. Però mi fa vedere cose che rischierei di non vedere. Lavorate sempre in equilibrio fra eleganza e forza bruta. Troppo eleganti non va bene mai, nemmeno nella vita. Troppo grezzi nemmeno.

Per ragioni di tempo didattico, si esegue il caso **peggiore** ipotizzabile: mutare entrambe le lisine (cariche positive) negli amminoacidi acidi (Asp, Glu, cariche negative). Tale doppia mutazione dovrebbe distruggere completamente il riconoscimento elettrostatico del palmitato.

5.8.3 Risultati della mutagenesi

Il mutante **K60E / K69D** mostra:

- $\Delta\text{Stability} \approx 3,5\text{--}4$ kcal/mol — un impatto significativo ma non disastroso sulla stabilità (il prof. Eberini fissa come soglia di allarme 3–4 kcal/mol).
- $\Delta\text{Affinity} \approx 1$ kcal/mol di riduzione — non enorme in valore assoluto, ma essendo l'energia libera di legame in scala logaritmica rispetto alla K_d , corrisponde a un fattore ≈ 10 di perdita di affinità.

5.8.4 Docking molecolare con il mutante

Per visualizzare l'effetto della doppia mutazione sul riconoscimento, si esegue un **docking molecolare**: si rimuove il palmitato dal complesso, si lascia il mutante in stato apo, e si chiede al software di reinserire il palmitato nel sito generando 10 conformazioni ottimali.

Docking molecolare. Simulazione computazionale dell'inserimento di un ligando in un sito di legame proteico. L'algoritmo esplora orientazioni e conformazioni del ligando, scorando ciascuna con una funzione energetica empirica e proponendo le N pose con punteggio migliore. Per piccole molecole si parla di *small-molecule docking*; per proteine–proteine di *protein-protein docking*, che usa algoritmi differenti.

Risultato per il mutante K60E / K69D: delle 10 conformazioni generate, circa la metà sono **capovolte** rispetto al wild-type — l'acido palmitico entra con la testa carbossilica rivolta verso l'**interno** anziché verso l'esterno. Le energie sono peggiori del wild-type e le due pose (testa-fuori, testa-dentro) sono **degeneri**, ossia isoenergetiche: il meccanismo di orientazione è perso.

Conclusione del caso. Lys 60 e Lys 69 non sono determinanti per la **capacità** di legare l'acido palmitico (il legame avviene comunque, perché la cavità idrofobica è preservata), ma sono **determinanti per l'orientamento** del ligando nel sito. La perdita di selettività orientazionale è il fingerprint molecolare della loro funzione.

Nota — Raccomandazione operativa del prof. Eberini: poiché $\Delta\text{Stability} = 3,5$ kcal/mol è al limite della soglia di sicurezza, prima di lanciare gli esperimenti wet sul mutante (espressione, purificazione, binding assay) si dovrebbe verificare la stabilità della proteina mutante con tecniche indipendenti — per esempio, proteolisi limitata (la proteina denaturata è più suscettibile) o dicroismo circolare (per modulare il contenuto di struttura secondaria e terziaria).

Lezione 6

Homology modeling: dalla β -lattoglobulina di bufalo all'inizio del progetto GPR17

Aprile 2026 — Sesta lezione

6.1 Modeling per omologia: principio operativo

Stabilita la teoria dell'omologia e degli allineamenti, si passa ora alla costruzione operativa di modelli strutturali. Il metodo principale si chiama **homology modeling** o **comparative modeling** (i due termini sono sinonimi):

Homology modeling / Comparative modeling. Costruzione del modello tridimensionale di una proteina di sequenza nota (**query**) usando come **templato** la struttura tridimensionale sperimentale di una proteina omologa nota. Il termine *homology* sottolinea l'inferenza filogenetica; il termine *comparative* sottolinea il confronto operativo fra le due sequenze.

6.2 Caso semplice: β -lattoglobulina di bufalo

Il primo esercizio didattico: costruire un modello della β -lattoglobulina di **bufalo**. Il bufalo è una specie per cui — nell'esempio del prof. Eberini — non esiste una struttura sperimentale. Tuttavia, abbiamo nel PDB la β -lattoglobulina di specie omologhe: bovino, ovino (capra, pecora), suino. L'identità di sequenza è elevatissima.

6.2.1 Recupero della sequenza dalla query

Si interroga **UniProt** per ottenere la sequenza primaria della β -lattoglobulina di bufalo (in formato FASTA, riconoscibile dal carattere > che apre la riga di intestazione).

Formato FASTA. Formato standard per le sequenze biologiche. Prima riga: > seguito da identificatore e descrizione. Righe successive: la sequenza, tipicamente in blocchi di 60 o 80 caratteri per riga. Vale sia per acidi nucleici sia per proteine. Il nome FASTA deriva dal software omonimo (Pearson & Lipman, 1988).

6.2.2 Ricerca del templato omologo nel PDB

Si esegue una ricerca **BLAST** della query contro il database **PDB** (non UniProt!), perché serve un templato di cui sia nota la **struttura tridimensionale**. UniProt contiene anche modelli AlphaFold che è meglio evitare, se possibile, come templato — preferendo strutture risolte sperimentalmente.

*Nota — Una tipica domanda d'esame: Su che database fai la ricerca del templato? Risposta corretta: **PDB**. Risposta sbagliata: UniProt — UniProt contiene tutte le proteine note ma non contiene necessariamente le loro strutture sperimentali.*

La ricerca BLAST restituisce templati con i seguenti dati (esempio):

Specie	Identità di sequenza	Copertura	Templato
Capra (<i>Capra hircus</i>)	≈ 95%	≈ 100%	Sì — ottimo
Pecora (<i>Ovis aries</i>)	≈ 94%	≈ 100%	Buono
Bovino (<i>Bos taurus</i>)	≈ 90%	≈ 100%	Buono

Si sceglie il template di capra come principale per copertura e identità, eventualmente integrandolo con uno secondario per gestire una porzione particolarmente difficile (chimerizzazione del modello).

6.2.3 Allineamento globale esatto

Una volta scaricato il template, si esegue l'allineamento globale **esatto** query–template (programmazione dinamica + matrice BLOSUM62). Attenzione: BLAST esegue allineamenti **locali** ed **euristici**, non sufficientemente accurati per il modeling. Per il modeling serve un allineamento **globale ed esatto**.

MOE esegue automaticamente l'allineamento bloccando intanto gli allineamenti del template fra loro (se ci sono più template), e allineando poi la query mantenendo bloccato l'allineamento dei template. È un lavoro che evita di reinventare la ruota — gli allineamenti dei template fra loro sono già stati ottimizzati.

6.2.4 Chimerizzazione del modello

Quando un singolo template non copre completamente la query, si possono usare **più template** chimerizzati: parte del modello dal template 1, parte dal template 2. Esempio nella lezione: per la β -lattoglobulina di bufalo, si usa il template di capra (1EXS) per la maggior parte della proteina, e un secondo template (4X0B) per una porzione finale dove il primo è stato risolto in modo incompleto.

6.2.5 Costruzione del modello: passi automatici di MOE

Passo	Operazione
1	Allineamento globale ottimale query $\leftrightarrow$ template
2	Copia del backbone (C α –C–N) del template per i residui allineati
3	Copia delle catene laterali dove la query e il template hanno lo stesso amminoacido
4	Ricostruzione delle catene laterali dove la query differisce dal template, mantenendo l'orientamento del rotamero
5	Modellazione dei loop nelle regioni con gap (query ha residui che mancano al template)
6	Costruzione dei ponti disolfuro e protonazione
7	Raffinamento : minimizzazione energetica del modello in acqua implicita
8	Generazione di più modelli alternativi (tipicamente 10)
9	Ranking dei modelli — tipicamente per energia di solvatazione (Generalized Born)
10	Selezione del modello migliore e raffinamento finale più aggressivo

Perché 10 modelli e non 1? Il modeling è un problema sotto-determinato: piccole variazioni nell'algoritmo di ricostruzione (specialmente nei loop e nelle catene laterali) producono modelli alternativi. Generandone 10 e selezionando il migliore secondo un criterio energetico indipendente (l'energia di solvatazione GB) si aumenta la robustezza statistica della scelta.

6.2.6 Validazione: l'energia di solvatazione come criterio

L'energia di solvatazione è un criterio efficace per il ranking dei modelli: se il modello è geometricamente ben costruito, i residui **idrofilici** stanno in superficie (ben solvatati = energia negativa) e i residui **idrofobici** stanno nel core (non esposti al solvente). Modelli con questa organizzazione corretta hanno energia di solvatazione molto negativa; modelli con errori (es. residui idrofobici esposti in superficie) hanno energia di solvatazione meno favorevole.

6.2.7 Caso semplice: identità di sequenza alta

Per la β -lattoglobulina di bufalo, il caso è didatticamente **semplice**: l'identità di sequenza con i template di capra, pecora e bovino è del 90–95%. L'allineamento è univoco. La differenza fra usare il template di capra o quello di pecora è marginale. Il modello finale è di alta qualità intrinseca.

6.3 Caso complesso: GPR17

Il secondo esercizio è la modellazione del **GPR17**, un **recettore di membrana a sette domini transmembrana** (*seven-transmembrane receptor*, 7TM) della famiglia GPCR di classe A. Il caso è didatticamente **complesso** per diverse ragioni.

6.3.1 Rilevanza farmacologica di GPR17

Il GPR17 è di alto interesse per il drug design: oltre il 40% dei farmaci in commercio agisce su GPCR. GPR17 è uno dei più studiati perché la sua attività è modulata sia da agonisti dei recettori P2Y purinergici (uridin-glucosio, uridin-galattosio, vari nucleotidi) sia da agonisti/antagonisti dei recettori cisteinilici dei leucotrieni (CysLT, LTC4, LTD4, montelukast). È quindi un **recettore filogeneticamente al confine** fra due sottofamiglie di GPCR di classe A: i purinergici e i cisteinilici.

6.3.2 Scelta del template: non solo identità di sequenza

Una considerazione di fondo: **non si sceglie il template solo sulla base dell'identità di sequenza**. Si tiene conto anche di:

- Appartenenza alla stessa **sottofamiglia funzionale** (GPCR di classe A, con ponte disolfuro N-terminale conservato).
- **Stato conformazionale** del template (attivo, inattivo, complessato con ligando, complessato con G-protein).
- Eventuali **modificazioni cristallografiche** per favorire la cristallizzazione (es. fusione con T4 lisozima nei loop intracellulari).

Per GPR17 si sceglie come template principale il recettore **P2Y1**, risolto sperimentalmente (codice PDB 4XNV o simili), che è parente filogenetico stretto e ha il ponte disolfuro caratteristico.

6.3.3 Pulizia del template: rimozione del T4 lisozima

Per cristallizzare il P2Y1, il cristallografo aveva sostituito un loop intracellulare (tagliando 5 amminoacidi nativi) con la sequenza del **T4 lisozima**, una proteina inserita per stabilizzare la struttura durante la cristallizzazione. Tale lisozima:

- Non fa parte della proteina nativa.
- Va **rimosso** prima di usare il template.
- I 5 amminoacidi nativi che erano stati tagliati vanno **ricostruiti**.

MOE consente di ricostruire un loop mancante chiedendo al software di campionare conformazioni alternative per il segmento da ricostruire, ordinandole per energia e selezionando la più favorevole.

6.4 Bassa identità di sequenza: le difficoltà del modeling difficile

Identità di sequenza GPR17 $\leftrightarrow$ P2Y1 $\approx$ 26–28%. Si è nella **twilight zone** per quanto riguarda l'inferenza strutturale. L'omologia è plausibile (entrambi sono GPCR di classe A), ma l'allineamento è fragile: 70 amminoacidi su 100 sono diversi, e basta sbagliare di una posizione lungo la sequenza per generare un modello completamente errato.

6.4.1 Strategia 1: allineamento multiplo di famiglia

Per migliorare la robustezza dell'allineamento, si può **riallineare** usando un MSA dell'intera famiglia GPCR di classe A, ottenendo un profilo di posizione. Questo trasferisce le informazioni di conservazione di tutta la famiglia sull'allineamento puntuale query–templato.

6.4.2 Strategia 2: predizione della struttura secondaria

Si predice la struttura secondaria della query (GPR17) e la si confronta con quella del template (P2Y1, nota dalla struttura cristallografica). Per un GPCR di classe A ci si aspetta 7 α -eliche transmembrana. L'allineamento è poi ottimizzato in modo che le α -eliche predette della query coincidano con le α -eliche del template.

6.4.3 Strategia 3: auto-annotation con la famiglia

Funzionalità di MOE: l'**auto-annotation** riconosce automaticamente la famiglia di appartenenza di una sequenza (GPCR di classe A nel nostro caso) e applica i **constraint** della letteratura per quella famiglia: posizioni delle 7 eliche transmembrana, residui conservati, ponti disolfuro caratteristici. L'allineamento viene ricalcolato rispettando questi vincoli.

6.4.4 Vincolo del ponte disolfuro

I GPCR di classe A possiedono un **ponte disolfuro conservato** fra una cisteina N-terminale (nel loop extracellulare 2) e una cisteina del dominio transmembrana 3. Verificando l'allineamento, le due cisteine della query GPR17 devono allinearsi con le due cisteine del template P2Y1 che fanno effettivamente il ponte. Questo è un controllo robusto di correttezza dell'allineamento.

6.5 Il dilemma metodologico: punteggio vs vincolo di costruzione

Un punto interessante emerso in classe durante la Lezione 7: in una specifica posizione dell'allineamento, l'introduzione del vincolo (constraint) della famiglia GPCR di classe A peggiora il punteggio della matrice di sostituzione (una L del template si allinea con una A della query, invece che con una F come suggerirebbe BLOSUM62). Cosa fare?

Opzione	Razionale	Argomento contrario
Mantenere il punteggio della matrice ($L \leftrightarrow F$, conservativa)	La matrice BLOSUM62 è basata su evidenza statistica osservazionale di sostituzioni in milioni di allineamenti.	Si ignora il dato filogenetico specifico della famiglia GPCR.
Spostare di una posizione e seguire il constraint ($L \leftrightarrow A$)	Si segue la coerenza filogenetica dell'intera famiglia, anche se localmente la sostituzione è meno conservativa.	Si peggiora il punteggio locale di allineamento.

Non c'è un giusto e uno sbagliato. Voi scriverete nel vostro modello il vostro ragionamento; vostra responsabilità sarà che il ragionamento sia esplicito e difendibile davanti a un revisore.

Nota — In classe la maggioranza degli studenti vota per la coerenza filogenetica (5 a 3). Il prof. Eberini ribadisce che entrambe le scelte sono accettabili, purché esplicitate e motivate.

6.6 Tre modelli alternativi

La discussione di Lezione 7 evidenzia che, dato un caso difficile, si potrebbero in linea di principio costruire **tre modelli** alternativi, riflettendo tre strategie di allineamento:

Modello	Strategia di allineamento
1	Allineamento di solo punteggio (BLOSUM62 + programmazione dinamica), senza alcun vincolo .
2	Allineamento con vincoli di struttura secondaria + auto-annotation di famiglia, ma uno specifico vincolo non rispettato per privilegiare il punteggio locale.
3	Allineamento con tutti i vincoli rispettati , accettando un peggioramento del punteggio in alcune posizioni.

Per ragioni di tempo si costruisce un solo modello (la scelta intermedia 2, secondo il voto della classe). Ma il prof. Eberini ricorda che **in un lavoro pubblicato** si avrebbero tutti e tre i modelli a disposizione, e si sceglierebbe non per ragioni statistiche ma per **coerenza con i dati sperimentali** (mutagenesi, dati di binding, fotolabelling, etc.).

Lezione 7

Completamento del modeling di GPR17: scoring, validazione, sito di legame

Aprile 2026 — Settima lezione

7.1 Ranking energetico dei modelli generati

Generati 10 modelli alternativi di GPR17, vanno ordinati per qualità. Le metriche utilizzabili in MOE sono:

Metrica	Significato
U (energia potenziale totale)	Somma dei termini di energia di legame e non-legame. Indica la stabilità termodinamica complessiva del modello.
E _{GB} (energia di solvatazione, Generalized Born)	Indica quanto correttamente i residui idrofili sono solvatati e gli idrofobici sepolti. Cruciale per proteine globulari; problematico per proteine di membrana .
Contact energy	Energia delle interazioni atomo–atomo nel core idrofobico.
Packing score	Qualità dell'impaccamento delle catene laterali, senza vuoti interni.
Distanza geometrica dal modello medio	Si genera la media geometrica dei 10 modelli e si calcola l'RMSD di ciascuno rispetto ad essa: il modello più vicino alla media è scelto.

7.2 Il problema dell'energia di solvatazione per le proteine di membrana

GPR17 è una proteina di membrana: ha **sette α -eliche transmembrana** composte di amminoacidi **idrofobici**. Se calcoliamo l'energia di solvatazione senza simulare la membrana lipidica, troviamo che quei residui idrofobici sono male solvatati: l'energia di solvatazione **non è un buon criterio** per il ranking, perché è artificialmente alta e non riflette la realtà fisica.

7.2.1 Possibili soluzioni

Tre approcci, in ordine di rigore:

Approccio	Descrizione	Praticabilità
Membrana esplicita	Inserire i 10 modelli in una membrana lipidica di POPC (o simile), simulare il sistema e calcolare l'energia di solvatazione corretta.	Lavoro pesante, ma metodologicamente corretto.
Membrana implicita	Modello di solvatazione che simula la presenza di una membrana senza inserire fosfolipidi espliciti. Disponibile in software come <i>Bioluminate</i> .	Pulito ma non disponibile in tutti i software.
Ignorare il problema e usare l'energia di solvatazione	Si calcola E _{GB} sbagliata per tutti i 10 modelli; ma essendo l'errore circa lo stesso per ogni modello (perché i residui transmembrana sono nelle stesse posizioni in tutti i 10), la discriminazione relativa fra modelli rimane informativa.	Pragmatica, da giustificare al revisore.

7.2.2 Risposta esemplificativa a un revisore critico

— Hai calcolato la solvatazione senza tenere conto della membrana, hai sbagliato!

— Sì, ma: (i) i 10 modelli che sto confrontando hanno tutti gli stessi residui transmembrana approssimativamente nelle stesse posizioni, quindi l'errore di solvatazione è approssimativamente costante e **si cancella nella differenza** fra modelli; (ii) l'energia totale è significativamente meno negativa di quanto sarebbe in membrana, e questo è informativo, ci conferma che ci sono effettivamente amminoacidi che vorrebbero stare in un microambiente non acquoso; (iii) per discriminare ulteriormente, ho confrontato i risultati con un criterio **puramente geometrico** (distanza dal modello medio calcolata solo sui C α), che non dipende dalla solvatazione.

7.3 Selezione del modello e analisi

Selezionato il modello migliore, lo si analizza dal punto di vista qualitativo e strutturale.

7.3.1 Grafico di Ramachandran

Grafico di Ramachandran. G. N. Ramachandran (1963) osservò che, su un grande insieme di proteine risolte sperimentalmente, gli angoli di torsione del backbone ϕ (C α -N-C'_(i-1)) e ψ (C'-C α -N_(i+1)) di ogni amminoacido cadono in regioni ben definite del piano (ϕ , ψ). Il terzo angolo del backbone (ω , attorno al legame peptidico C'-N) non ruota liberamente per via della **risonanza ammidica**: il legame peptidico è parzialmente un doppio legame.

Le regioni consentite del grafico di Ramachandran corrispondono a:

- **α -elica destrorsa:** $\phi \approx -60^\circ$, $\psi \approx -45^\circ$.
- **Foglietto β :** $\phi \approx -120^\circ$, $\psi \approx +130^\circ$.
- **α -elica sinistrorsa:** $\phi \approx +60^\circ$, $\psi \approx +45^\circ$ (rara; consentita per la glicina, che non ha catena laterale e quindi può assumere questa conformazione).

Per un modello ben costruito, la **maggioranza** degli amminoacidi deve cadere nelle regioni consentite. Per GPR17, costituito quasi esclusivamente di α -eliche, la maggior parte dei residui dovrà cadere nella regione α -elica destrorsa.

7.3.2 Outliers di Ramachandran

Si chiamano **outliers** gli amminoacidi che cadono fuori dalle regioni consentite. Strategia operativa raccomandata:

N outliers	Interpretazione	Azione
8–10 o più	Il modello è probabilmente sbagliato (allineamento errato, scelta del template infelice).	Rivedere allineamento e scelta del template.
2–3	Possibile errore locale, oppure outlier presente anche nel template reale.	Verificare il template: se gli stessi outlier sono presenti nella struttura sperimentale, si lasciano e si giustificano con la presenza in natura.
0–1	Modello accettabile.	Procedere alla validazione ulteriore.

Se mi chiedono perché ci sono due outliers, io rispondo: madre natura li ha messi nel template originale, esiste in natura una proteina che cristallizzata sperimentalmente li ha. Quindi sono possibili. Non mi sono posto un problema.

7.4 Identificazione del sito di legame

Validato il modello, si cercano le **cavità** della superficie proteica che potrebbero ospitare un ligando. Si usano **metodi geometrici basati su sfere** (es. algoritmo Site Finder di MOE; concetto simile in CASTp, fpocket, etc.):

Site Finder geometrico (sfere α). L'algoritmo riempie con sfere espansive lo spazio attorno alla proteina, finché le sfere occupano l'intero volume libero. Quelle sfere che si trovano in cavità profonde (circondate da atomi proteici) sono colorate diversamente. Si distinguono **sfere grigie** (al centro di cavità ben formate, soddisfano i criteri geometrici di un sito di legame) e **sfere rosse** (al bordo delle cavità, dove l'incavo non è ottimale).

Per il modello GPR17, l'algoritmo identifica con un singolo click la cavità più grande, situata fra le sette eliche transmembrana — che corrisponde esattamente al **sito ortosterico** del recettore, dove si legano i ligandi endogeni e i farmaci. Il sito è ricco di sfere grigie centrali (sito ben formato) e rosse perimetrali (bordo del sito).

7.5 Cosa si può fare con il modello validato

Un modello validato di GPR17 abilita una serie di studi successivi:

- **Virtual screening:** docking di librerie di piccole molecole per identificare nuovi ligandi (hit identification).
- **Docking dirigido** di ligandi noti (LTC4, montelukast, uridin-glucosio, antagonisti P2Y) per ricostruire il loro modo di binding.
- **Mutagenesi in silico** per progettare proteine mutanti destinate a esperimenti wet di binding o di trasduzione del segnale.
- **Dinamica molecolare** per studiare la flessibilità del recettore e l'eventuale transizione fra stato attivo e inattivo.
- **Docking proteina-proteina** con anticorpi anti-GPR17 (prospettiva terapeutica: anticorpi monoclonali contro recettori di membrana sono una classe emergente).

Nota — Il docking proteina-proteina utilizza algoritmi differenti dal docking small-molecule-proteina: i due partner sono entrambi macromolecole flessibili e la ricerca conformazionale è computazionalmente più impegnativa. Software dedicati includono HADDOCK, ClusPro, ZDOCK, PIPER.

Lezione 8

Dinamica molecolare: teoria, campi di forza, ensemble termodinamici

Aprile 2026 — Ottava lezione — Tenuta dal dott. Davide Bassani

8.1 Introduzione: oltre la struttura statica

La Lezione 8 è tenuta dal dott. **Davide Bassani**, collaboratore del gruppo Eberini e dottorando esperto di simulazioni di dinamica molecolare applicate ad anticorpi monoclonali. L'argomento: la **dinamica molecolare** (Molecular Dynamics, MD), ossia il metodo computazionale che permette di studiare il comportamento dinamico delle proteine nel tempo, andando oltre la rappresentazione statica fornita dall'*homology modeling* o dalla cristallografia.

Dinamica molecolare. Simulazione computazionale del moto degli atomi di un sistema molecolare nel tempo, ottenuta integrando numericamente le **equazioni del moto di Newton** applicate ad ogni atomo a partire da posizioni e velocità iniziali, con le forze derivate da un **campo di forze** (force field) parametrizzato.

Una simulazione MD lascia che la proteina si muova nel tempo, rivelando cambiamenti conformazionali, stabilità strutturale, modalità di interazione con ligandi e con altre macromolecole. Va oltre la cristallografia (che fornisce una singola struttura statica, oltretutto distorta dalle condizioni di cristallizzazione) e l'*homology modeling* (che fornisce anch'esso una struttura statica).

8.2 Le basi fisiche: la seconda legge di Newton

Il fondamento teorico della MD è la **seconda legge di Newton**:

Equazione del moto. $\mathbf{F} = m \cdot \mathbf{a}$, dove $\mathbf{F}$ è la forza netta su una particella, m la sua massa, e $\mathbf{a}$ l'accelerazione. L'accelerazione è la derivata seconda della posizione rispetto al tempo: $\mathbf{a} = d^2\mathbf{r}/dt^2$.

Conoscendo la massa di ogni atomo (nota dal sistema periodico), la posizione iniziale (dalla struttura cristallografica o dal modello) e la forza netta agente su ciascun atomo, possiamo calcolare l'accelerazione, e dall'accelerazione la velocità (integrale temporale dell'accelerazione) e la posizione (integrale temporale della velocità).

Le **velocità iniziali** non sono note ma sono assegnate in modo conforme alla temperatura del sistema: si estraggono da una **distribuzione di Maxwell–Boltzmann** alla T desiderata. L'energia cinetica media è $3/2 k_B T$ per atomo.

8.2.1 Il legame fra forza e energia potenziale

La forza netta su un atomo è la derivata negativa dell'**energia potenziale** del sistema rispetto alla posizione:

Forza e gradiente dell'energia. $\mathbf{F}_i = -\nabla_i U(\mathbf{r}_1, \mathbf{r}_2, \dots, \mathbf{r}_N)$, dove U è l'energia potenziale del sistema, funzione delle posizioni $\mathbf{r}_i$ di tutti gli N atomi. Il gradiente ∇_i indica la derivata rispetto alle coordinate della particella i .

Dunque per simulare il sistema dinamicamente serve un modello matematico per calcolare $U(\mathbf{r})$ data una configurazione atomica qualunque. Questo modello è il **campo di forze**.

8.3 I campi di forza

Campo di forze (*force field*). Insieme di equazioni e di parametri che consentono di stimare l'energia potenziale di un sistema molecolare in funzione delle coordinate atomiche. Esempi storici e attuali: AMBER, CHARMM, OPLS, GROMOS.

In un campo di forze, l'energia potenziale è scomposta in due categorie di termini:

8.3.1 Termini di legame (*bonded*)

Termine	Significato	Funzione
Bond stretching	Stiramento dei legami covalenti rispetto alla lunghezza di equilibrio.	Oscillatore armonico: $U = (1/2) k_b (r - r_0)^2$
Angle bending	Variazione degli angoli di legame rispetto al valore di equilibrio.	Oscillatore armonico: $U = (1/2) k_\theta (\theta - \theta_0)^2$
Torsioni (angoli diedri)	Rotazione attorno a un legame singolo (es. attorno al carbonio α).	Funzione periodica (serie di Fourier): $U = \sum_n V_n [1 + \cos(n\omega - \gamma)]$

8.3.2 Termini di non-legame (*non-bonded*)

Termine	Origine fisica	Funzione
Interazione elettrostatica	Forze di Coulomb fra cariche atomiche parziali.	$U = q_i q_j / (4\pi\epsilon_0 \epsilon_r r_{ij})$
Interazione di van der Waals	Attrazione di dispersione (London) e repulsione di Pauli a corto raggio.	Potenziale di Lennard-Jones (12-6): $U = 4\epsilon [(\sigma/r)^{12} - (\sigma/r)^6]$

8.3.3 Tipizzazione degli atomi

Un punto sottile ma fondamentale: nei campi di forze ogni atomo non è identificato solo dal suo elemento chimico (C, H, N, O...) ma anche dal **contesto chimico** in cui si trova:

- Un carbonio carbonilico (C=O) ha parametri diversi da un carbonio aromatico, da un carbonio sp^3 saturato, etc.
- Un idrogeno legato a un ossigeno (O-H, scambiabile) ha parametri diversi da un idrogeno alifatico.

La **tipizzazione** degli atomi è il processo automatico con cui il software assegna ad ogni atomo il proprio tipo di forza in base alla connettività locale. Per amminoacidi naturali la tipizzazione è robusta; per ligandi sintetici non standard può richiedere parametrizzazione manuale (es. con il software *antechamber* di AmberTools).

8.4 L'energia potenziale come superficie multidimensionale

Superficie di energia potenziale (PES). Funzione $U(\mathbf{r}_1, \dots, \mathbf{r}_N)$ definita su tutto lo spazio configurazionale. Ogni configurazione atomica del sistema corrisponde a un punto sulla PES, con un valore di energia associato.

Una proteina globulare in soluzione esplora la PES cercando **minimi energetici**: configurazioni stabili in cui tutti i termini (legami, angoli, torsioni, elettrostatica, van der Waals) sono ottimizzati simultaneamente. Lo stato nativo della proteina corrisponde al **minimo globale** (o, più realisticamente, a un *basin* di minimi locali energeticamente vicini).

La cristallografia restituisce una conformazione che, sebbene fisicamente esistente, non è necessariamente al minimo energetico globale: il packing cristallino impone vincoli innaturali. La simulazione MD permette al sistema di rilassarsi verso il minimo naturale in soluzione.

8.5 File necessari per una simulazione MD

Una simulazione MD richiede almeno due file di input:

File	Contenuto	Caratteristica
File di topologia	Connettività del sistema: legami, angoli, torsioni, tipizzazione degli atomi, carica formale. Non cambia durante la simulazione.	Statico
File di coordinate	Posizioni (x, y, z) di tutti gli atomi a un dato istante. Per la simulazione, posizioni iniziali; durante la simulazione, salvate periodicamente.	Dinamico

Mettendo insieme una sequenza temporale di file di coordinate salvati ad ogni passo (*frame*), si ottiene la **traiettoria**: il film del comportamento del sistema nel tempo.

8.6 L'ambiente di simulazione: solvente

Una proteina in soluzione è circondata da acqua. La simulazione deve riprodurre questo ambiente. Esistono due strategie:

8.6.1 Solvente implicito

Si introduce una correzione matematica che approssima l'effetto complessivo dell'acqua sulle interazioni elettrostatiche e di solvatazione, senza inserire molecole d'acqua esplicite.

Aspetto	Vantaggio	Svantaggio
Costo computazionale	Drasticamente ridotto: niente molecole d'acqua da simulare (che possono essere decine di migliaia).	
Fluttuazioni energetiche	Ridotte, perché non c'è continuo scambio di energia con l'acqua. Buono per calcoli di binding energy.	Si perde l'effetto dinamico delle molecole d'acqua: ponti idrogeno mediati dall'acqua, acque strutturali.
Accuratezza per cambiamenti conformazionali grandi		Insufficiente: non si possono studiare grandi transizioni con accuratezza.

8.6.2 Solvente esplicito

Si circonda la proteina con molecole d'acqua reali. La proteina viene posta al centro di una **scatola** (box) il cui volume è riempito di molecole d'acqua secondo la densità fisiologica.

Vantaggi: realistica simulazione dell'ambiente, possibilità di osservare il ruolo specifico di singole acque, alta accuratezza. Svantaggio: il numero di atomi cresce drasticamente (tipicamente di un fattore 10–100), e con esso il costo computazionale.

8.6.3 Periodic Boundary Conditions

Quando si simula una box di solvente esplicito, sorge un problema: le molecole d'acqua che si avvicinano ai bordi della box possono uscirne, oppure scontrarsi contro le pareti generando artefatti.

Periodic Boundary Conditions (PBC). Strategia per cui ogni volta che una molecola esce dalla scatola da un lato, una copia identica rientra dal lato opposto con stesse velocità ed accelerazione. La scatola è quindi replicata infinite volte in tutte le direzioni (x, y, z), ed il sistema diventa effettivamente infinito. Il numero di particelle nella box rimane costante; non ci sono pareti contro cui rimbalzare.

8.7 Ensemble termodinamici

Una simulazione MD può essere eseguita in diversi **ensemble termodinamici**, ciascuno con grandezze macroscopiche conservate diverse. I tre più rilevanti:

Ensemble	Quantità conservate	Uso tipico
NVE (microcanonico)	Numero di particelle, Volume , Energia totale .	Sistema isolato. Approccio veloce ma poco accurato: i sistemi reali non sono mai isolati.
NVT (canonico)	Numero di particelle, Volume , Temperatura .	Sistema in contatto con un termostato che mantiene T costante scambiando energia. Buono per simulazioni a volume fisso.
NPT (isobaro-isoterma)	Numero di particelle, Pressione , Temperatura .	Sistema con termostato e barostato (un pistone virtuale) che mantiene la pressione costante variando il volume. Fondamentale durante l' equilibratura per raggiungere la densità corretta.

8.8 Analisi della traiettoria

Dopo la simulazione (tipicamente di durata nanosecondi–microsecondi) si analizza la traiettoria con diverse metriche quantitative:

Metrica	Significato	Uso
RMSD (Root Mean Square Deviation)	Deviazione strutturale media di un frame rispetto alla struttura di riferimento (es. il frame iniziale).	Monitoraggio della stabilità: quando l'RMSD si stabilizza su un plateau, il sistema è equilibrato.
RMSF (Root Mean Square Fluctuation)	Fluttuazione media di ogni singolo atomo (o residuo) rispetto alla propria posizione media durante la simulazione.	Identificazione delle regioni flessibili della proteina (tipicamente loop esposti, terminali); le regioni rigide hanno RMSF basso.
Raggio di girazione (R_g)	Misura della compattezza globale della proteina.	Monitoraggio di eventi di <i>folding/unfolding</i> ; espansione/contrazione globale.
Energia di interazione proteina–ligando	Calcolo dell'energia di interazione mediata sui frame.	Stima dell'affinità di binding.
Mappe di contatto residuo–residuo	Frequenza con cui due residui sono in contatto durante la simulazione.	Identificazione delle interazioni chiave proteina–ligando o proteina–proteina.

8.9 Limitazioni della MD classica ed *Enhanced Sampling*

La MD classica ha due limitazioni fondamentali:

(1) **Scala temporale:** si possono simulare al massimo microsecondi, mentre eventi biologicamente rilevanti come il folding completo di una proteina avvengono su scale di millisecondi–secondi.

(2) **Barriere energetiche:** la MD classica non può agevolmente attraversare barriere energetiche elevate. Il sistema rimane intrappolato in minimi locali e non esplora altri minimi potenzialmente più stabili.

8.9.1 Dinamica molecolare accelerata (aMD)

Accelerated Molecular Dynamics (aMD). Metodo di *enhanced sampling* che modifica la superficie di energia potenziale aggiungendo un **potenziale di boost** che abbassa le barriere energetiche, permettendo al sistema di esplorare configurazioni che altrimenti rimarrebbero inaccessibili. Il sistema può così transire da uno stato a un altro stato energeticamente lontano.

L'aMD permette di osservare, in tempi di simulazione accessibili, fenomeni come transizioni conformazionali grandi (attivazione recettoriale), apertura/chiusura di loop, eventi di binding e unbinding. È particolarmente utile per anticorpi monoclonali, dove il comportamento dinamico delle **regioni CDR** determina la specificità antigenica e dove gli eventi rilevanti avvengono su scale temporali a volte non accessibili alla MD classica.

Lezione 9

Predizione di proprietà dalla struttura primaria, reti neurali, BLAST

Aprile 2026 — Nona lezione

9.1 Sintesi del flusso DNA → proteina → funzione

Lo squilibrio fra dati di sequenza e dati di struttura è notevole: si conoscono molte più sequenze che strutture. Il flusso operativo della bioinformatica strutturale parte dunque necessariamente dalla struttura primaria:

Livello	Cosa rappresenta	Come si ottiene
DNA	Codifica genetica	Sequenziamento (NGS, Sanger)
RNA	Trascrizione del gene	RNA-seq, derivato sperimentalmente
Sequenza proteica (struttura primaria)	Traduzione dell'mRNA	Predetta dal cDNA o sequenziata via spettrometria di massa
Struttura tridimensionale	Folding della catena polipeptidica nel suo stato nativo	Cristallografia, NMR, cryo-EM (sperimentale); homology modeling, AlphaFold (computazionale)
Funzione	Attività biologica	Biochimica, biologia cellulare, omiche

Per arrivare dalla struttura primaria alla funzione si può passare attraverso varie vie:

- Via sperimentale (cristallografia ai raggi X, NMR, cryo-EM, microscopia a forza atomica): lunga, costosa, non sempre praticabile (proteine grandi, proteine di membrana, proteine instabili).
- Via computazionale: modeling per omologia (se esiste un template), oppure metodi *ab initio* e *de novo* (se non esiste template).

9.2 Proteine come biopolimeri

Le proteine sono **biopolimeri amminoacidici**: catene di amminoacidi legati l'uno all'altro dal **legame peptidico**.

Legame peptidico. Legame ammidico fra il gruppo carbossilico di un amminoacido e il gruppo amminico dell'amminoacido successivo, con perdita di una molecola d'acqua. Le proteine sono dunque **poliammidi**.

Il backbone della catena proteica si compone della ripetizione di tre atomi per amminoacido: **N (azoto amminico)**, **C α (carbonio alfa)**, **C' (carbonio carbossilico)**. Le proprietà specifiche di ogni amminoacido derivano dalle **catene laterali** (gruppi R).

9.2.1 La risonanza ammidica e l'angolo ω

Il legame peptidico C'–N **non ruota facilmente**. La ragione è chimico-fisica: gli elettroni del doppietto non condiviso sull'azoto sono **parzialmente delocalizzati** sul carbonio carbossilico, conferendo al legame C'–N un carattere parzialmente di doppio legame (risonanza ammidica). Conseguenza: l'angolo ω (attorno a C'–N) è essenzialmente fisso a 180° (configurazione trans) per la maggior parte dei legami peptidici.

Per ogni amminoacido si hanno dunque solo due angoli torsionali rotabili (gli angoli di Ramachandran): ϕ e ψ .

9.3 Database di sequenza e di struttura

Database	Tipo	Note
UniProt	Sequenze proteiche	Database europeo, alta qualità, sequenze annotate, crosslink ad altri database. Preferito a NCBI-NR.
NCBI-NR	Sequenze proteiche	Database americano, non ridondante. Equivalente operativo a UniProt per ricerche BLAST.
PDB (Protein Data Bank)	Strutture tridimensionali	Unico database mondiale di strutture sperimentali. Tre versioni-mirror: RCSB (USA), PDBe (Europa), PDBj (Giappone). Stessi dati.
CATH	Domini strutturali	Classifica le proteine del PDB in domini gerarchici.
SCOP	Classificazione filogenetica strutturale	Considera sia sequenza sia architettura strutturale.

9.4 Proprietà locali e globali

Proprietà locale. Dipende solo dai residui vicini in **sequenza primaria**. Esempio: la struttura secondaria di un residuo è determinata dai residui ad esso adiacenti lungo la catena.

Proprietà globale. Dipende da residui che, sebbene possano essere lontani in sequenza primaria, sono **vicini nello spazio tridimensionale**. Esempio: i ponti disolfuro fra due cisteine; l'esposizione al solvente di un residuo (dipende dalla geometria 3D); le interazioni residuo-residuo a lunga distanza.

Nota — Distinzione cruciale per la predizione: le proprietà locali possono essere predette dalla sola sequenza primaria con buona accuratezza; le proprietà globali richiedono almeno la struttura secondaria predetta o, meglio, la struttura 3D.

9.5 Predizione della struttura secondaria

9.5.1 DSSP: il metodo dizionario

DSSP (Dictionary of Secondary Structure of Proteins). Metodo storico (Kabsch & Sander, 1983) basato su un **dizionario** di pezzetti di sequenza associati alla loro struttura secondaria. La proteina query viene divisa in finestre e ciascuna finestra è cercata nel dizionario; la struttura secondaria viene assegnata per analogia.

L'accuratezza del DSSP è di circa il **70%**: 7 amminoacidi su 10 sono correttamente predetti. È un punto di riferimento operativo.

9.5.2 Metodi più moderni

Metodi successivi hanno migliorato l'accuratezza:

- **Allineamenti multipli di sequenze omologhe:** si trasferisce la struttura secondaria nota di una proteina di una famiglia a tutte le altre proteine omologhe allineate. Si è già visto l'esempio delle tioredossine (Lezione 4).
- **Reti neurali artificiali** (machine learning): metodi che apprendono da grandi dataset di proteine note l'associazione fra patch di sequenza e struttura secondaria. Accuratezza fino al **80%**.

9.6 Reti neurali artificiali

Rete neurale artificiale. Modello matematico che rappresenta l'interconnessione di neuroni artificiali (**perceptroni**). Ogni perceptrone riceve input, li somma con pesi appropriati, e si attiva (output 1) o non si attiva (output 0) a seconda che la somma pesata superi una soglia.

9.6.1 Il perceptrone

Un perceptrone è il neurone artificiale elementare. Riceve input (es. tre input I_1, I_2, I_3), li somma pesati, e si attiva se la somma supera una soglia (*trigger*). Esempio semplice: il perceptrone si attiva se $I_1 + I_2 + I_3 > 2$, quindi se almeno tre input sono attivi. Il pattern di attivazione viene trasmesso ai perceptroni successivi (analoghi dei dendriti del neurone biologico).

9.6.2 Topologia di una rete neurale

Una rete neurale per la predizione della struttura secondaria ha tipicamente la struttura seguente:

Strato	Composizione	Significato
Input layer	300 perceptroni	Codifica una finestra di 15 amminoacidi attorno al residuo da predire (7 a monte, il residuo stesso, 7 a valle). Ogni posizione richiede 20 perceptroni (uno per ognuno dei 20 amminoacidi naturali), di cui 1 attivo (l'amminoacido presente) e 19 inattivi. Totale: $15 \times 20 = 300$.
Hidden layer(s)	Variabile (decine-centinaia)	Strati interni che apprendono pattern intermedi. Il loro significato biologico è generalmente oscuro — sono <i>scatole nere</i> ottimizzate dal training.
Output layer	3 perceptroni	Uno per ciascuna delle tre classi di struttura secondaria: α -elica, foglietto β , random coil.

9.6.3 Funzione di attivazione sigmoidale

Le reti neurali reali non usano una funzione di attivazione a gradino (0/1) bensì una **funzione sigmoidale** che produce valori continui fra 0 e 1. L'output di ciascun perceptrone rappresenta dunque una **probabilità**: per la struttura secondaria, ad esempio, otteniamo $P(\alpha\text{-elica}) + P(\beta) + P(\text{coil}) = 1$.

9.6.4 Pesi sinaptici e training

Le sinapsi non sono tutte equivalenti. Ogni connessione ha un **peso** diverso: alcuni input contano più di altri. I pesi vengono ottimizzati nella **fase di training** della rete, presentando coppie input–output sperimentali e modificando i pesi per minimizzare l'errore di predizione (algoritmo di *backpropagation*).

Nota — Una volta addestrata, una rete neurale non si può modificare rimuovendo perceptroni (che cambierebbero i gradi di libertà del sistema) ma solo modulando i pesi delle connessioni. Mettendo a zero un peso si disattiva quella connessione senza alterare la topologia.

9.6.5 Predizione dei ponti disolfuro: DiANNA

Un'altra applicazione: la rete neurale **DiANNA** predice se due cisteine date sono o non sono coinvolte in un ponte disolfuro. Per ogni coppia di cisteine si forniscono in input 23 informazioni per cisteina (20 di natura filogenetica + 3 di struttura secondaria) per un totale di 46 input. Output: un singolo perceptrone che fornisce $P(\text{ponte disolfuro presente})$ fra 0 e 1.

9.7 Predizioni dalla struttura primaria

Dalla sola struttura primaria si possono ottenere numerose informazioni utili:

Predizione	Metodo
Massa molecolare	Somma delle masse dei residui (assenza di modifiche post-traduzionali)
Punto isoelettrico (pI)	Algoritmo basato su pKa dei residui titolabili
Idrofobicità	Scala di Kyte-Doolittle (o altre): grafico media flottante lungo la sequenza
Struttura secondaria	DSSP, reti neurali
Peptide segnale	SignalP, riconoscimento di pattern
Domini transmembrana	TMHMM, profili di idrofobicità
Domini funzionali (firme)	InterPro, PROSITE, Pfam
Ponti disolfuro	DiANNA, predizione di rete neurale
Localizzazione subcellulare	Pattern di sequenza specifici

9.7.1 Idrofobicità: profili lungo la sequenza

Il grafico di idrofobicità è uno strumento diagnostico molto potente. Si plotta sull'asse x l'indice del residuo (1, 2, ..., N) e sull'asse y il valore di idrofobicità del residuo secondo una scala (Kyte-Doolittle è la più usata). Si applica una **media flottante** su una finestra di 9–11 residui per smussare le oscillazioni.

Interpretazione:

- **Picchi di alta idrofobicità:** regioni interne (core globulare) della proteina; oppure, in proteine di membrana, domini transmembrana.
- **Picchi di bassa idrofobicità (idrofilia):** regioni esposte al solvente, spesso loop superficiali.

9.7.2 Mappe di contatto

Mappa di contatto (contact map). Matrice in cui sull'asse x e sull'asse y si dispongono gli indici dei residui di una stessa proteina. La cella (i, j) è annerita se i residui i e j sono entro una distanza-soglia (tipicamente 10 Å) nello spazio tridimensionale. La diagonale principale è tutta nera (un residuo è a distanza 0 da sé stesso).

La lettura di una mappa di contatto rivela la struttura secondaria e terziaria:

- **Ispessimento** della diagonale principale → **α -elica**: residui consecutivi (i, i+3, i+4) sono in contatto.
- **Diagonali secondarie parallele** alla principale → **foglietti β paralleli**.
- **Diagonali secondarie perpendicolari** alla principale → **foglietti β antiparalleli**.

9.8 BLAST: l'algoritmo in dettaglio

La Lezione 9 chiude con la descrizione tecnica di **BLAST** (Basic Local Alignment Search Tool), strumento centrale di tutto il corso. L'algoritmo standard usato oggi è **Gapped BLAST** (anche detto BLAST 2).

BLAST. Algoritmo di allineamento **locale**, **euristico** (non garantisce di trovare l'ottimo assoluto) e **veloce**. La velocità è il suo punto di forza: permette di confrontare una query con centinaia di migliaia di sequenze di un grande database in tempi accettabili.

9.8.1 Passaggi dell'algoritmo BLAST

Passo	Operazione
1	Rimozione delle regioni a bassa complessità (sequenze ripetute, omopolimeri) dalla query, per evitare match spuri.
2	Spezzettamento della query in parole di lunghezza fissa (es. triplette).
3	Per ogni parola, ricerca nel database di sequenze contenenti parole simili (con punteggio sopra una soglia, secondo la matrice BLOSUM62 di default).
4	Per ogni match trovato, estensione dell'allineamento verso destra e verso sinistra fino a che il punteggio cresce. Quando il punteggio inizia a decrescere, l'estensione si ferma.
5	Si ottengono i HSP (<i>High Scoring Segment Pairs</i>): allineamenti locali con punteggi associati.
6	Gli HSP vicini (entro una distanza di alcuni amminoacidi, tipicamente ≤ 10) vengono uniti con un gap nel mezzo, da Gapped BLAST. Gli HSP distanti rimangono separati.
7	Ranking degli HSP per punteggio e calcolo dell'E-value associato.

9.8.2 Il template trovato da BLAST → allineamento globale

Una volta che BLAST ha identificato il **template omologo migliore** per la nostra query (quello con E-value minore), **non si usano gli HSP** di BLAST per il modeling. Si rigenera l'allineamento query–template con un metodo **globale ed esatto** (programmazione dinamica con Needleman-Wunsch). Le ragioni:

- (1) Gli HSP sono **locali**: coprono solo porzioni della sequenza, non l'intera proteina.
- (2) BLAST è **euristico**: l'allineamento HSP è veloce ma non necessariamente ottimo. Per il modeling serve la migliore qualità di allineamento ottenibile.

Nota — Sbagliare anche di una sola posizione l'allineamento query–template comporta un disastro nel modello risultante. Si genererebbero clash sterici fra catene laterali che dovrebbero stare lontane e vuoti nel core idrofobico, rendendo il modello inutilizzabile per drug design.

9.9 Sintesi del workflow di homology modeling

Il workflow completo, ribadito a chiusura della Lezione 9:

Passo	Operazione	Strumento
1	Recupero della sequenza query	UniProt
2	Ricerca del template omologo nel PDB	BLAST (o PSI-BLAST o HMM se sensibilità insufficiente)
3	Selezione del miglior template	Valutazione di identità, copertura, qualità sperimentale, stato conformazionale
4	Allineamento globale esatto query–template	Programmazione dinamica (Needleman–Wunsch) + matrice BLOSUM62
5	Costruzione di N (es. 10) modelli alternativi	MOE / Modeller / SwissModel
6	Validazione e ranking dei modelli	Energia di solvatazione, contact energy, Ramachandran plot, RMSD geometrico
7	Selezione del miglior modello	Combinazione di metriche
8	Ricostruzione dei loop critici (se necessario)	Loop modeling specifico

Passo	Operazione	Strumento
9	Predizione di domini transmembrana (per recettori di membrana)	Analisi di idrofobicità + dati di letteratura

9.10 Note sui metodi *ab initio* e basati su AI

Quando non esiste alcun template omologo, si ricorre a metodi **ab initio** (o **de novo**). Le versioni classiche più note sono **I-TASSER** e **Rosetta**, riprese in dettaglio nella Lezione 10.

L'avvento dei metodi basati su intelligenza artificiale — **AlphaFold** (DeepMind, 2020-2021) in primis, seguito da **RoseTTAFold**, **ESMFold** e successori — ha rivoluzionato il campo, fornendo predizioni di accuratezza paragonabile a quella dell'*homology modeling* classico per moltissime proteine, indipendentemente dalla disponibilità di template omologhi.

Diremo che ci sono, diremo che sono più accurati dei metodi ab initio classici, molto meno accurati dell'homology modeling, ma è un metodo che fra una settimana e un mese è cambiato. Vorrei che capiste solo le basi.

Nota — Il prof. Eberini chiarisce: dove esiste un buon template omologo, l'homology modeling resta superiore. AlphaFold è prezioso dove template omologhi non esistono o sono troppo distanti. La scelta del metodo non è dogmatica ma contestuale.

Lezione 10

Costruzione e validazione dei modelli, CASP, threading e modeling de novo/ab initio

Maggio 2026 — Decima lezione

10.1 L'allineamento globale esatto: il passaggio più critico

La lezione si apre con una dimostrazione fondamentale. Si confrontano due modelli generati con due allineamenti globali diversi: uno corretto e uno in cui è stato **forzato un errore**, slittando l'allineamento di una sola posizione. Conseguenza: ogni amminoacido della query si ritrova allineato all'amminoacido **sbagliato** del template. Basta lo spostamento di una singola posizione per generare un modello completamente errato.

L'impatto strutturale è visibile immediatamente:

Allineamento	Effetto strutturale
Corretto	Le catene laterali del core si interfacciano bene, stanno nel core idrofobico, nessun problema.
Slittato di 1 posizione	Compaiono clash (catene laterali ingombranti che urtano una contro l'altra: sovrapposizione dei raggi di van der Waals) e vuoti (aree non impaccate all'interno del modello).

Le due regole del core. Nel cuore della proteina (1) ci deve essere un buon **impaccamento** delle catene laterali idrofobiche e (2) **non** devono esserci grandi spazi vuoti, a meno che non si tratti di un sito di legame. Clash e vuoti sono il segno inequivocabile di un allineamento errato.

*Nota — Attenzione a non confondere due allineamenti diversi: l'allineamento **a coppie** che si fa contro il PDB per **cercare** il template omologo, e l'allineamento **globale ed esatto** che si fa **dopo**, per **riallineare** il template già trovato e costruire il modello. Quest'ultimo è il più critico: se è sbagliato, il modello è sbagliato.*

10.2 Rendere robusto l'allineamento

Per ridurre il rischio di errore, l'allineamento globale può essere irrobustito integrando informazioni esterne:

- Informazioni di **struttura secondaria** (predetta o sperimentale).
- Dati **sperimentali** di laboratorio (mutagenesi, dati di binding, vincoli sui ponti disolfuro).
- Allineamento contro una **intera famiglia** di template anziché un singolo template. Le famiglie già preallineate si recuperano da database come **Pfam**.

Se lo state facendo a mano, dovete allineare e essere sicuri che la famiglia sia allineata bene; altrimenti recuperatela già preallineata dai database delle famiglie.

10.3 L'algoritmo di costruzione: rigid body assembly

Costruito l'allineamento, il modello si genera per **rigid body assembly**: si copiano le posizioni dal template. La procedura distingue backbone e catene laterali.

10.3.1 Il backbone si copia tutto

Il **backbone** (catena principale) è fatto, per ogni amminoacido, della ripetizione $C\alpha-C'-N$: questi atomi sono **uguali** in tutte le proteine. Le proteine si differenziano solo per le catene laterali. Pertanto il backbone del template si può copiare integralmente sul modello... con un'eccezione.

Dove il backbone non si può copiare. Nei punti dell'allineamento dove c'è un **indel** (gap): un tratto del template manca rispetto alla query. Lì il backbone non c'è da copiare e va **ricostruito** (loop modeling).

10.3.2 Le catene laterali: copia o ricostruzione

Situazione nell'allineamento	Operazione sulla catena laterale
Match (template e query hanno lo stesso amminoacido)	Si copia direttamente la catena laterale del template (non solo il vertice $C\alpha$).
Mismatch (amminoacidi diversi)	Si ricostruisce la catena laterale, tenendo conto dell'orientamento di quella del template, ma soddisfacendo i vincoli spaziali: niente sovrapposizione di atomi, angoli ϕ/χ coerenti con il grafico di Ramachandran, energia ragionevole.

10.4 Modelli chimerici vs allineamento multiplo

Per casi complessi si possono usare **più template** per costruire un unico modello, copiando parti diverse da template diversi: è il **modeling chimérico**.

*Nota — Da non confondere con l'allineamento multiplo. L'**allineamento multiplo** serve a generare un allineamento robusto, dopo di che si può usare anche un **solo** template per il modello. Il **modeling chimérico** usa invece **template diversi per parti diverse** del modello. Il primo è basato su allineamenti, il secondo su template.*

10.5 Generazione e validazione di più modelli

Non si genera mai un solo modello, ma sempre **5–10 modelli** alternativi. Cosa cambia fra essi? Il modo in cui vengono ricostruite le parti incerte: i loop nelle regioni con gap (che si possono costruire in molti modi) e l'orientamento delle catene laterali, campionate con regole di sampling a temperature diverse (il software usato di default fa un singolo sampling a **300 K**; si può chiedere diversamente).

10.5.1 Metodo geometrico: distanza dal modello medio

Un criterio di scelta è puramente geometrico: si sovrappongono i 10 modelli e se ne genera un **modello medio**; si calcola poi la RMSD di ciascun modello rispetto alla media e si sceglie quello con la **distanza più bassa**, ossia il modello reale più rappresentativo dell'insieme.

Critica al modello medio. Un revisore può obiettare che, mentre i 10 modelli esistono nello spazio chimico-fisico (sono stati generati e minimizzati), il modello **medio** è una media che potrebbe **non esistere** come conformazione reale fisicamente accettabile. Per questo non si sceglie il modello medio in sé, ma il modello reale più vicino ad esso.

10.5.2 Energia di solvatazione: il criterio più usato

Il criterio più utilizzato non è quello geometrico, ma l'**energia di solvatazione** dei modelli finali. Il principio: un modello fatto bene assomiglia a una proteina reale, con gli amminoacidi **idrofobici nel core** (protetti dal solvente) e gli **idrofilici in superficie** (a contatto con l'acqua). Si ottiene allora un'energia elettrostatica di solvatazione molto **negativa** (favorevole); se invece in superficie ci sono troppi residui idrofobici, l'energia è sfavorevole.

*Nota — Caso speciale: per una proteina **transmembrana**, calcolare la solvatazione senza considerare la membrana introduce un errore, perché si valuta come solvatati amminoacidi che nel mondo reale sono dentro al doppio strato lipidico. Va gestito: trascurandolo ma dichiarandolo, con una membrana implicita, o con una membrana esplicita.*

10.5.3 Impaccamento e Atomic Contact Energy

Se gli idrofili sono in superficie, allora gli idrofobici sono nel core. Due funzioni di punteggio aggiuntive verificano proprio il core: la **qualità di impaccamento** delle catene laterali e l'**energia di contatto interatomico** (Atomic Contact Energy, ACE). Un buon modello ha: solvatazione molto negativa (idrofilici esposti), buon impaccamento ed energia di contatto favorevole (idrofobici nel core che si impaccano bene senza urtarsi e senza lasciare buchi).

*Nota — Per gli anticorpi, essendo proteine **solubili**, il problema della membrana non si pone: si possono usare tutti questi metodi senza limitazioni particolari.*

10.6 CASP: la competizione di predizione strutturale

CASP (Critical Assessment of protein Structure Prediction). Gara biennale che coinvolge sia ricercatori sperimentali sia bioinformatici. Gli sperimentali risolvono strutture di proteine tenendone **segreti** i dati; ai bioinformatici viene data la sola struttura primaria e viene chiesto di predire la struttura tridimensionale. Le predizioni sono poi confrontate con le strutture sperimentali tenute nel «cassetto».

Il ciclo è biennale: nel primo anno si raccolgono i target, si predice e si valuta; nel secondo anno gli *assessor* pubblicano i risultati su un numero speciale della rivista *Proteins: Structure, Function, and Bioinformatics*. Il primo CASP è del **1994** con 35 gruppi; nel 2006–2008 i gruppi erano già circa 250. CASP ha dimostrato, fra l'altro, che la predizione *ab initio* — un tempo ritenuta poco credibile — è possibile, purché i risultati siano presi in modo critico.

10.7 La gerarchia dei metodi di predizione

Metodo	Principio	Accuratezza
Homology / comparative modeling	Usa un template omologo di struttura nota. Richiede che esista un omologo nel database.	La più alta (quando un buon template esiste).
Threading	Organizza tutte le strutture sperimentali note in famiglie di architetture; prova sulla query tutte le architetture note (ignorando l'omologia) e sceglie, con una funzione di punteggio, quella a energia più bassa (più stabile).	Intermedia.
De novo / ab initio	Non usa template né strutture risolte: solo potenziali chimico-fisici o statistici del comportamento degli amminoacidi.	Bassa (migliorata, non risolta, dall'AI).

10.8 AlphaFold: una messa in guardia

Il prof. Eberini insiste su un punto controverso: **AlphaFold non ha «risolto» il problema della struttura delle proteine**. Racconta di un lavoro in revisione, con un buon modello costruito per omologia, in cui un revisore chiedeva perché non fosse stato usato AlphaFold «che è lo stato dell'arte». Per il docente questo è un errore: dove esiste un buon template omologo, l'homology modeling resta superiore; modelli AlphaFold possono presentare regioni destrutturate («a palloncino») mentre un buon modello per omologia è ben impaccato e foldato.

Ordine di priorità raccomandato. (1) Se posso lavorare per **omologia**, lavoro per omologia. (2) Se non posso, provo prima il **threading**. (3) Solo se non posso fare diversamente, vado *ab initio*, e in tal caso scelgo un metodo basato sull'**intelligenza artificiale** (non un de novo classico vecchio), sapendo che l'accuratezza può essere bassa.

Non fatevi fregare da chi vi dice: AlphaFold è lo stato dell'arte, usiamo AlphaFold e teniamo il modello così com'è. A volte ci tocca, ma è un ripiego.

10.9 La costruzione dei loop

Uno dei punti critici del modeling è la **costruzione dei loop**: le parti più variabili, spesso corrispondenti a gap/indel nell'allineamento. Si usa un **loop modeler**. Esempio già visto: la ricostruzione del loop di 5 amminoacidi in regione intracellulare di P2Y1, da cui il cristallografo aveva rimosso 5 residui per impiantare il **T4 lisozima** (poi rimosso da noi).

Approccio al loop	Come funziona
Database di loop	Esistono database di loop estratti da proteine risolte sperimentalmente. Si cerca un loop con sequenza identica o simile, lo si «trapianta» nel modello (come un parrucchino) e si valuta energeticamente se è credibile.
Costruzione de novo	Si genera il loop dai potenziali chimico-fisici e statistici tramite MD (dinamica molecolare), MC (Monte Carlo) o SA (Simulated Annealing); poi si trapianta e si valuta.

Simulated Annealing (ricottura simulata). Dinamica molecolare a temperatura variabile: si scalda e si raffredda ripetutamente il sistema, somministrando «botte di energia» via temperatura per far uscire la struttura dai minimi energetici relativi (locali); infine la si raffredda fino allo zero assoluto, congelando la conformazione verso il minimo ottimale.

I due approcci possono essere **combinati**: si chiede al software di generare loop sia *de novo* sia dal database, si uniscono e si scelgono i più stabili, restringendo i limiti dell'esplorazione conformazionale.

10.10 Le proteine transmembrana

Le proteine di membrana sono «una sofferenza»: difficili da purificare e da risolvere sperimentalmente, perché ricche di residui idrofobici che, una volta estratta la proteina dalla membrana, destabilizzano. Per i GPCR di classe A, all'inizio esisteva una sola struttura risolta: la **rodopsina bovina**.

Perché la rodopsina bovina era un template «sfigato». (i) il suo ligando è legato in modo **covalente** (i GPCR di classe A normalmente non lo sono); (ii) il ligando è un **agonista inverso** (né agonista né antagonista); (iii) il legame covalente profondo faceva chiudere il loop extracellulare 2 sul sito di legame, rendendo i modelli inadatti al virtual screening sul sito. Solo in seguito sono arrivate altre strutture (es. recettore β 2-adrenergico umano).

10.10.1 Kink delle eliche e regola di von Heijne

Le eliche transmembrana spesso presentano **kink** (piegature dell'asse maggiore) introdotti dalla **prolina**, che agisce da *helix breaker*. Per orientare un'elica nella membrana si usa una regola empirica:

Regola di von Heijne (positive-inside rule). Gli amminoacidi carichi **positivamente** si trovano prevalentemente sul lato **intracellulare**. Se l'estremità N-terminale di un'elica ha molte cariche positive, sarà il N-terminale a essere intracellulare; viceversa per il C-terminale. Aiuta a determinare la polarità di attraversamento (N→C o C→N) della membrana.

Inoltre, alle due interfacce membrana-solvente si trova una **cintura aromatica** (*aromatic belt*) di tirosine e triptofani, che fa da «galleggiante» posizionando l'elica alla giusta profondità nella membrana.

10.11 Modeling de novo / ab initio in dettaglio

Il modeling *de novo* non usa informazioni pregresse (né templati, né omologia): solo potenziali chimico-fisici (campi di forza empirici o quanto-meccanici) o potenziali statistici estratti dai database di strutture. La procedura generale, per i metodi **non** basati su AI:

Passo	Operazione
1	Frammentare la proteina in pezzetti piccoli, generalmente di 3–9 residui (a questo livello l'omologia non ha più senso: ci si affida alle proprietà chimico-fisiche, non alla derivazione evolutiva).
2	Modellare ogni frammento (con potenziali fisici o statistici).
3	Ricombinare i frammenti in tutti i modi possibili, generando moltissimi modelli candidati: i decoy (come ricomporre il mostro di Frankenstein).
4	Minimizzare l'energia di ogni decoy.
5	Clusterizzare i decoy in insiemi di strutture simili.
6	Prendere il cluster più popolato (più strutture simili = maggiore probabilità di fold corretto).
7	Generare la struttura media del cluster (o il centroide/medoide) e minimizzarla : è il modello più credibile.

10.11.1 I-TASSER

I-TASSER (gruppo di Yang Zhang) è un server web automatico (bassa interazione con l'operatore): si fornisce la struttura primaria e si ricevono i modelli via email. Si basa su **threading**, structure assembly, raffinamento e ricostruzione. Il suo algoritmo di *fold recognition* si chiama **MUSTER** e lavora su **profili** (proprietà degli amminoacidi, struttura secondaria, structural fragment profile, accessibilità al solvente, angoli ϕ/ψ , idrofobicità). I-TASSER è stato anche un **metaserver**: quando non riusciva da solo, distribuiva la sequenza ad altri server, raccoglieva le loro predizioni e le combinava in una metapredizione.

Nota — I-TASSER usa per lo scoring un campo di forza empirico classico (CHARMM22) e valuta, fra l'altro, il numero di legami a idrogeno. Punto cruciale: il numero di legami a idrogeno in assoluto non ha significato, perché dipende dal numero di amminoacidi della proteina (più residui = più legami potenziali). Va sempre normalizzato per il numero di amminoacidi. Vale per ogni metodo che usi i legami a idrogeno come indicatore di stabilità.

10.11.2 Rosetta / Robetta

Rosetta non è un singolo software ma una **suite** (come Maestro): un ambiente di più programmi per molecular modeling (docking, predizione di funzione, modeling). Il modulo che fa la predizione *ab initio* classica si chiama **Robetta**. Quindi: Rosetta = la suite, Robetta = il modulo.

Nota — Aneddoto: Anna Tramontano — una delle più importanti bioinformatiche al mondo, con cui il prof. Eberini ha lavorato — correggeva la pronuncia di David Baker, ricordando che il modulo si chiama Robetta e va distinto dalla suite Rosetta.

Robetta modella i frammenti con un metodo **Monte Carlo** e selezione di **Metropolis**: varia in modo casuale gli angoli ϕ/ψ del backbone dei pezzetti, minimizza l'energia e decide se tenere o scartare la struttura, ripetendo molti cicli. Il campo di forza si concentra sulle **interazioni a corto raggio** (van der Waals, legami a idrogeno, accessibilità al solvente); a lungo raggio considera solo l'elettrostatica (dipendente da distanza e dielettrico). Ha senso: in un modello a bassa accuratezza, è inutile calcolare con precisione l'interazione fra due atomi lontanissimi.

10.11.3 Le due componenti di van der Waals

Dispersiva e repulsiva. L'energia di van der Waals ha due componenti: una **dispersiva** (negativa, favorevole, dovuta alla distanza ottimale fra atomi) e una **repulsiva** (quando si avvicinano troppo, i raggi di van der Waals si sovrappongono e l'energia sale rapidamente). Valutare entrambe permette di evitare sia i **vuoti** sia i **clash** nel modello — gli stessi due difetti visti nell'allineamento slittato a inizio lezione.

10.12 AI ed essere critici

In conclusione: per la predizione *ab initio* oggi si usano le versioni di I-TASSER, Robetta o altri metodi di Rosetta che implementano l'intelligenza artificiale (es. AlphaFold, AlphaFold2). Metodi diversi si basano su assunzioni diverse: vanno scelti leggendone bene le differenze e i risultati vanno presi in modo **critico**. I metodi AI forniscono un'accuratezza per ciascun amminoacido, segnalando le zone più e meno affidabili.

Il messaggio finale sul modeling. L'homology modeling è il metodo **potenzialmente** più accurato, ma «potenzialmente» non significa «sempre». Un modello con il **70%** di identità di sequenza nell'allineamento query-templato è estremamente accurato; un modello con il **20%** è un modello ad allineamento critico. L'accuratezza dipende dalla qualità del templato, dalla qualità dell'allineamento, dall'identità/similarità di sequenza e dalla validazione geometrica. Siate sempre critici.

Lezione 11

Pratica MOE: ottimizzazione razionale dell'anticorpo CNT-O627 e Antibody Modeler

Maggio 2026 — Undicesima lezione — Sessione pratica/demo

11.1 Il caso: CNT-O627, un anticorpo anti-IL-13

Lezione pratica condotta in diretta sul software **MOE**. L'anticorpo di studio è il **CNT-O627**, un anticorpo monoclonale **anti-interleuchina 13**. L'IL-13 è un mediatore importante nell'asma e nelle malattie allergiche; l'idea è neutralizzarla con l'anticorpo. È disponibile un cristallo in cui l'anticorpo è stato **co-cristallizzato con l'IL-13**, utile per studiare il riconoscimento antigene-anticorpo e per modificare l'anticorpo.

11.2 Preparazione della struttura

Caricato il file strutturale, si esegue la **Quick Preparation** di MOE. Si toglie il *fix* (per permettere il rilassamento dell'**intera** struttura, non solo del sito di legame) e si rimuovono i restraint dopo il calcolo. Questa fase è sempre fondamentale: identifica atomi, catene laterali e residui mancanti, aggiunge gli idrogeni, corregge lo stato di protonazione e rilassa il sistema. Si può fare step-by-step o automaticamente.

11.3 Le catene della struttura

La struttura contiene tre catene più un glicano:

- La catena **L** (leggera).
- La catena **pesante**.
- L'**antigene** (IL-13).
- Un composto di **zuccheri** (glicano) attaccato alla catena pesante, parte della glicosilazione, qui non rilevante per lo studio.

*Nota — In questo cristallo manca il frammento Fc cristallizzabile: la struttura è sostanzialmente **Fab** + **antigene**.*

11.4 Annotazione e CDR

Come già fatto per GPR17, si usa lo strumento di lettura della struttura primaria e riconoscimento delle particolarità. Per gli anticorpi, essendo estremamente studiati, esistono diversi metodi di **numerazione e annotazione**. Annotato l'anticorpo, MOE lo divide in tre finestre (catena leggera, catena pesante, antigene), evidenziando in ciascuna gli amminoacidi che costituiscono i **CDR**.

CDR (Complementarity-Determining Regions). La parte ipervariabile del framework variabile. Sono sei: tre sulla catena leggera (in viola nella visualizzazione) e tre sulla catena pesante (due in arancione, uno — **H3** — in rosso). L'H3 è evidenziato diversamente perché è il più variabile e il più critico da modellare.

Colorando l'antigene in oro si vede bene che l'interazione antigene-anticorpo avviene, come atteso, proprio attraverso i sei CDR (tre della leggera, tre della pesante).

11.5 Analisi dei contatti all'interfaccia

Con lo strumento di valutazione dei **contatti** si confronta il set «anticorpo» con il set «antigene», ordinando per energia. Le interazioni si dividono in due blocchi:

Blocco	Natura	Dettaglio
Carico	Ponti salini	Cinque acidi aspartici dell'anticorpo (carichi negativamente, energie molto favorevoli) che interagiscono con arginine e lisine dell'antigene (cariche positive).
Idrofobico	Interazioni idrofobiche	Aminoacidi come alanina, metionina, triptofano all'interfaccia di riconoscimento.

11.5.1 L'interazione chiave

L'interazione energeticamente più importante: un'**arginina** dell'antigene viene «pinzata» fra due aspartati dell'anticorpo, **Asp 49** (sul CDR della catena leggera) e **Asp 106** (sul CDR3 della catena pesante). Ordinando per frequenza emerge anche una prolina che interagisce con una lisina (interazione idrofobica).

11.6 Il problema dell'aggregazione

Durante lo sviluppo, il CNT-O627 mostrava un grave difetto: una volta somministrato tendeva a **precipitare**. I precipitati si accumulavano nei reni, innescando reazioni infiammatorie critiche. La causa: un'estesa **patch idrofobica** superficiale che favorisce l'aggregazione.

11.7 Mappatura della superficie di riconoscimento

Si genera la **superficie molecolare** e la si colora secondo diverse proprietà:

- Per **carica elettrostatica**: eccesso di cariche negative in rosso, positive in blu. La superficie di riconoscimento mostra una grande area fortemente **negativa** (le piazze di aspartati che interagiscono con le arginine/lisine dell'antigene).
- Per **idrofobicità/lipofilia**: si evidenzia una netta **patch idrofobica**.

Lo strumento di analisi delle patch. Mappa sulla superficie le aree con caratteristiche particolari, colorandole: verde per le zone idrofobiche, rosso per gli eccessi di carica negativa, blu per gli eccessi di carica positiva. L'interfaccia di riconoscimento risulta composta da una **patch idrofobica** e una **zona carica**. La patch idrofobica è il problema: fa aggregare e precipitare l'anticorpo.

*Nota — Le patch vengono rilevate solo sopra certe soglie di dimensione ed energia (per le idrofobiche, indicativamente oltre $\sim 50 \text{ \AA}^2$ di superficie e una certa soglia energetica). Il prof. Eberini precisa che i valori esatti **non vanno memorizzati**: conta capire che una patch è definita da una dimensione minima e una soglia energetica.*

11.8 La strategia di ottimizzazione duale

L'obiettivo è lavorare attorno alle due caratteristiche (superficie negativa e patch idrofobica) per ottenere due risultati:

Direzione	Obiettivo	Beneficio
1	Ridurre l'estensione della patch idrofobica sostituendo alcuni amminoacidi idrofobici.	Minore aggregazione e precipitazione.
2	Migliorare l'affinità dell'anticorpo per l'antigene.	Dose somministrata più bassa → minore concentrazione circolante → minore probabilità di aggregazione.

11.9 Il calcolatore di proprietà e la metionina 92

Lo strumento **Compute Properties** calcola una grande quantità di proprietà molecolari, mostrabili per l'intera proteina (Property Viewer) o per ogni residuo (Residue Table). Classificando i residui per **esposizione al solvente** emerge la **metionina 92**, un amminoacido idrofobico esposto in superficie, già fra quelli che costituiscono la patch idrofobica.

*Nota — Bonus diagnostico: fra le proprietà calcolate c'è anche l'ossidabilità delle metionine esposte. La Met 92 è anche ossidabile: oltre al problema di idrofobicità, è un punto di **invecchiamento rapido** del farmaco biotecnologico. Sostituirla risolve entrambi i problemi.*

11.10 Mutagenesi manuale: Glu vs Asp al posto di Met 92

Per le mutazioni si usano due «scene» salvate (snapshot) che consentono confronti rapidi senza ricostruire ogni volta. La mutazione si fa col **builder** (manuale) oppure col protocollo automatico di mutagenesi con affinità (come fatto per le due lisine della β -lattoglobulina).

Si suggerisce di mutare la metionina (idrofobica) con un amminoacido **carico e idrofilo**. Acido aspartico o glutamico? La differenza sembra minima ma non lo è:

Asp vs Glu: un metilene di differenza. L'acido glutamico ha un gruppo CH_2 (metilene) in più nella catena rispetto all'aspartico. Una catena più lunga = più gradi di libertà: il glutammato può riorganizzarsi in modo più articolato e raggiungere più partner di interazione.

Sostituendo Met 92 con **acido glutamico** e minimizzando la catena laterale, il glutammato si riorienta e forma **due** interazioni con gli azoti delle asparagine dell'antigene (più forte con **Asn 23**, più debole con **Asn 19**): si rompe la patch idrofobica e contemporaneamente si inserisce un'interazione molto buona. Si salva il mutante **M92E**.

Provando invece con l'**acido aspartico**: la catena, più corta, non consente alla testa carbossilica di riorientarsi per fare entrambe le interazioni; raggiunge Asn 23 ma lascia scoperta Asn 19. Entrambi rompono la patch, ma il **glutammato** fa doppia interazione, l'aspartato singola: l'anticorpo con glutammato legherà una quantità maggiore di antigene.

11.11 Mutagenesi automatica con calcolo di affinità

Si identificano col sequence viewer gli amminoacidi rilevanti: oltre alla metionina, anche una **valina** sulla stessa superficie. L'idea è mutarle entrambe per ridurre ulteriormente il rischio di aggregazione.

Anziché provare tutte e 19 le possibilità, si ragiona:

Residuo	Strategia	Razionale
Met 92	Provare tutti gli amminoacidi tranne gli idrofobici (opzione «except hydrophobic»).	Serve qualcosa di idrofilo per rompere la patch.

Residuo	Strategia	Razionale
Valina	Scegliere un idrofilo di dimensione simile alla valina (né troppo grande né troppo piccolo) → treonina .	Mantenere l'ingombro ma togliere l'idrofobicità. La serina è troppo piccola, la tirosina troppo grande e poco idrofila; la treonina ha l'OH ed è di dimensione adatta.

Attivando il pulsante **Affinity**, MOE riconosce automaticamente l'antigene e, generati i mutanti, calcola come cambia l'affinità dell'anticorpo. Tutto il lavoro fatto prima a mano viene così automatizzato. Si generano **22 mutanti** (il wild-type e le combinazioni).

Il mutante migliore. La combinazione ottimale risulta **arginina** al posto della metionina e **treonina** al posto della valina, con un $\Delta\text{Affinity} \approx -4,4 \text{ kcal/mol}$. Sorprendentemente, al posto della metionina funzionano sia amminoacidi acidi (Asp, Glu) sia basici (Arg): l'arginina rompe ugualmente la patch idrofobica ma fa interazioni ancora più rilevanti del glutammato. La conferma definitiva spetta comunque ai test di laboratorio.

11.12 Il messaggio: rational design

Si è partiti da una molecola bioattiva (l'anticorpo originale funziona) con caratteristiche non ideali, e con due strategie parallele — eliminare la patch idrofobica e migliorare l'affinità per ridurre la dose — si è ottenuto un anticorpo meno idrofobico, meno incline ad aggregare, più affine. Tutto il lavoro è fatto **in silico**; solo i mutanti finali si generano e si testano in laboratorio.

Non immaginatevi più lo sciame di pipettatori di quando ero giovane: oggi nei laboratori di drug development avanzato tutto passa attraverso il rational design, capire le caratteristiche e i motivi del difetto e cercare di risolverli.

11.13 L'Antibody Modeler di MOE

L'ultima parte mostra il **modellare** degli anticorpi. Pur con alcune specificità, funziona come l'homology modeling già visto per le altre proteine. Le premesse:

- Il **framework** ha caratteristiche strutturali conservate (pattern di folding ben noto).
- La parte variabile sono i **sei CDR** (3 catena leggera, 3 catena pesante).

Comportamento dei sei loop CDR. Cinque loop — L1, L2, L3 (catena leggera) e H1, H2 (catena pesante) — assumono un numero **ristretto** di conformazioni e sono prevedibili. L'**H3** è il più complicato: assume molte più conformazioni ed è il più critico da modellare (spesso de novo, via dinamica molecolare, se non si trova un loop simile nel database).

Si parte dalla sequenza FASTA del framework variabile: due sequenze, **VL** (catena leggera) e **VH** (catena pesante). I software commerciali con Antibody Modeler contengono un **dataset dedicato** di anticorpi del PDB, già elaborati: riconoscono automaticamente VL e VH, propongono i template di framework con punteggio di identità (di varie specie, soprattutto umana e murina) e selezionano automaticamente i CDR (modificabili manualmente). Per ogni CDR si vedono percentuale di similarità/identità, specie, numerosità del cluster, risoluzione e sequenza. Si sceglie il framework migliore (il più conservato) e si genera il modello.

11.14 Rimozione di un sito di glicosilazione

Sul modello generato si possono riconoscere i **siti di N-glicosilazione**, che negli anticorpi hanno un pattern riconoscibile (motivo **PROSITE N-X-S/T**: un'asparagina seguita, due posizioni dopo, da una serina o treonina, in una sequenza esposta al solvente). Trovato un sito, per bloccare la glicosilazione si può sostituire uno degli amminoacidi del pattern.

Usare le statistiche degli anticorpi noti (Protein Search). Poiché gli anticorpi sono super-studiati, invece di una mutagenesi alla cieca si interroga un **database di anticorpi noti** (Protein Search) e si guarda statisticamente quale amminoacido ricorre in quella posizione nell'allineamento multiplo. Nel caso mostrato, dove c'era una **serina** (Ser 95, che nell'allineamento multiplo corrisponde alla posizione 115), nella maggior parte degli anticorpi c'è in realtà una **prolina**.

Si può quindi mutare la serina in **prolina** con due certezze: (i) l'anticorpo **non si destabilizzerà**, perché la prolina è quella più frequente in quella posizione; (ii) la **glicosilazione non avverrà più**, perché il riconoscimento dell'enzima richiede la serina/treonina due posizioni dopo l'asparagina, e rimuovendola il motivo non è più valido.

11.15 Verso la Lezione 12

La glicosilazione degli anticorpi non è un dettaglio: cambia le proprietà dell'anticorpo, la sua struttura tridimensionale, la capacità di interagire con gli antigeni e di **trasmettere il segnale ai recettori Fc**. Sarà proprio il tema della lezione successiva, tenuta dal dott. Davide Bassani sullo studio di dinamica molecolare delle glicoforme anticorpali.

Sintesi delle Lezioni 10–11. La Lezione 10 ha completato la teoria del modeling (allineamento globale esatto, rigid body assembly, validazione, CASP, threading, de novo/ab initio con Rosetta e I-TASSER, proteine transmembrana). La Lezione 11 ha mostrato in pratica, su MOE, come tutta questa cassetta degli attrezzi si applichi al **rational design** di un anticorpo terapeutico reale (CNT-O627), ottimizzandone affinità e proprietà biofisiche e modellandone framework, CDR e siti di glicosilazione.

Lezione 12

Caso di studio: dinamica molecolare delle glicoforme anticorpali e ruolo del dominio Fc

Maggio 2026 — Dodicesima lezione — Seminario di ricerca sulla MD applicata agli anticorpi

Nota — Questa lezione è un seminario di ricerca che applica le tecniche di dinamica molecolare introdotte nella Lezione 8 al caso reale dell'ottimizzazione di anticorpi monoclonali anticipato nella Lezione 11. Il contenuto è stato ricostruito dalla trascrizione automatica WhisperX, decodificando la terminologia tecnica resa imperfettamente dal sistema di speech-to-text. Dove la trascrizione era troppo degradata, i passaggi sono stati integrati con la logica scientifica del discorso; tali integrazioni sono coerenti con la letteratura sul tema ma vanno verificate sul materiale ufficiale del corso.

12.1 Richiamo strutturale: domini Fab, Fc e regione cerniera

La lezione riprende l'architettura dell'anticorpo introdotta nella Lezione 11. Dal punto di vista strutturale, l'immunoglobulina è composta da due catene pesanti e due catene leggere tenute insieme da ponti disolfuro. Dal punto di vista **funzionale**, queste catene si organizzano in due tipi di dominio:

- Il **dominio Fab** (Fragment antigen-binding), responsabile del riconoscimento dell'antigene.
- Il **dominio Fc** (Fragment crystallizable), responsabile del riconoscimento da parte dei meccanismi effettori del sistema immunitario (recettori Fc sulle cellule effettrici).

Regione cerniera (hinge). I domini Fab e Fc sono uniti da una **regione non strutturata** (la cerniera), altamente flessibile. La flessibilità della cerniera consente ai due Fab di muoversi rispetto all'Fc, adattandosi al riconoscimento dell'antigene. La regione cerniera è il principale snodo conformazionale dell'intera molecola.

12.2 I due livelli di interazione immunitaria

Un anticorpo media due interazioni distinte e sequenziali:

Livello	Dominio coinvolto	Funzione
Interazione primaria	Fab (regioni variabili / CDR)	Riconoscimento e legame dell'antigene.
Interazione secondaria	Fc	Reclutamento delle cellule effettrici del sistema immunitario, che riconoscono il complesso antigene-anticorpo tramite i recettori Fc e innescano la distruzione della cellula bersaglio (es. ADCC).

Questa seconda interazione è di particolare rilevanza in ambito **oncologico**: oltre a riconoscere il bersaglio patologico, l'anticorpo permette di innescare l'eliminazione tramite il sistema immunitario dell'ospite. La funzionalità del dominio Fc, e con essa la capacità di reclutare gli effettori, è **fortemente regolata dalla glicosilazione**.

12.3 Glicosilazione del dominio Fc e sottopopolazioni

Il dominio Fc porta una glicosilazione conservata (sull'Asn 297 della catena pesante) che modula in modo determinante l'attività effettrice. Anche un anticorpo con una singola sequenza primaria esiste in realtà come **miscela di glicoforme**, ciascuna con comportamento biologico differente.

Nelle rappresentazioni grafiche standard dei glicani (nomenclatura SNFG), i simboli colorati indicano i diversi monosaccaridi: il **quadrato blu** indica la N-acetilglucosammina (GlcNAc), il **cerchio** il mannosio/galattosio, il **triangolo rosso** il fucosio. La presenza o assenza del fucosio sul core del glicano è il fattore con il maggiore impatto sull'attività anticorpale:

Glicoforma	Caratteristica del glicano	Impatto funzionale
Fucosilata	Fucosio presente sul core (forma più abbondante in natura).	Affinità standard per FcγRIIIa; ADCC di base.
Afucosilata	Fucosio assente.	Affinità marcatamente aumentata per FcγRIIIa; ADCC potenziata .
Aglicosilata	Glicano assente del tutto (es. mutante N297A).	Perdita dell'interazione con i recettori Fc; anticorpo solo neutralizzante , senza funzione effettrice.

Nota — Le librerie di glicani possono essere incluse nei modelli, sia nel Fab sia nell'Fc. Il controllo della glicosilazione è centrale anche nello sviluppo di prodotti vaccinali e nella progettazione di anticorpi terapeutici: residui conservati della cerniera e del sito di glicosilazione, identificati già in letteratura negli anni Novanta, fanno la differenza nella quantità e nella qualità della produzione e dell'attività biologica.

12.4 Impostazione dello studio di dinamica molecolare

L'obiettivo dello studio è capire, a livello molecolare, **come la glicosilazione del dominio Fc influisca sul comportamento conformazionale dell'intero anticorpo**, senza limitarsi al solo Fc: modifiche locali a livello dell'Fc possono infatti propagarsi e impattare l'intera struttura.

12.4.1 Scelta della struttura di partenza

Si parte da una **struttura sperimentale completa** di un anticorpo (con tutti i domini risolti, inclusa la cerniera). La disponibilità di una struttura intera, e non solo di frammenti Fab o Fc isolati, è essenziale per studiare il movimento relativo dei domini. La struttura risolta sperimentalmente viene preparata con i passaggi standard (aggiunta idrogeni, protonazione, eventuale ricostruzione di loop mancanti).

12.4.2 Campi di forza e parametrizzazione dei glicani

Come discusso nella Lezione 8, il calcolo dell'energia potenziale richiede un campo di forze. Per le **proteine** (i nostri amminoacidi naturali) la parametrizzazione è robusta e consolidata. Il problema sorge per le componenti non standard:

- Esistono campi di forza **generici** che contengono parametri per molte situazioni chimiche.
- Esistono campi di forza **specifici** per le piccole molecole (ligandi, farmaci).
- La parametrizzazione dei **glicani** è complessa: i carboidrati hanno una grande flessibilità conformazionale e richiedono campi di forza dedicati (es. GLYCAM) per essere simulati correttamente.

12.4.3 Solvatazione esplicita ed equilibratura

Il sistema viene immerso in una box di **solvente esplicito** (molecole d'acqua reali). Si procede con l'**equilibratura** graduale del sistema, riducendo progressivamente i vincoli (*restraint*) imposti inizialmente sulle posizioni atomiche: tipicamente da forze di vincolo elevate, poi intermedie, fino a meno di 1 kcal/mol·Å², e infine la fase di **produzione** libera. Per ciascun sistema (ciascuna glicoforma) si eseguono più repliche di simulazione, in modo da valutare la riproducibilità statistica dei risultati.

12.5 Analisi della traiettoria: stabilità globale

Le prime analisi mirano a verificare che le simulazioni siano stabili e correttamente equilibrate, prima di estrarre conclusioni biologiche.

12.5.1 RMSD

Si calcola l'**RMSD** (Root Mean Square Deviation) rispetto alla struttura iniziale, dapprima su tutti i **carboni** α dell'intera proteina:

- Valori di RMSD più alti indicano maggiori cambiamenti conformazionali rispetto al riferimento.
- Quando l'RMSD raggiunge un **plateau** e vi si mantiene, il sistema è equilibrato: si può individuare l'inizio della fase di produzione utile per l'analisi e scartare la fase transitoria iniziale.

*Nota — L'RMSD calcolato su **tutti** i carboni α misura il comportamento globale ma può mascherare cambiamenti locali. Differenze di posizione concentrate in un dominio possono essere diluite nella media globale. Per questo si procede ad analisi più fini, dominio per dominio.*

12.5.2 RMSF

RMSF (Root Mean Square Fluctuation). Misura la **fluttuazione media di ciascun singolo residuo** rispetto alla sua posizione media durante la simulazione. Mentre l'RMSD misura quanto l'intera struttura si discosta dal riferimento nel tempo, l'RMSF identifica **quali residui** sono più mobili. Valori alti = regioni flessibili (loop esposti, terminali, cerniera); valori bassi = regioni rigide (core strutturale).

L'analisi RMSF residuo-per-residuo permette di confrontare le diverse glicoforme e di localizzare le differenze di flessibilità: ad esempio, regioni che nella forma afucosilata fluttuano diversamente rispetto alla forma fucosilata.

12.5.3 Raggio di girazione

Il **raggio di girazione** (R_g) misura la **compattezza globale** della molecola. Confrontando le glicoforme:

- La forma **nativa/abituale** e la forma di confronto risultano globalmente **compatte** (R_g contenuto).
- La forma modificata (es. aglicosilata) mostra un R_g **maggiore**: l'anticorpo è globalmente meno compatto.

Significato funzionale della compattezza. La letteratura indica che **conformazioni più compatte e chiuse dell'Fc portano a una riduzione dell'attività effettrice**. La compattezza dell'Fc e l'arrangiamento relativo dei domini sono quindi descrittori meccanicisticamente legati alla funzione: misurarli in simulazione permette di prevedere l'impatto funzionale di una modifica.

12.6 Descrittori geometrici dedicati

Poiché le metriche globali (RMSD, R_g) non catturano completamente i movimenti relativi dei domini, si introducono **descrittori geometrici dedicati**, costruiti su siti conservati in tutti i sistemi confrontati.

12.6.1 Distanza fra i domini

Identificato un **sito conservato** (un punto di riferimento presente in tutte le glicoforme), si calcola la **distanza** fra i due domini di interesse (per esempio fra i due Fab, o fra Fab e Fc) lungo l'intera traiettoria. L'andamento di questa distanza nel tempo descrive se i domini si avvicinano o si allontanano, ossia se l'anticorpo tende a chiudersi o ad aprirsi.

12.6.2 Angoli e movimento relativo

Oltre alla distanza, si misurano gli **angoli** che descrivono l'orientamento relativo dei domini: quanto e come un dominio ruota rispetto all'altro. Combinando distanza e angolo si ottiene una descrizione quantitativa del movimento conformazionale (avvicinamento, allontanamento, rotazione, apertura/chiusura).

Nella forma **aglicosilata**, in particolare, i domini Fab risultano più mobili e meno vincolati: ciò è coerente con una minore affidabilità del riconoscimento da parte dei recettori Fc e con un valore di R_g maggiore (struttura più aperta).

12.6.3 Quantificare apertura e chiusura

L'obiettivo finale di questi descrittori è **quantificare** quanto una conformazione è «aperta» e quanto è «chiusa», poiché questo impatta direttamente l'attività mediata dai recettori effettori. Si confrontano così le diverse glicoforme su una scala continua di apertura conformazionale, anziché con categorie qualitative.

12.7 Ruolo delle molecole d'acqua strutturali

Un livello di dettaglio ulteriore riguarda il ruolo delle **molecole d'acqua** nel stabilizzare la struttura.

12.7.1 Identificazione delle acque strutturali

Si analizzano le **interazioni mediate dall'acqua** (ponti a idrogeno acqua–proteina) all'interfaccia fra i glicani e la proteina, e nelle cavità interne. Con metodi di analisi della densità di solvente si stima dove le molecole d'acqua tendono a organizzarsi stabilmente, formando una sorta di rete di legami a idrogeno che cementa la struttura.

12.7.2 Effetto stabilizzante

Si valuta poi se la presenza di acqua in posizioni cristallografiche o ricorrenti abbia un **effetto stabilizzante**, analizzando l'energetica del sistema. Il risultato osservato:

- La forma **fucosilata/glicosilata** presenta un **maggior numero di molecole d'acqua stabilizzanti** che occupano e cementano l'interfaccia, contribuendo alla compattezza e alla stabilità del dominio Fc.
- La forma **aglicosilata** presenta un numero **minore** di molecole d'acqua strutturali: con meno acque stabilizzanti, la struttura è più libera, meno compatta e meno vincolata.

Catena di causalità ricostruita. Glicano (fucosio) presente → più acque strutturali stabilizzanti all'interfaccia → Fc più compatto e ordinato → arrangiamento dei domini favorevole all'interazione con i recettori Fc → attività effettrice preservata/modulata. La rimozione del glicano spezza questa catena a monte.

12.8 Dinamica accelerata: oltre la MD classica

Il primo studio descritto utilizza **dinamica molecolare classica**. Un secondo studio aggiunge la **dinamica molecolare accelerata** (aMD), introdotta concettualmente nella Lezione 8.

12.8.1 Perché serve l'accelerazione

Nella MD classica, anche estendendo le simulazioni a 300–400 nanosecondi, le oscillazioni conformazionali rilevanti possono restare limitate: il sistema appare stabile (RMSD a plateau) ma esplora solo localmente la superficie di energia potenziale, senza superare le barriere che separano conformazioni alternative. Si fatica quindi a distinguere se due glicoforme differiscono davvero nel comportamento conformazionale o se semplicemente non si è campionato abbastanza.

Quando il sistema è stabile vediamo comunque delle oscillazioni, perché le catene laterali si muovono; ma le grandi transizioni dei domini, con la dinamica classica, restano fuori portata.

12.8.2 Come opera l'aMD

L'aMD aggiunge un **potenziale di boost** che innalza i minimi della superficie di energia potenziale, **abbassando di fatto le barriere** fra conformazioni. Il sistema può così attraversare barriere altrimenti invalicabili ed esplorare un numero molto maggiore di conformazioni, comprese quelle a energia più bassa e quindi più stabili e più vicine alla realtà fisica.

Per descrivere le conformazioni esplorate si usano gli **angoli diedri** che catturano l'orientamento globale dei domini. Proiettando le conformazioni su questi angoli si costruisce una mappa dell'energia libera (un paesaggio di minimi) e si identificano i prodotti conformazionali più stabili, che la MD classica non aveva raggiunto.

12.8.3 Risultato: il fucosio aumenta la mobilità dei Fab

L'analisi accelerata rivela un effetto chiave del fucosio sul comportamento globale dell'anticorpo:

Effetto del fucosio sulla dinamica dei Fab. In presenza di **fucosio**, i domini **Fab** risultano più mobili: hanno una maggiore capacità di ruotare attorno alla cerniera e una maggiore tendenza al cambiamento conformazionale. Questa mobilità potrebbe tradursi in una diversa modalità di interazione con l'antigene rispetto alle forme prive di fucosio.

Si confrontano così, su base energetica, i minimi conformazionali delle diverse glicoforme: il livello energetico più stabile e la sua collocazione cambiano a seconda della presenza/assenza del glicano e del fucosio, sia in presenza sia in assenza dell'antigene.

12.9 Dalla descrizione globale all'analisi per residuo

Avendo caratterizzato il comportamento globale (RMSD, R_g , descrittori di dominio, energetica aMD), si procede al dettaglio atomico per spiegare **perché** si osservano le differenze.

- Si analizzano le **interazioni specifiche** fra glicano e proteina (es. fra residui dell'Fc e il glicano), e fra i residui delle interfacce dei domini, mediante mappe di contatto.
- Si identificano i **residui chiave** la cui presenza o il cui contatto, in determinati frame della simulazione, modificano il comportamento dell'anticorpo, restringendo l'arrangiamento dei domini verso conformazioni più compatte o più aperte.

Nota — Il flusso metodologico è lo stesso enunciato nella Lezione 11 per il caso CNT-O627: si parte da osservazioni globali (aggregazione, attività, compattezza), si scende al dettaglio molecolare per individuare i residui e le interazioni responsabili, e si usa questa conoscenza per guidare l'ingegnerizzazione razionale dell'anticorpo.

12.10 Implicazioni per l'ingegneria degli anticorpi terapeutici

Il messaggio conclusivo del seminario è che lo studio computazionale delle glicoforme non è puramente descrittivo, ma uno strumento di **ingegneria razionale**. Conoscendo come ciascuna glicoforma si comporta dal punto di vista conformazionale e di interazione con i recettori Fc, si può scegliere deliberatamente la glicoforma ottimale per uno specifico obiettivo terapeutico:

Obiettivo terapeutico	Glicofoma da privilegiare	Razionale
Massimizzare la distruzione delle cellule bersaglio (es. oncologia)	Afucosilata	Massima affinità per FcγRIIIa, massima ADCC: il sistema immunitario è reclutato a eliminare la cellula.
Neutralizzare l'antigene senza attivare gli effettori (es. alcune autoimmunità)	Aglicosilata	Nessuna interazione con i recettori Fc: l'anticorpo blocca il bersaglio senza innescare lisi cellulare.
Modulare finemente affinità e stabilità	Glicoforme intermedie	Si bilancia mobilità dei Fab, compattezza dell'Fc e stabilità mediata dalle acque strutturali.

Non analizziamo ciascun amminoacido della struttura uno per uno: descriviamo il comportamento globale dei domini, e solo dove serve scendiamo nel dettaglio del singolo residuo. L'obiettivo è trovare, in base alla situazione clinica, la migliore alternativa fra le glicoforme disponibili.

Sintesi della Lezione 12. La glicosilazione del dominio Fc — e in particolare la presenza/assenza del **fucosio** — controlla la compattezza dell'Fc, la mobilità dei Fab, la rete di acque strutturali stabilizzanti e, in ultima analisi, l'attività effettrice dell'anticorpo. La dinamica molecolare classica caratterizza la stabilità; la dinamica accelerata rivela le transizioni conformazionali altrimenti inaccessibili. L'insieme di queste analisi fornisce la base razionale per scegliere e ingegnerizzare la glicofoma anticorpale ottimale per ogni contesto terapeutico.

Glossario tecnico

Termini chiave del corso, ordine alfabetico

AlphaFold

Algoritmo di predizione strutturale basato su reti neurali profonde (DeepMind, 2020). Ha trasformato la predizione di proteine senza template omologhi noti, vincendo CASP14 con margine storico. Usa allineamenti multipli, informazioni co-evolutive e predizione di mappe di contatto. Confidenza locale espressa con il punteggio pLDDT.

Allineamento globale

Allineamento che copre l'intera lunghezza di entrambe le sequenze. Algoritmo classico: Needleman–Wunsch (programmazione dinamica). Necessario per il modeling per omologia.

Allineamento locale

Allineamento che identifica le regioni di massima similarità fra due sequenze, ignorando il resto. Algoritmo classico: Smith–Waterman. BLAST usa allineamenti locali euristici.

Allineamento multiplo (MSA)

Allineamento simultaneo di tre o più sequenze omologhe. Strumenti: Clustal, MUSCLE, T-Coffee. Permette di identificare residui conservati e firme di famiglia.

Architettura

Modo di folding di una proteina, considerato a livello di famiglia/superfamiglia. Distinta dalla struttura (posizione precisa degli atomi).

ARTC2.2 / NICD

Acronimo che ricorre in alcune trattazioni di immunometabolismo: ART transferase / NAD-induced cell death. Meccanismo mouse-specifico, non rilevante per il presente corso ma utile come memoria di contesto biologico del prof. Grassi (gruppo di appartenenza dello studente).

BLAST (Basic Local Alignment Search Tool)

Algoritmo euristico, locale e veloce per cercare omologhi in un database. Frammenta la query in parole, le cerca nel database, estende i match in HSP. Versione standard: Gapped BLAST.

BLOSUM

Famiglia di matrici di sostituzione osservazionali (Henikoff & Henikoff, 1992). BLOSUM62 è la matrice standard di BLAST. Più è alto il numero, più alta era l'identità di sequenza delle proteine usate per costruirla.

CASP

Critical Assessment of protein Structure Prediction. Competizione internazionale biennale di predizione strutturale in cieco.

CATH

Database di classificazione gerarchica dei domini strutturali del PDB: Class (composizione di struttura secondaria), Architecture, Topology, Homologous superfamily.

CDR (Complementarity-Determining Regions)

Le sei regioni ipervariabili di un anticorpo (tre sulla catena leggera, tre sulla catena pesante) che, nello stato foldato, formano il paratopo per il riconoscimento dell'antigene.

Comparative modeling

Sinonimo di homology modeling. Costruzione di un modello tridimensionale a partire dal template omologo di struttura nota.

Dayhoff (matrici PAM)

Margaret Dayhoff sviluppa nel 1978 le matrici di sostituzione PAM, fondamento storico della bioinformatica. PAM1 è osservazionale; le altre PAM sono ottenute moltiplicando matematicamente PAM1 per se stessa.

Distant homolog

Proteina omologa con bassa identità di sequenza (tipicamente $< 25\%$). La relazione di omologia esiste ma è difficile da stabilire e da sfruttare per il modeling accurato.

Dot plot

Matrice di confronto sequenza–sequenza con punteggio binario (match/mismatch). Rivela diagonal principali, gap, ripetizioni interne e palindromi.

DSSP

Dictionary of Secondary Structure of Proteins (Kabsch & Sander, 1983). Metodo storico di predizione della struttura secondaria basato su dizionario di frammenti. Accuratezza $\sim 70\%$.

E-value

Expected value: numero atteso di allineamenti casuali con punteggio uguale o superiore al nostro in un dato database. Più piccolo, più significativo. Soglia operativa: $E < 0,02$.

Enhanced sampling

Famiglia di metodi (Accelerated MD, Metadynamics, Replica Exchange) che permettono di esplorare regioni della superficie di energia potenziale altrimenti inaccessibili alla MD classica.

FASTA

Formato standard per sequenze biologiche. Prima riga $>$ con intestazione, righe successive con la sequenza. Anche nome del software omonimo (Pearson & Lipman, 1988).

Force field (campo di forze)

Insieme di equazioni e parametri che permettono di calcolare l'energia potenziale di un sistema molecolare. Esempi: AMBER, CHARMM, OPLS, GROMOS.

Gap (indel)

Spazio inserito in un allineamento per gestire un'inserzione o una delezione fra due sequenze. Penalizzato nel calcolo del punteggio di allineamento.

Generalized Born (GB)

Modello di solvatazione implicita che simula sia l'effetto dielettrico dell'acqua sia l'energia di solvatazione superficiale. Compromesso fra realismo e velocità.

GPCR (G-protein-coupled receptor)

Recettore di membrana a sette eliche transmembrana. Più grande famiglia di recettori farmacologici (40%+ dei farmaci agiscono su GPCR). Classe A: la più numerosa, include GPR17.

Gumbel distribution

Distribuzione dei valori estremi che descrive la distribuzione dei punteggi di allineamento locale di una query contro un grande database casuale. Asimmetrica, con coda destra.

HMM (Hidden Markov Model)

Modello probabilistico con stati nascosti e simboli emessi. In bioinformatica: apprende il pattern caratteristico di una famiglia di proteine; usato per classificazione e allineamento.

Homology modeling

Costruzione di un modello strutturale di una proteina usando come template la struttura sperimentale di una proteina omologa. Metodo più accurato disponibile quando esiste un template di qualità.

HSP (High Scoring Segment Pair)

Coppia di segmenti ad alto punteggio prodotta da BLAST. Allineamento locale di una porzione della query con una porzione di una sequenza del database.

Identità di sequenza

Percentuale di posizioni in cui due sequenze allineate hanno lo stesso amminoacido. Indicatore quantitativo surrogato dell'omologia.

Lipocalina

Famiglia di proteine, contiene la β -lattoglobulina. Architettura: foglietto β classico (otto strand antiparalleli che formano un calice) + α -elica.

Loop EF

Loop conformazionalmente flessibile della β -lattoglobulina che connette i foglietti β E ed F. Responsabile della transizione di Tanford: chiuso a pH acido, aperto a pH basico.

MOE (Molecular Operating Environment)

Software professionale di Chemical Computing Group per bioinformatica strutturale, drug design e modeling di anticorpi. Strumento principale dimostrato nel corso.

Omologia

Relazione filogenetica fra geni o proteine derivati da un comune antenato evolutivo. Concetto qualitativo (sì/no), non quantitativo. Sottoclassi: ortologia, paralogia, xenologia.

Ortologia

Sotto-tipo di omologia: stessa proteina/funzione in specie diverse. Es. albumina umana e bovina.

PAM (Percent Accepted Mutation)

Famiglia di matrici di sostituzione di Dayhoff. PAM1 = 1% di mutazione accettata. Altre PAM (PAM30, PAM80, ..., PAM250) ottenute matematicamente.

Paralogia

Sotto-tipo di omologia: proteine omologhe nella stessa specie, derivate da duplicazione genica. Es. LCAT e ACAT nell'uomo.

Paratopo

Superficie di un anticorpo che riconosce e lega l'antigene. Formata dai 6 CDR raggruppati spazialmente.

PDB (Protein Data Bank)

Unico database mondiale di strutture macromolecolari risolte sperimentalmente. Tre mirror: RCSB (USA), PDBe (Europa), PDBj (Giappone).

Perceptrone

Neurone artificiale elementare delle reti neurali. Riceve input pesati, li somma, e si attiva (in modo binario o sigmoidale) se la somma supera una soglia.

Periodic Boundary Conditions (PBC)

Strategia in MD: la box di simulazione viene replicata infinitamente; molecole che escono da un lato rientrano dall'altro. Evita artefatti di parete.

Ponte disolfuro

Legame covalente fra le catene laterali di due cisteine in stato ossidato. Stabilizza la struttura terziaria; conservato nei GPCR di classe A (loop extracellulare 2 $\leftrightarrow$ elica TM3).

Programmazione dinamica

Strategia matematica per trovare l'allineamento ottimale fra due sequenze senza provare tutti gli allineamenti possibili. Needleman–Wunsch (globale), Smith–Waterman (locale). Origine: crittoanalisi militare.

PropKa

Software per calcolare le pKa dei residui titolabili di una proteina. Veloce, basato su equazione lineare empirica. Usato nello studio della transizione di Tanford in β -lattoglobulina.

PSI-BLAST (Position-Specific Iterative BLAST)

Variante iterativa di BLAST. Ad ogni ciclo, gli allineamenti significativi vengono usati per costruire un profilo, che diventa la nuova query del ciclo successivo. Maggiore sensibilità per omologhi distanti.

Ramachandran plot

Grafico degli angoli torsionali ϕ e ψ del backbone di ciascun amminoacido di una proteina. Le regioni consentite corrispondono a strutture secondarie standard. Strumento fondamentale di validazione.

RMSD (Root Mean Square Deviation)

Deviazione strutturale media di una struttura rispetto a una di riferimento, misurata sui C α o su tutti gli atomi pesanti. Unità: Å. Strumento principale di analisi delle traiettorie MD.

RMSF (Root Mean Square Fluctuation)

Fluttuazione media di ogni residuo rispetto alla sua posizione media durante una simulazione MD. Identifica regioni rigide vs flessibili.

Rotamero

Una delle conformazioni preferite di una catena laterale amminoacidica. I rotameri sono catalogati in librerie statistiche (es. Dunbrack).

SCOP

Structural Classification of Proteins. Database di classificazione filogenetica strutturale, considera sia sequenza sia architettura.

Similarità di sequenza

Percentuale di posizioni in cui due sequenze allineate hanno amminoacidi simili (sostituzioni conservative), pesata secondo una matrice di sostituzione.

Site Finder

Algoritmo geometrico per identificare cavità di legame su una superficie proteica usando sfere espansive. Sfere grigie (sito ben formato) vs sfere rosse (bordo del sito).

Solvente esplicito

Modello di solvatazione che inserisce molecole d'acqua individuali nella simulazione. Modelli noti: TIP3P, SPC/E, TIP4P.

Solvente implicito

Modello che approssima l'effetto dell'acqua senza inserire molecole esplicite. Più veloce, meno realistico, sovrastima la solvatazione.

Tanford (transizione di)

Cambiamento conformazionale pH-dipendente della β -lattoglobulina, descritto da Charles Tanford negli anni Sessanta. Loop EF chiuso a pH acido, aperto a pH basico. Motore molecolare: pKa anomala di Glu 89.

Templato

Proteina di struttura sperimentale nota usata come modello per ricostruire la struttura della query nell'homology modeling.

Twilight zone

Zona di identità di sequenza (12–25%) in cui non si distingue con certezza fra omologia distante e similarità casuale. Modeling difficile e fragile.

UniProt

Database europeo di sequenze proteiche annotate. Preferito a NCBI-NR per qualità e crosslink ad altri database.

Viterbi (algoritmo di)

Algoritmo che, dato un HMM, calcola la probabilità che il modello generi una data sequenza. Usato per classificazione di appartenenza a famiglia di proteine.

Xenologia

Sotto-tipo di omologia: somiglianza inspiegabile con l'evoluzione normale, attribuita a trasferimento genico orizzontale (tipicamente virale).

Z-score

Punteggio normalizzato: $z = (S - \mu) / \sigma$. Indipendente dalla matrice e dal database. Soglia operativa di significatività: $z \geq 5$.

Tabelle riassuntive

Sintesi visive dei concetti chiave

T1. Identità di sequenza e inferenza strutturale

% Identità	Inferenza	Affidabilità modello
> 70%	Architettura, struttura, funzione conservate	Molto alta
45–70%	Architettura e struttura conservate, funzione probabile	Alta
25–45%	Architettura conservata, struttura approssimativa	Media
12–25%	Twilight zone — omologia incerta	Bassa
< 12%	Midnight zone — similarità casuale più probabile dell'omologia	Inadeguata

T2. Significatività statistica degli allineamenti

Metrica	Valore	Significato
Z-score	≥ 5	Significativo
P-value	$\leq 10^{-5}$	Omologia molto probabile
E-value	$\leq 0,02$	Soglia operativa di omologia
E-value	$0,02 - 1$	Zona ambigua
E-value	> 1	Verosimilmente non omologhi

T3. Approssimazioni di Dayhoff (PAM)

#	Approssimazione
1	$P(i \rightarrow j) = P(j \rightarrow i)$: simmetria della matrice (non vera in natura)
2	Niente retromutazioni $i \rightarrow j \rightarrow i$
3	Processo Markoviano: lo stato a t dipende solo da $t-1$
4	Frequenza di mutazione uguale in ogni posizione della proteina (non vera: dipende dalla posizione strutturale/funzionale)

T4. Ensemble termodinamici in dinamica molecolare

Ensemble	Conserva	Uso
NVE (microcanonico)	N, V, E	Sistema isolato; raro in pratica
NVT (canonico)	N, V, T	Termostato; produzione a V costante

Ensemble	Conserva	Uso
NPT (isobaro-isotermo)	N, P, T	Termostato + barostato; equilibratura

T5. Workflow standard di homology modeling

Passo	Strumento
Recupero sequenza query	UniProt
Ricerca template omologo	BLAST su PDB
Selezione template (identità, copertura, qualità)	Valutazione manuale + criteri statistici
Allineamento globale esatto	Needleman–Wunsch + BLOSUM62
Costruzione N modelli alternativi	MOE / Modeller / SwissModel
Ranking modelli	Energia di solvatazione + criteri geometrici
Validazione	Ramachandran + RMSD + dati sperimentali
Raffinamento finale	Minimizzazione energetica in solvente

T6. Sintesi delle famiglie di anticorpi

Isotipo	Catena pesante	Funzione
IgG	γ	Anticorpo serico, biofarmaci, memoria
IgM	μ	Risposta primaria, pentamerico
IgA	α	Mucose, dimerico nelle secrezioni
IgE	ϵ	Allergie, antiparassitario
IgD	δ	Funzione minore

T7. Tre punti chiave del corso

#	Principio cardine
1	Omologia: il core dell'interesse. Misurata surrogatamente con identità e similarità di sequenza.
2	Accuratezza adeguata: scegliere il livello appropriato, non il massimo per principio.
3	Responsabilità: nessun protocollo universale; ogni scelta va giustificata.

Domande d'esame possibili

Raccolte dalle indicazioni esplicite del prof. Eberini

Le domande che seguono sono ricavate o (i) da esplicite indicazioni del docente come potenziali domande d'esame, oppure (ii) da punti su cui il docente ha insistito con particolare fermezza nelle lezioni. Sono organizzate per tema. Per ognuna si indica la sezione del manuale in cui rivedere il contenuto.

A. Domande sui fondamenti (Lezioni 1–2)

D.1 Definisca il concetto di omologia. Perché è importante per la bioinformatica strutturale? Si può parlare di «percentuale di omologia»? Giustifichi la risposta.

Punti chiave della risposta: Omologia = derivazione da antenato comune. Dogma biofisico: proteine omologhe condividono struttura, funzione, architettura. L'omologia è qualitativa (sì/no), non quantitativa: dire «40% di omologia» è sbagliato. Si misura surrogatamente con identità e similarità di sequenza.

Vedi: Sezioni 1.1, 1.1.1, 1.1.2

D.2 Distingua ortologia, paralogia e xenologia con esempi.

Punti chiave della risposta: Ortologia: stessa proteina in specie diverse (es. albumina umana e bovina). Paralogia: proteine omologhe nella stessa specie da duplicazione genica (es. LCAT e ACAT). Xenologia: somiglianza fra specie distanti, spiegata da trasferimento genico orizzontale (virale).

Vedi: Sezioni 1.2.1, 1.2.2, 1.2.3

D.3 Cosa intende Eberini quando afferma che «l'accuratezza più alta non è sempre la più utile»? Faccia almeno un esempio.

Punti chiave della risposta: L'accuratezza deve essere adeguata alla domanda. Esempi: (i) diagnostica COVID: l'antigenico, meno sofisticato, è stato la scelta operativa migliore; (ii) virtual screening di 1,5 milioni di molecole: serve un'accuratezza di ordine di grandezza, non kcal/mol preciso. Lo screening fine di una serie congenere richiede invece alta accuratezza.

Vedi: Sezioni 1.3.1, 1.3.2, 1.3.3

D.4 Distingua architettura e struttura di una proteina.

Punti chiave della risposta: Architettura = modo di folding, condiviso da famiglie/superfamiglie. Struttura = posizione precisa di ogni atomo nello spazio 3D. Identità alta → struttura conservata; identità bassa → almeno l'architettura è spesso conservata.

Vedi: Sezione 1.6

D.5 Quali sono i tre punti chiave del corso?

Punti chiave della risposta: (1) Il core è l'omologia, non identità/similarità in sé; (2) Accuratezza adeguata, non massima per principio; (3) Responsabilità metodologica: non ci sono protocolli universali.

Vedi: Sezione 2.4 / 11.5 / Tabella T7

B. Allineamenti e matrici di sostituzione (Lezione 3)

D.6 Cos'è la matrice dot plot? Quali quattro tipi di pattern si possono osservare e cosa indicano?

Punti chiave della risposta: Matrice di confronto sequenza–sequenza con punteggio binario (match/mismatch). Pattern: (i) diagonale principale = regioni identiche; (ii) spostamenti orizz./vert. = gap (indel); (iii) diagonali secondarie parallele = sequenze ripetute; (iv) diagonali secondarie perpendicolari = sequenze palindromi (es. siti di restrizione, siti TF).

Vedi: Sezioni 3.2.1, 3.2.2

D.7 Cosa sono finestra flottante e ktup nella matrice dot plot? Perché sono necessari?

Punti chiave della risposta: Riducono il rumore di fondo dovuto a match casuali. Finestra flottante = intorno di N celle (tipicamente dispari, 3, 5, 7) attorno alla cella in esame. Ktup = numero minimo di match richiesti nell'intorno per dichiarare il match. Più è ampia la finestra, meno rumore ma anche meno informazione.

Vedi: Sezione 3.2.3

D.8 Distingua distanza di Hamming e distanza di Levenshtein. Quali sono i rispettivi ambiti operativi e le definizioni?

Punti chiave della risposta: Hamming: numero di posizioni differenti fra stringhe di **uguale lunghezza**. Levenshtein: numero minimo di edit (inserzione, delezione, sostituzione) per trasformare una stringa in un'altra, applicabile a stringhe di **qualunque lunghezza**. Non confondere ambito operativo e definizione.

Vedi: Sezione 3.3

D.9 (Domanda tipica) Mi parli delle matrici di sostituzione di Dayhoff. Quali sono le approssimazioni che ha fatto Dayhoff e quale ne è l'impatto sull'uso delle matrici PAM?

Punti chiave della risposta: Dayhoff (1978) costruisce la PAM1 osservazionalmente da proteine ad alta identità. Le altre PAM (30, 80, 250) sono ottenute matematicamente moltiplicando PAM1 per se stessa. Le quattro approssimazioni: (1) $P(i \rightarrow j) = P(j \rightarrow i)$; (2) niente retromutazioni; (3) processo Markoviano; (4) frequenza di mutazione indipendente dalla posizione. Impatto: gli errori si propagano e amplificano nelle matrici PAM derivate; le BLOSUM (osservazionali per ogni range di identità) mitigano significativamente questi problemi.

Vedi: Sezioni 3.5, 3.5.3, Tabella T3

C. Statistica e omologia distante (Lezione 4)**D.10 Cos'è lo Z-score? Perché è utile rispetto al punteggio assoluto di allineamento?**

Punti chiave della risposta: $Z = (S - \mu) / \sigma$. Normalizza il punteggio rispetto alla distribuzione di Gumbel, che dipende da matrice e database. Lo Z-score è indipendente da queste variabili e permette confronti. Soglia: $z \geq 5$.

Vedi: Sezione 4.1.2

D.11 Distingua P-value ed E-value. Cosa significa E = 0,02? Quante proteine devo aspettarmi che generino casualmente un allineamento uguale o migliore?

Punti chiave della risposta: P = probabilità che un singolo allineamento sia casuale. $E = P \times D$ (D = dim. database) = numero atteso di allineamenti casuali con punteggio uguale o superiore. E = 0,02 significa che mi aspetto meno di una proteina (0,02) con punteggio uguale o superiore per caso. Per averne una sola servirebbe un database 50 volte più grande.

Vedi: Sezione 4.1.3, 4.1.4

D.12 Cosa è la twilight zone nell'identità di sequenza? Perché esiste?

Punti chiave della risposta: Zona 12–25% di identità in cui non si distingue omologia distante da similarità casuale. Esiste perché prendendo proteine casuali e confrontandole si trova quasi sempre il 20% di identità per puro caso (alfabeto di 20 amminoacidi).

Vedi: Sezione 4.2.1

D.13 Cos'è un modello di Markov nascosto applicato alle proteine? Quali sono i due algoritmi principali e cosa fanno?

Punti chiave della risposta: HMM = struttura computazionale stocastica con stato nascosto (stati MATCH, INSERT, DELETE) e stato di emissione (probabilità di emettere ciascun amminoacido per ogni stato MATCH). Apprende il pattern di una famiglia di proteine. Algoritmo di **Viterbi**: calcola la probabilità che il modello generi una data sequenza (problema di scoring, classificazione). Algoritmo **forward-backward**: determina il percorso ottimale degli stati per generare una sequenza data (problema di allineamento). Importante: l'HMM **non confronta proteine**; le classifica per appartenenza a famiglia.

Vedi: Sezioni 4.5, 4.5.3

D. Case studies e modeling pratico (Lezioni 5–7)

D.14 Spieggi la transizione di Tanford nella β -lattoglobulina bovina. Quale residuo è il motore molecolare? Quale meccanismo spiega la sua pKa anomala?

Punti chiave della risposta: Cambiamento conformazionale pH-dipendente: a pH acido (stomaco) il loop EF chiude il sito di legame; a pH basico (intestino) il loop si apre. Motore: **Glu 89**, con pKa anomala di ~7,2 (rispetto ai 3,5–4,5 attesi per un acido glutamico). La pKa anomala è dovuta a: (i) collocazione in cavità idrofobica interna; (ii) legame a idrogeno stabile con il backbone della Ser 116. A pH basico il loop si apre, Glu 89 si espone al solvente e la pKa torna normale (4,5).

Vedi: Sezioni 5.5, 5.6.2, 5.6.3

D.15 Perché si fa una doppia validazione (stabilità + affinità) quando si esegue una mutagenesi in silico? Quale soglia di $\Delta\Delta G^\circ_{\text{fold}}$ è considerata preoccupante?

Punti chiave della risposta: Una mutazione che riduce l'affinità osservata potrebbe in realtà destabilizzare il folding, impedendo alla proteina di assumere la struttura nativa. Senza distinguere i due effetti, si rischiano false conclusioni. Soglia: $\Delta\Delta G^\circ_{\text{fold}} > 3\text{--}4$ kcal/mol indica destabilizzazione preoccupante.

Vedi: Sezione 5.8.1

D.16 (Domanda tipica) Su che database fa la ricerca del template per un homology modeling?

Punti chiave della risposta: **Protein Data Bank (PDB)**. Non UniProt o NCBI-NR: questi contengono sequenze ma non strutture sperimentali. Per il modeling serve la struttura 3D del template. Da evitare i modelli AlphaFold su UniProt come template, se possibile, preferendo strutture sperimentali.

Vedi: Sezione 6.2.2 / 9.9

D.17 Quale tipo di allineamento si usa fra la query e il template per il modeling? Perché non si usano gli HSP prodotti da BLAST?

Punti chiave della risposta: Si usa un allineamento **globale ed esatto** (Needleman–Wunsch + BLOSUM62). Gli HSP di BLAST sono **locali** (non coprono tutta la sequenza) ed **euristici** (BLAST è veloce ma non garantisce l'ottimo). Per il modeling serve l'allineamento globale ottimale.

Vedi: Sezioni 6.2.3, 9.8.2

D.18 Spieggi cosa rappresenta il grafico di Ramachandran e quali regioni sono consentite. Cosa sono gli outliers?

Punti chiave della risposta: Plot degli angoli torsionali ϕ e ψ del backbone per ogni amminoacido. Regioni consentite: α -elica destrorsa ($\phi \approx -60^\circ$, $\psi \approx -45^\circ$), foglietto β ($\phi \approx -120^\circ$, $\psi \approx +130^\circ$), α -elica sinistrorsa (rara, tipicamente glicina). L'angolo ω è fisso a 180° (risonanza ammidica del legame peptidico). Outliers = amminoacidi fuori dalle regioni consentite. 0–1 accettabili, 2–3 da verificare nel template, 8+ indica errore di modello.

Vedi: Sezioni 7.3.1, 7.3.2

E. Dinamica molecolare (Lezione 8)

D.19 Su quale principio fisico si basa la dinamica molecolare? Come si calcolano le forze?

Punti chiave della risposta: Seconda legge di Newton: $F = ma$. La forza netta su ogni atomo è $-\nabla U$, dove U è l'energia potenziale calcolata dal **campo di forze**. Da F e m si ricava a , da a si integra numericamente la velocità, da v la posizione. Le velocità iniziali sono assegnate dalla distribuzione di Maxwell–Boltzmann alla temperatura desiderata.

Vedi: Sezioni 8.2, 8.2.1

D.20 Cosa contiene un campo di forze? Distingua termini di legame e di non-legame.

Punti chiave della risposta: Un campo di forze è un insieme di equazioni e parametri per calcolare $U(r)$. Termini di legame (bonded): stretching dei legami (oscillatore armonico), bending degli angoli (oscillatore armonico), torsioni (serie di Fourier periodica). Termini di non-legame (non-bonded): elettrostatica (Coulomb fra cariche parziali) e van der Waals (Lennard–Jones 12–6). Esempi: AMBER, CHARMM, OPLS, GROMOS.

Vedi: Sezione 8.3

D.21 Quali sono i tre ensemble termodinamici principali in MD? Cosa conservano e quando si usano?

Punti chiave della risposta: **NVE** (microcanonico): conserva N , V , E . Sistema isolato; raro in pratica. **NVT** (canonico): conserva N , V , T tramite termostato; per produzione a volume fisso. **NPT** (isobaro-isoterma): conserva N , P , T con termostato + barostato; fondamentale durante l'equilibratura per raggiungere la densità corretta.

Vedi: Sezione 8.7, Tabella T4

D.22 Cosa sono le Periodic Boundary Conditions? Perché sono necessarie?

Punti chiave della risposta: Strategia per cui la box di simulazione è replicata infinitamente in tutte le direzioni. Una molecola che esce da un lato rientra dal lato opposto. Evita artefatti di parete: senza PBC, le molecole d'acqua urterebbero contro pareti rigide generando comportamenti non fisici.

Vedi: Sezione 8.6.3

D.23 Quali sono le principali limitazioni della MD classica e cosa permette di superarle?

Punti chiave della risposta: Limitazioni: (i) scala temporale limitata (nanosecondi–microsecondi), insufficiente per molti eventi biologici (folding, transizioni grandi); (ii) impossibilità di attraversare barriere energetiche elevate (il sistema rimane intrappolato in minimi locali). Soluzione: metodi di **enhanced sampling** come Accelerated MD (aMD), Metadynamics, Replica Exchange. L'aMD aggiunge un potenziale di boost che abbassa le barriere energetiche.

Vedi: Sezioni 8.9, 8.9.1

F. Predizioni dalla sequenza e BLAST (Lezione 9)

D.24 Distingua proprietà locali e globali di una proteina. Faccia almeno un esempio di ciascuna.

Punti chiave della risposta: Proprietà locale: dipende dai residui vicini in sequenza primaria. Esempio: struttura secondaria. Proprietà globale: dipende da residui vicini nello spazio 3D, anche se lontani in sequenza. Esempio: ponti disolfuro, esposizione al solvente, interazioni residuo–residuo a lunga distanza. Implicazione: la struttura secondaria è predicibile dalla sola sequenza con buona accuratezza; le proprietà globali richiedono la struttura 3D.

Vedi: Sezione 9.4

D.25 Cos'è una rete neurale? Cos'è un perceptrone? Quali strati compongono una rete per la predizione della struttura secondaria?

Punti chiave della risposta: Rete neurale = modello matematico di neuroni artificiali (perceptroni) interconnessi. Perceptrone = neurone elementare che riceve input pesati, li somma, e si attiva (output 0 o 1, o sigmoidale fra 0 e 1) se la somma supera una soglia. Strati per struttura secondaria: input layer (300 perceptroni: 15 finestra $\times$ 20 amminoacidi); hidden layer (interno, «scatola nera»); output layer (3 perceptroni: α , β , coil). Pesi ottimizzati nella fase di training.

Vedi: Sezioni 9.6, 9.6.1, 9.6.2

D.26 Descriva passo per passo l'algoritmo di BLAST.

Punti chiave della risposta: (1) Rimozione regioni a bassa complessità; (2) frammentazione della query in parole fisse; (3) ricerca delle parole simili nel database; (4) estensione bidirezionale di ogni match finché il punteggio cresce; (5) generazione degli HSP; (6) merging di HSP vicini (distanza ≤ 10) con gap (Gapped BLAST); (7) ranking per punteggio e calcolo dell'E-value. BLAST è locale, euristico, veloce.

Vedi: Sezione 9.8.1

G. Modeling avanzato, anticorpi e glicoforme (Lezioni 10–12)

D.27 Cos'è CASP e perché è importante? Come è organizzato il ciclo biennale?

Punti chiave della risposta: CASP = Critical Assessment of protein Structure Prediction. Gara biennale: i ricercatori sperimentali risolvono strutture tenendone segreti i dati; ai bioinformatici viene data la sola struttura primaria e si chiede di predire la struttura 3D. Le predizioni sono confrontate con i dati sperimentali. Nel primo anno si predice e si valuta; nel secondo gli assessor pubblicano i risultati (rivista *Proteins: Structure, Function, and Bioinformatics*). Primo CASP nel 1994 (35 gruppi); ~250 gruppi nel 2006–2008. Ha dimostrato che la predizione ab initio è possibile, se presa criticamente.

Vedi: Sezione 10.6

D.28 Qual è la gerarchia dei metodi di predizione (omologia, threading, de novo)? Qual è la posizione del prof. Eberini su AlphaFold?

Punti chiave della risposta: Gerarchia di accuratezza: **homology modeling** (la più alta, ma richiede un template omologo) > **threading** (prova tutte le architetture note e sceglie quella a energia più bassa; accuratezza intermedia) > **de novo/ab initio** (solo potenziali chimico-fisici/statistici; accuratezza bassa). Su AlphaFold: **non** ha risolto il problema del folding; dove esiste un buon template omologo l'homology modeling resta superiore. Ordine di priorità: (1) omologia, (2) threading, (3) ab initio basato su AI. I metodi AI vanno usati ma con spirito critico.

Vedi: Sezioni 10.7, 10.8

D.29 Cosa sono i CDR di un anticorpo? Quanti sono, come si distribuiscono e quale è il più critico da modellare e perché?

Punti chiave della risposta: CDR (Complementarity-Determining Regions) = parte ipervariabile del framework variabile, formano il paratopo. Sono **sei**: tre sulla catena leggera (L1, L2, L3) e tre sulla pesante (H1, H2, H3). Cinque (L1–L3, H1, H2) assumono un numero ristretto di conformazioni e sono prevedibili; l'**H3** è il più critico perché assume molte più conformazioni e spesso va modellato de novo (es. via dinamica molecolare) quando non si trova un loop simile nei database.

Vedi: Sezioni 11.4, 11.13

D.30 Descriva il caso CNT-O627. Quale strategia di ottimizzazione è stata adottata e con quale duplice effetto?

Punti chiave della risposta: CNT-O627 = anticorpo anti-IL-13 (asma/allergie), efficace ma con aggregazione in vivo (precipitazione renale e infiammazione) dovuta a una **patch idrofobica** superficiale. Strategia duale: (1) ridurre la patch idrofobica sostituendo amminoacidi idrofobici (es. **Met 92**, peraltro anche ossidabile, con un residuo idrofilo: M92E fa doppia interazione con Asn 19 e Asn 23); (2) migliorare l'affinità per ridurre la dose. Con mutagenesi automatica + calcolo di affinità il mutante migliore risulta Arg (al posto di Met 92) + Thr (al posto della valina), con $\Delta\text{Affinity} \approx -4,4$ kcal/mol. Esito: anticorpo meno idrofobico, meno aggregante, più affine, a dose ridotta.

Vedi: Sezioni 11.6–11.11

D.31 Perché l'allineamento globale esatto query–template è il passaggio più critico del modeling? Cosa succede se è sbagliato di una posizione?

Punti chiave della risposta: Perché il modello viene costruito copiando dal template le posizioni allineate: un errore di allineamento si traduce direttamente in un errore strutturale. Slittando l'allineamento di **una sola posizione**, ogni amminoacido della query si allinea al residuo sbagliato del template, generando un modello completamente errato: compaiono **clash** (catene laterali che si sovrappongono) e **vuoti** nel core. Da non confondere con l'allineamento a coppie fatto su PDB per cercare il template: questo è il riallineamento globale ed esatto fatto *dopo*, per costruire il modello.

Vedi: Sezioni 10.1, 10.3

D.32 Descriva la procedura generale del modeling de novo/ab initio non basato su AI. In cosa differiscono Rosetta e I-TASSER?

Punti chiave della risposta: Procedura: (1) frammentare la proteina in pezzetti di 3–9 residui; (2) modellare ogni frammento con potenziali chimico-fisici/statistici; (3) ricombinare in tutti i modi possibili generando molti **decoy**; (4) minimizzarne l'energia; (5) **clusterizzare** i decoy; (6) prendere il cluster più popolato; (7) generarne la struttura media e minimizzarla = modello più credibile. **I-TASSER** (gruppo Zhang) è un server automatico basato su **threading** (algoritmo MUSTER su profili), metaserver, scoring con CHARMM22 e conteggio dei legami a idrogeno (da normalizzare per numero di residui). **Rosetta** è una suite; il modulo ab initio è **Robetta**, che usa Monte Carlo + selezione di Metropolis e si concentra sulle interazioni a corto raggio.

Vedi: Sezioni 10.11, 10.11.1, 10.11.2

D.33 Perché le proteine transmembrana sono difficili da modellare? Cosa dice la regola di von Heijne?

Punti chiave della risposta: Sono difficili da purificare e risolvere sperimentalmente (pochi templati; ricche di residui idrofobici che destabilizzano fuori dalla membrana). Le eliche transmembrana hanno spesso **kink** introdotti dalla prolina (helix breaker). La **regola di von Heijne** (positive-inside rule) afferma che gli amminoacidi carichi positivamente si trovano prevalentemente sul lato **intracellulare**; permette di stabilire la polarità di attraversamento (N→C o C→N) della membrana. Alle interfacce membrana-solvente si trova inoltre una **cintura aromatica** (tirosine, triptofani) che posiziona l'elica alla giusta profondità.

Vedi: Sezione 10.10

D.34 Come influisce la glicosilazione del dominio Fc sull'attività di un anticorpo? Cosa rivela lo studio di dinamica molecolare delle glicoforme?

Punti chiave della risposta: La glicosilazione dell'Fc (su Asn 297) modula l'attività effettrice. Glicoforme: **fucosilata** (ADCC di base), **afucosilata** (affinità aumentata per FcγRIIIa, ADCC potenziata), **aglicosilata** (perde l'interazione coi recettori Fc, solo neutralizzante). La MD mostra che la glicosilazione controlla la compattezza dell'Fc (R_g), la mobilità dei Fab e la rete di acque strutturali stabilizzanti; la **dinamica accelerata** (aMD) rivela che il fucosio aumenta la mobilità rotazionale dei Fab. L'insieme fornisce la base per scegliere la glicoforma ottimale per il contesto terapeutico (afucosilata in oncologia per massimizzare l'ADCC; aglicosilata per neutralizzare senza effettori).

Vedi: Sezioni 12.3, 12.5–12.10

— colofone —

Questo manuale è stato compilato a partire dalle trascrizioni automatiche WhisperX (modello large-v3, Demucs attivo) delle dodici lezioni del prof. Ivano Eberini, con il contributo del dott. Davide Bassani sulla dinamica molecolare, tenute presso l'Università degli Studi di Milano nei mesi di marzo, aprile e maggio 2026.

Le trascrizioni grezze sono state corrette ricostruendo la terminologia tecnica originaria a partire dal contesto biochimico e dalla letteratura di riferimento, organizzate in forma accademica, integrate da glossario, tabelle riassuntive e raccolta di domande d'esame. Le trascrizioni delle Lezioni 10, 11 e 12 (validazione e modeling de novo; pratica MOE sull'anticorpo CNT-O627; dinamica molecolare delle glicoforme anticorpali) provengono da trascrizioni WhisperX in alcuni tratti fortemente degradate, di cui è stato decodificato e ricostruito il contenuto tecnico a partire dal contesto biochimico e computazionale.

per aspera ad scientiam